DAY 1
上午

AI Agent 与数据基础

上午 · 认知 Agent，界定任务，看清数据

Day 1 上午 · 180 min · 看得懂 Agent，说得清任务，认得出数据

连享会《AI 数据分析实战专题》
主讲：杨楷
深圳大学 · 经济学院

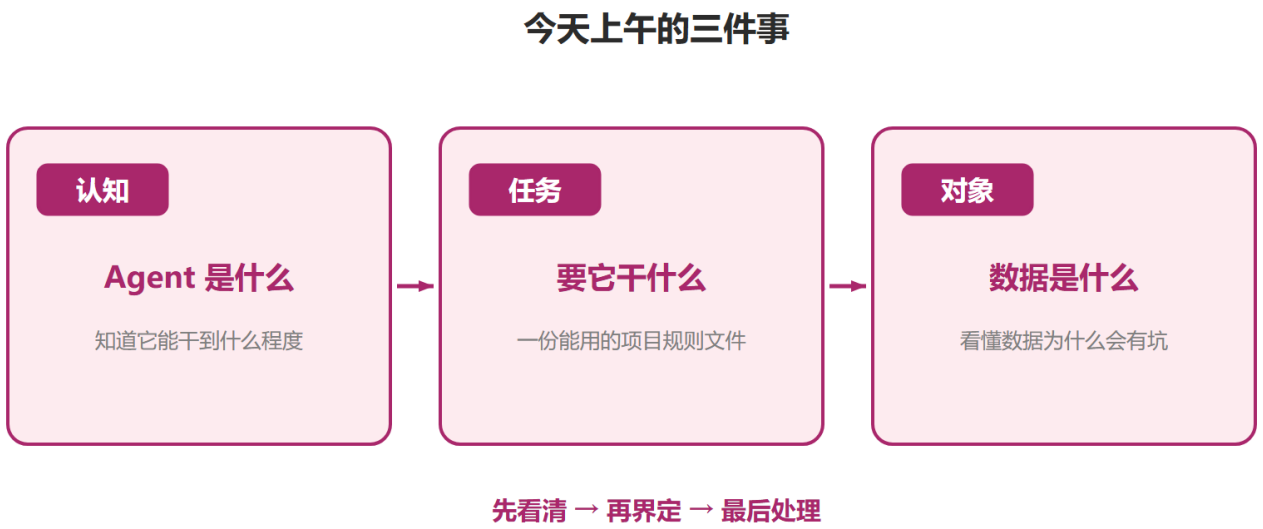
00

开场

今天的三件大事

今天上午要解决的三件事

- 第一件事：AI Agent 到底是什么，它能替我们干什么
- 第二件事：我们要让 Agent 干的那件事，边界在哪
- 第三件事：它要处理的那个东西——数据，究竟是什么



上午路线图

时段	模块	你会拿走什么
09:10 – 10:00	AI Agent 基础	知道 Agent 能干到什么程度
10:00 – 10:50	问题界定	一份能用的项目规则文件
10:50 – 11:35	数据底层原理	看懂数据为什么会有坑

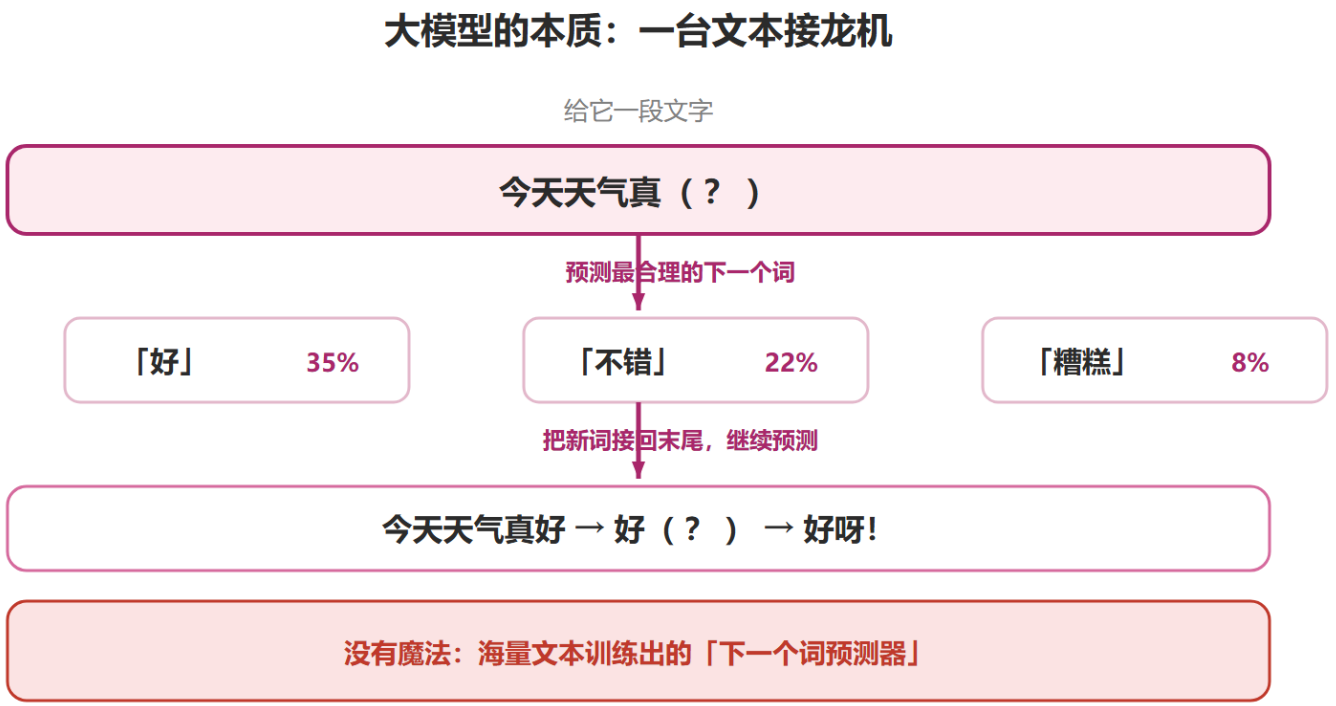
01

AI Agent 基础

大模型 • Harness • 项目主线

大模型本质：一台文本接龙机

- **大模型 = 给定一段文字，预测最合理的下一段**
- 没有魔法：它是海量文本训练出来的「下一个词预测器」
- 输入整数串 → 输出仍是整数串，中间的「理解」是统计规律

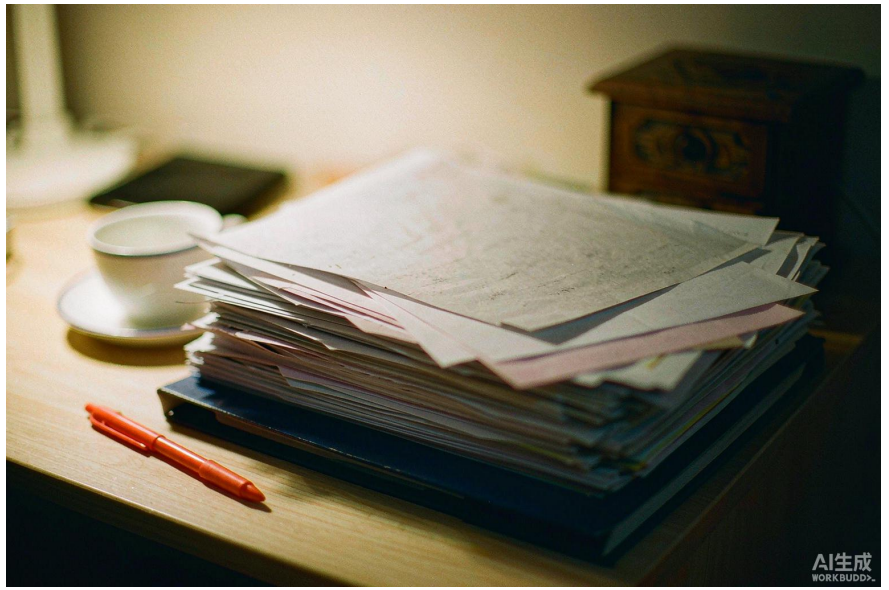


它能「看到」什么：四类输入

- **纯文本：提问、一段资料、财报原文**
- 文件：PDF / Word / Excel，年报 PDF 直接丢进去
- 图片：课件截图、手写公式、财报里的图表
- 链接：网页 URL，巨潮资讯的公告页面

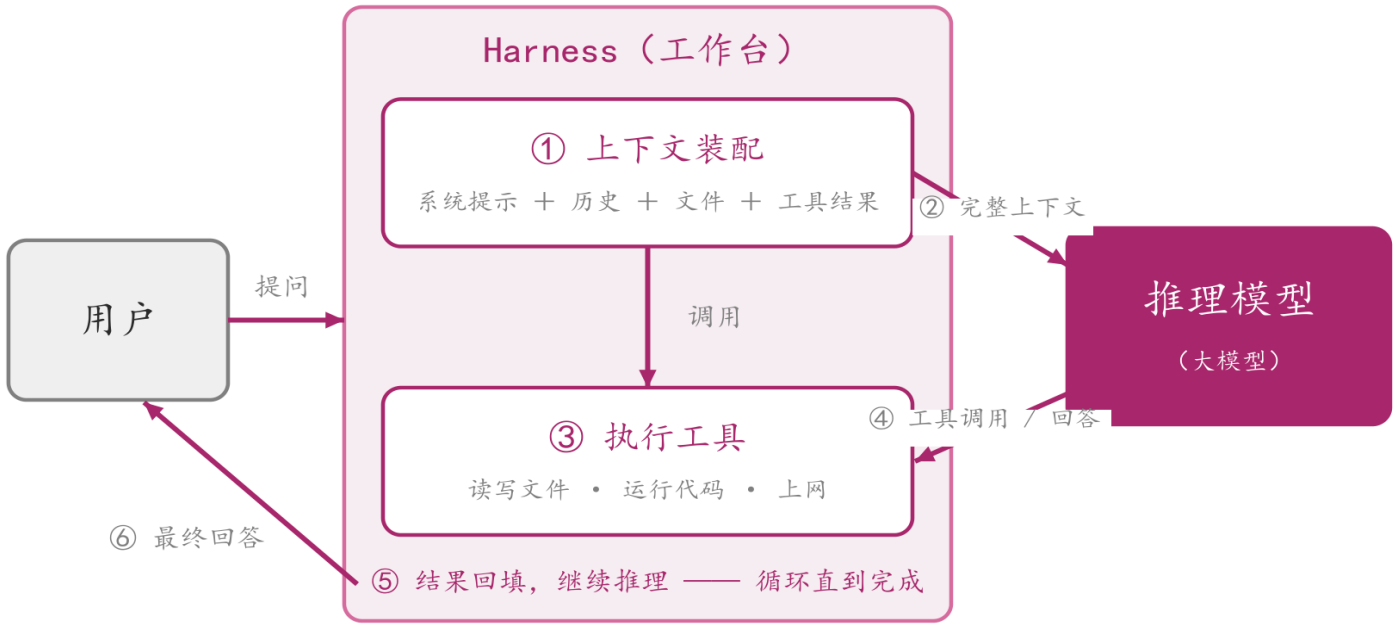
从「会聊天」到「会干活」

- **网页版：你说一句，它答一句，结束**
- Harness：你给目标，它自己拆解任务
- 关键差别：能不能调用工具——读写文件、跑代码、上网
- 它会检查结果、迭代、直到做完才停



Harness 的一次工作循环（详解图）

- **五步闭环：目标 → 拆解 → 执行 → 检查 → 迭代**
- 真正的执行发生在你的电脑上，不是在模型里
- 结果不合格就回到拆解，循环直到任务完成



网页版 vs Harness：一张表看差别

对比项	网页版	Harness
能不能读我的文件	只能上传单个	直接读整个文件夹
能不能跑代码	不能	能，当场执行
重复 48 次的任务	手动做 48 遍	一句话批量完成
适合什么	快速问答、改写材料	成体系的重复劳动

拆开看：模型收到了什么、吐出了什么？

① 原始输入：一个巨大的 JSON

```
{
  "model": "hy4-preview",
  "messages": [          ← 全部历史
    { "role": "system",   身份+规则 },
    { "role": "user",     “帮我看看目录” },
    { "role": "assistant", ... },
    ... 共 135 条
  ],
  "tools": [             ← 23 个工具
    { "name": "Bash",
      "description": "执行命令…" },
    ...
  ],
  "stream": true
}
```

即 HTTP 请求体（请求.txt，36 万字符）

② 模型的输出：仍然只是文本

普通聊天时：

```
{ "role": "assistant",
  "content": "我来帮你看看…" }
```

想调命令行时，输出变成：

```
{ "role": "assistant",
  "tool_calls": [ {
    "function": {
      "name": "Bash",
      "arguments": "{\"command\":
        \"ls -la ...\"}" } ] }
```

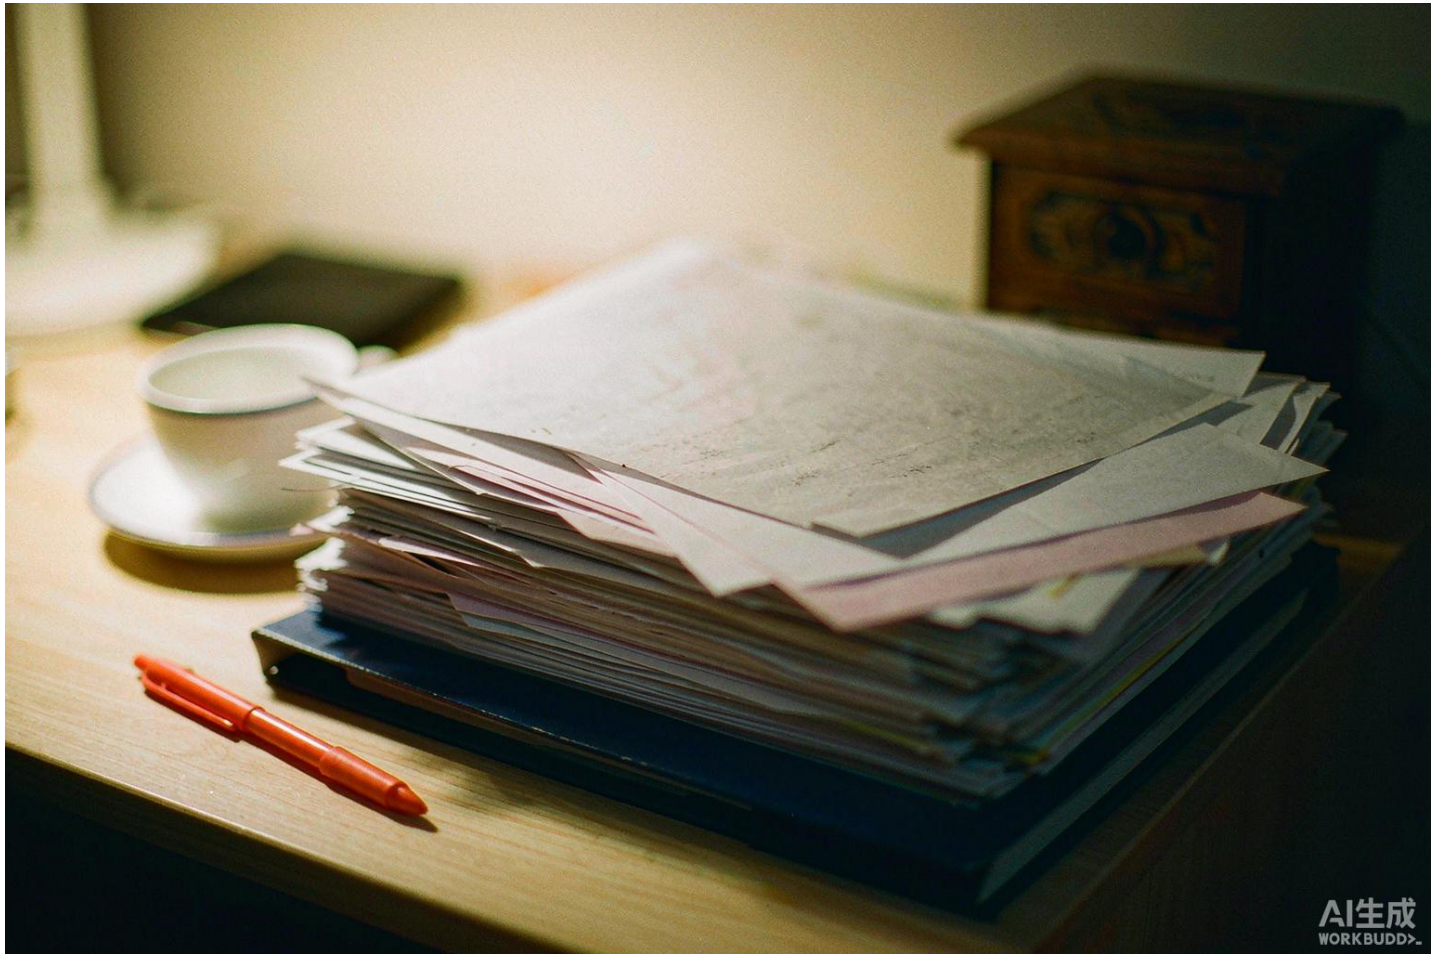
两种都只是文本 —— 后一种是“按约定格式写的申请单”

③ 破解疑惑：谁在真正执行？

- 模型没有“手”，碰不到你的电脑
- 它只是把命令写成**约定格式的 JSON**
- Harness 解析后**代它真正执行**
- 结果回填 → 再问模型循环，直到完成

记住：LLM 只负责生成文本，从未碰过你的电脑 —— 真正执行命令的，永远是 Harness

同一个任务，两种体验



任务：批改 48 份学生作业并汇总成绩表 —— 网页版要重复 48 次；Harness 一句话“读取 ./作业 文件夹，逐一批改，汇总成 Excel”，它自己干完

主流 Harness 工具

工具	形态	特点
Claude Code	命令行 / IDE 插件	开发者首选，生态最成熟
WorkBuddy	桌面 Agent	中文友好、技能市场丰富（今天用它演示）
Cursor	AI 代码编辑器	写代码、改项目
通义灵码 / 文心快码	IDE 插件	国内合规，免费额度较大

收费模式与选择建议

订阅制

Claude Pro $20/月起 • 按月包干，有用量窗口

API 按量计费

按 token 计费，用多少付多少，适合跑具体任务

免费 / 国内合规

国内网页版大多免费或低价

建议

偶尔用用 → 国内网页版，¥0

每天处理文件课件 → 订阅一个主流 Harness，$20 – 100/月

注意：成绩、未公开科研数据注意合规，优先本地化方案

三个必须懂的概念

Context • Skills • MCP

上下文（Context）：工作记忆

定义：模型在一次对话中能“看到”的一切内容

直观感受

相当于给模型一张“工作台”，台上东西太多，早先的就会被挤掉



三个特性

有限

窗口有上限：20 万 token ≈ 一本书

会满

早期内容被“挤出”，模型开始忘事

花钱

上下文越长，越贵、越慢

实操：资料要“精”，不要“多”

系统提示 + 历史对话 + 文件 + 工具结果，全都挤在一个有限的窗口里：新的进来，最早的被“挤出”

上下文：模型的工作台

Anthropic-Claude

官方价格地址:https://docs.anthropic.com/en/docs/about-claude/pricing

官方模型列表:https://docs.anthropic.com/en/docs/about-claude/models/overview

接入端点:

`https://api.zhizengzeng.com/v1/chat/completions` (openai格式请求)

`https://api.zhizengzeng.com/anthropic` (注意这只是基地址,claude格式请求)

模型名称	供应商	提问价格(官方)	回答价格(官方)	模型说明
claude-fable-5-1	Anthropic	$10 /1M tokens	$50 /1M tokens	Claude最新模型
claude-fable-5	Anthropic	$10 /1M tokens	$50 /1M tokens	Claude最新模型
claude-mythos-5	Anthropic	$10 /1M tokens	$50 /1M tokens	Claude最新模型
claude-opus-5	Anthropic	$5 /1M tokens	$25 /1M tokens	Claude opus 5

上下文：有限、会满、花钱

① 有限

窗口有上限：20 万 token 约等于一本中等厚度的书

② 会满

塞太多，早期内容被“挤出”，模型开始“忘事”

③ 花钱

上下文越长，费用越高、响应越慢

实操启示

长对话感觉“变笨” → 开新对话，把关键结论粘贴过去

给模型的资料要“精”，不是“多”

Skills：给 Agent 装的“技能包”

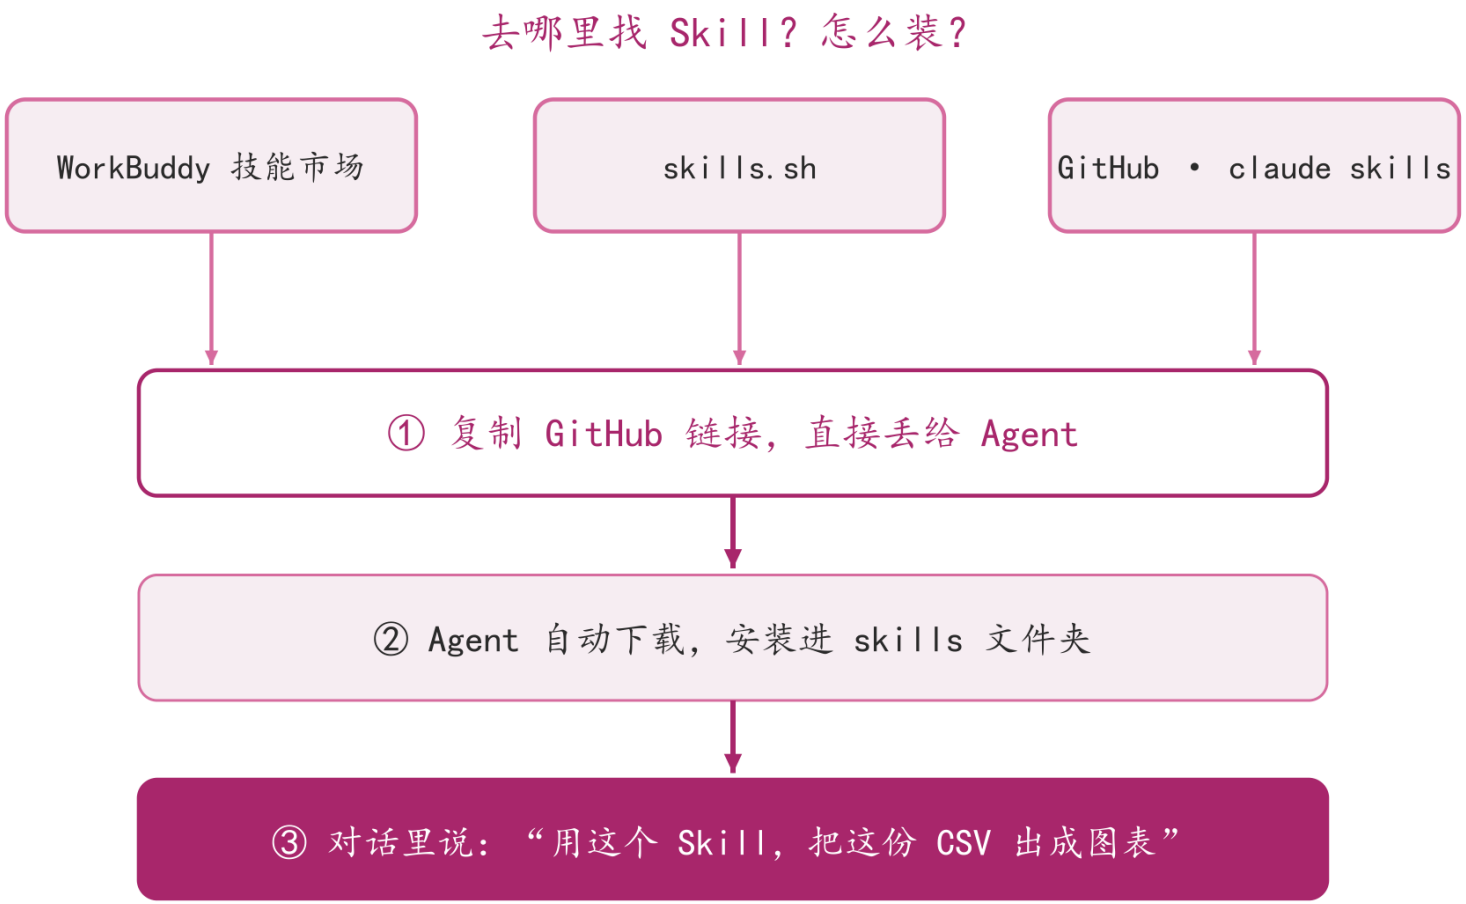
定义：一个打包好的指令文件夹（SKILL.md ＋ 配套脚本/资料），教 Agent 按固定流程完成某类任务

类比：Agent 是个聪明但不了解你单位情况的实习生，Skill 就是你写给它的“岗位 SOP 手册”



一个 Skill = 一个文件夹 ＋ 一份说明书（SOP）。例：“成绩分析” Skill = 读 CSV → 算分布 → 出图 → 出报告

Skill 从哪里获取？怎么安装？



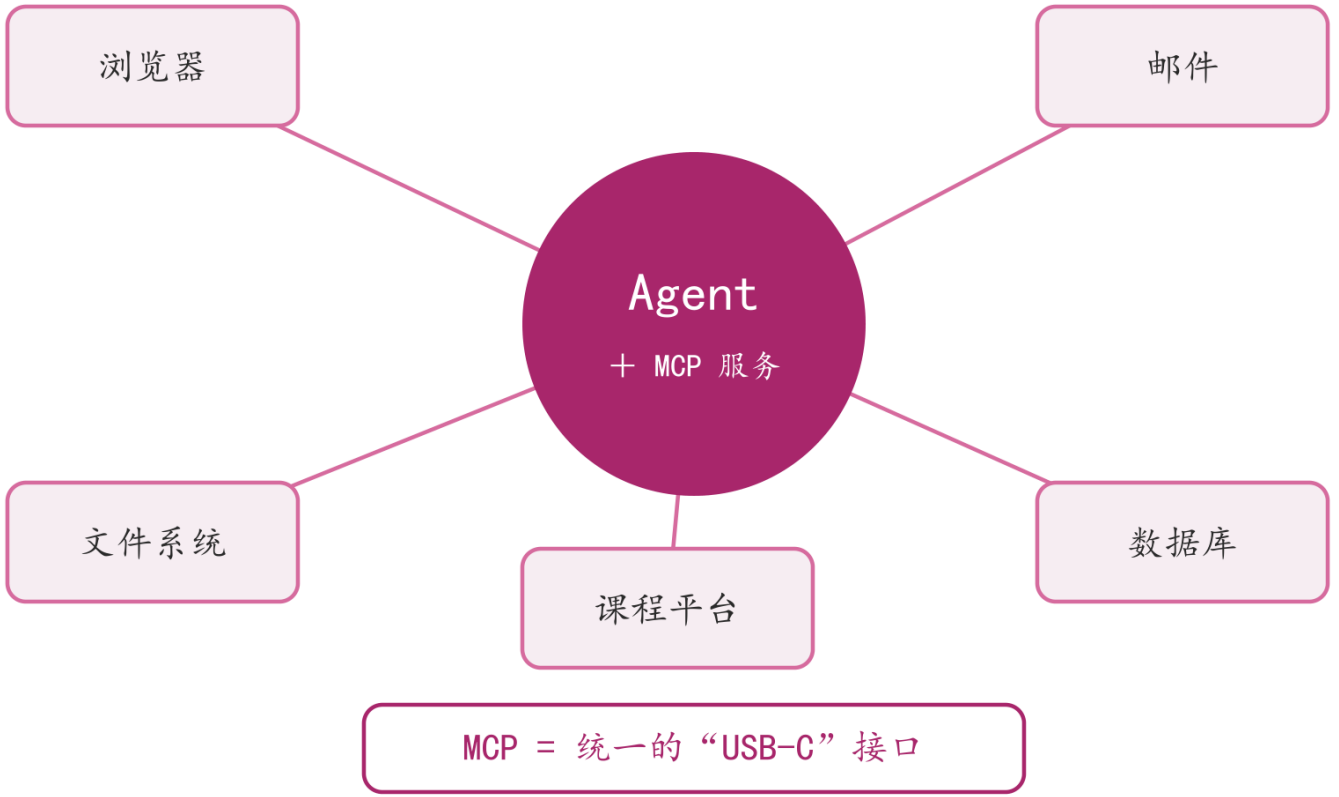
三个来源：技能市场 • skills.sh • GitHub —— 一般不用挑方法：把 GitHub 链接直接丢给 Agent，它就自动装好

MCP：Agent 的 USB-C 接口



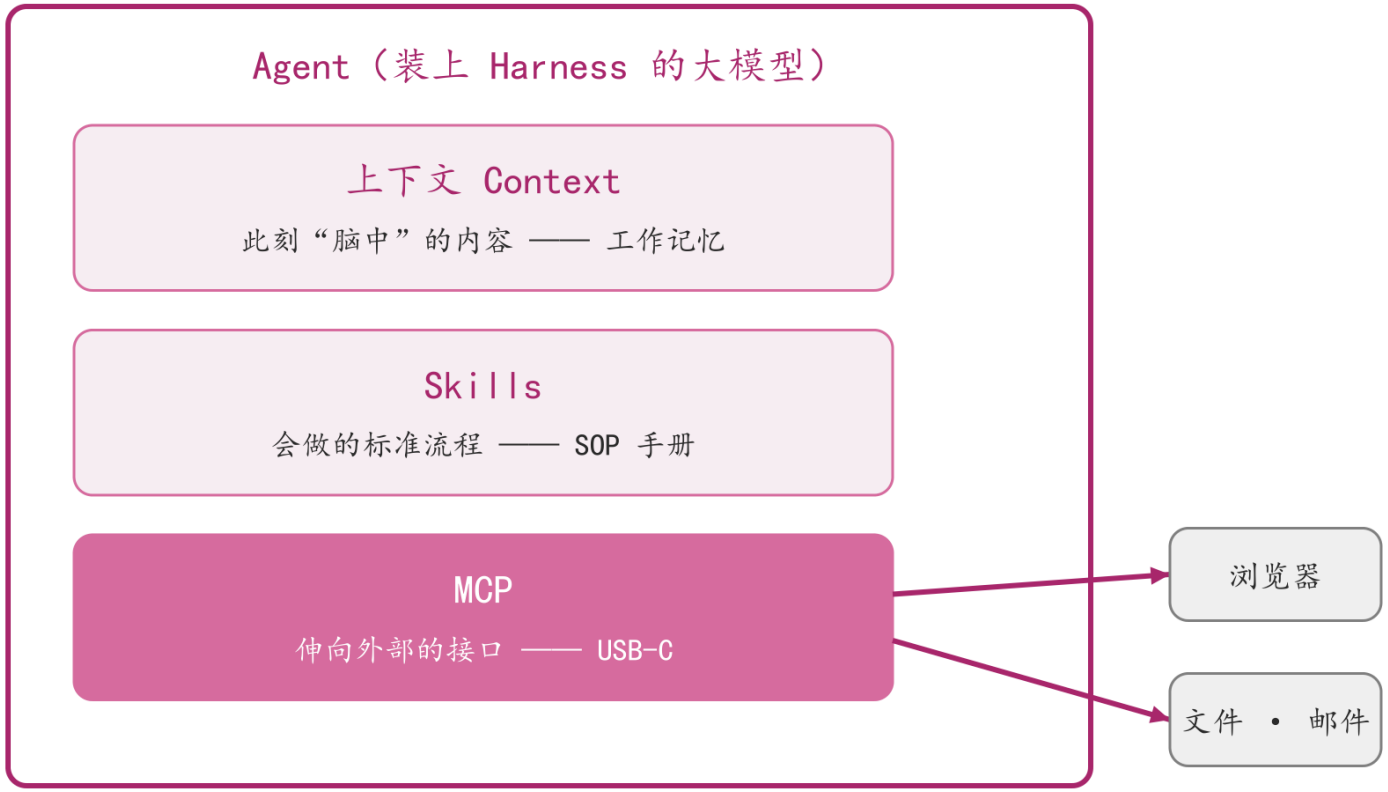
MCP（Model Context Protocol）：开放协议，让 Agent 以标准方式连接外部工具与数据 —— 以前每个设备一个专用接口，现在统一一个口，插什么都可以

MCP：一个接口，连接一切



装上对应的 MCP 服务，Agent 就能操作浏览器、文件、邮件、数据库、课程平台 —— 全部走同一个标准协议

三者关系一图流



上下文 = 此刻“脑中”的内容 • Skills = 会的流程 • MCP = 伸出去的接口

我们的项目：一条主线走三天

- **一条主线，不是五个互不相干的练习**
- Day1 上午先做第一环：定义任务 + 看懂数据
- Day2 / Day3 在这条线上继续往下走



这个项目的目标：给上市公司做财务舞弊预警

- **输入：上市公司公开披露的财务数据与年报文本**
- 输出：一家公司的财务困境风险评分 + 舞弊可疑度
- 用途：投资判断、信贷审批、审计线索筛查
- 全程不写一行代码模型，靠 Agent 驱动完成

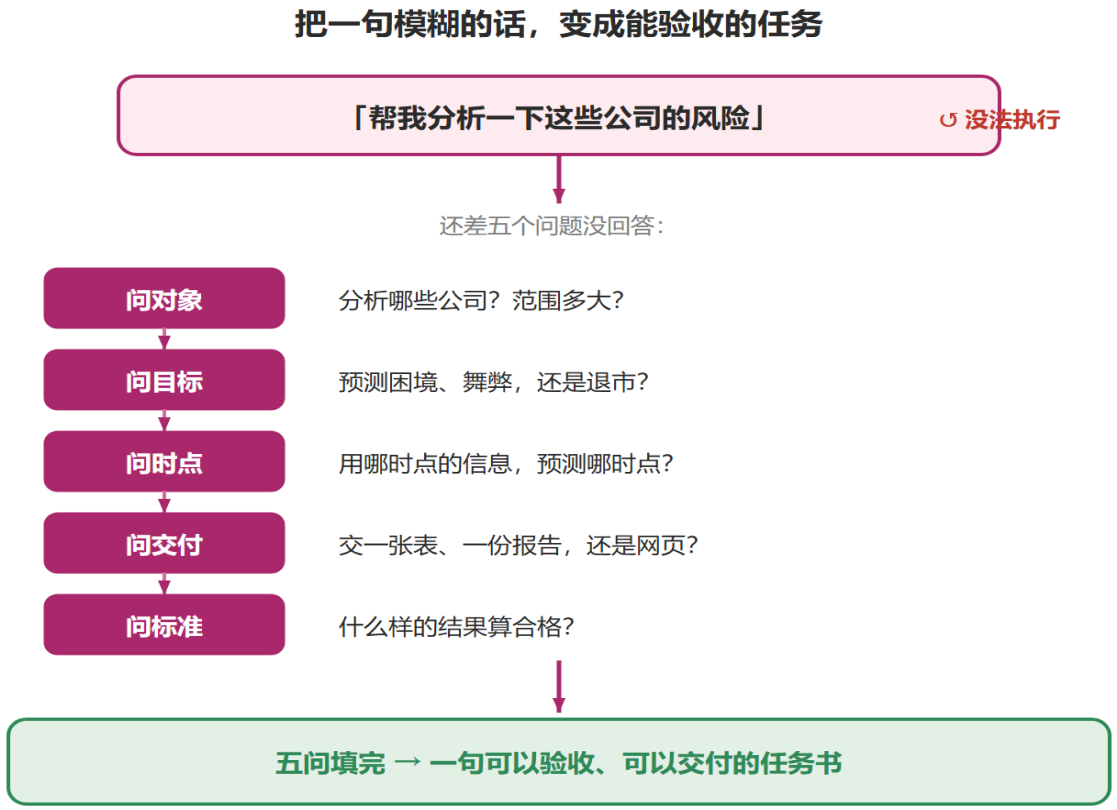
02

问题界定

五问 • 两前提 • 三口径

立项：把一句模糊的话，变成能验收的任务

- 原始需求往往长这样：「帮我分析一下这些公司的风险」
- 这句话 Agent 没法执行——因为它有五个问题没回答
- 本模块要做的：把这五个问号一个个填上



五次追问：界定边界

- **问对象：分析的是哪些公司？范围多大？**
- 问目标：预测的是什么事件？困境、舞弊，还是退市？
- 问时点：用哪个时点的信息，预测哪个时点的结果
- 问交付：最终交出什么？一张表、一份报告，还是一个网页
- 问标准：什么样的结果算合格

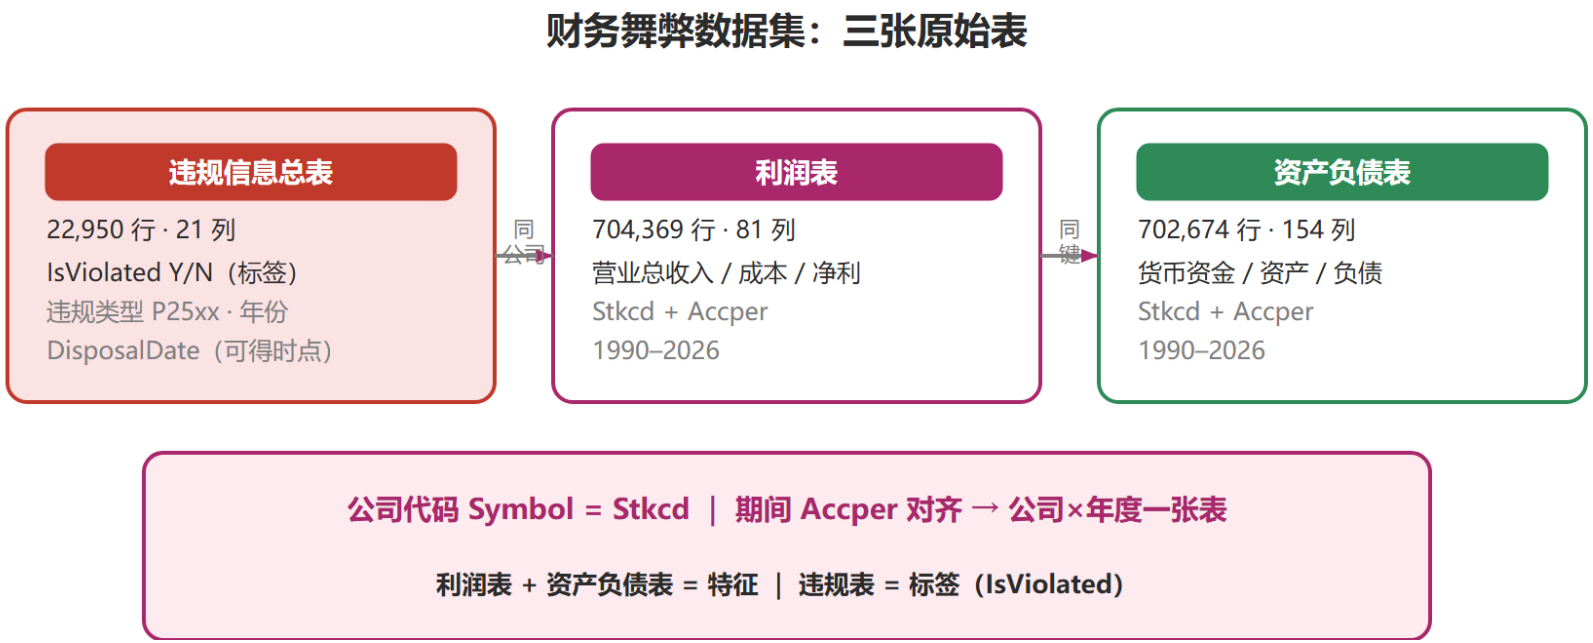
案例：财务舞弊数据集长什么样

三张原始表，全部来自国泰安（1990－2026）

违规信息总表：22,950 条处罚事件，IsViolated 打标签

利润表：70 万行，营业总收入/成本等 81 个科目

资产负债表：70 万行，货币资金/负债等 154 个科目



数据基座：让 AI 先看懂数据，再让它干活

AI 要处理数据，第一步永远是「先看懂」

表格类（xlsx/csv）→ Agent 检查数据，生成一份 md 索引

索引写清：字段含义、主键、表间关联、质量陷阱

文档类（PDF/年报全文）→ 向量数据库 + RAG，Day3 详解

索引就是数据基座 —— 后续所有 Agent 都靠它接入

两类数据，两种接入方式

表格类数据（结构化）

xlsx / csv / 数据库表

→ Agent 检查数据、生成索引 md

→ 索引里写清：字段/主键/关联/陷阱

→ AI 后续读索引即可正确取数

→ 本项目：舞弊数据集 3 张表

（今天上午实操）

文档类数据（非结构化）

PDF / Word / 网页 / 年报全文

→ 切片 + 向量化 → 向量数据库

→ 语义检索（RAG）让 AI 引用原文

→ 主流：Milvus / Pinecone / 云服务

→ 本项目：年报文本（Day3 详解）

（Day3 上午细讲）

共同目标：让 AI 先看懂数据长什么样，再让它干活

让 Agent 先看懂原始数据：做索引

第一步不是取数，是让 Agent 读懂三张表

它逐表扫描表头、抽样行，写出一份索引 md

字段含义、主键、表间关联、质量陷阱写清楚

人审索引：索引写歪，后面全部白做



给 Agent 的第一条指令：先探索数据

不要直接告诉 AI 用哪张表 —— 让它先自己把三张表摸一遍，写一份「数据探索文档 DATA.md」。

请你先探索这三张原始表（违规信息总表 / 利润表 / 资产负债表），

然后生成一份数据探索文档 DATA.md，写清楚：

- 每张表有哪些字段、主键是什么
- 表与表之间靠什么键关联（Symbol = Stkcd，Accper 对齐）
- 数据质量陷阱（说明行、缺失、单位、口径不一致）
- 哪些字段与「舞弊」最相关

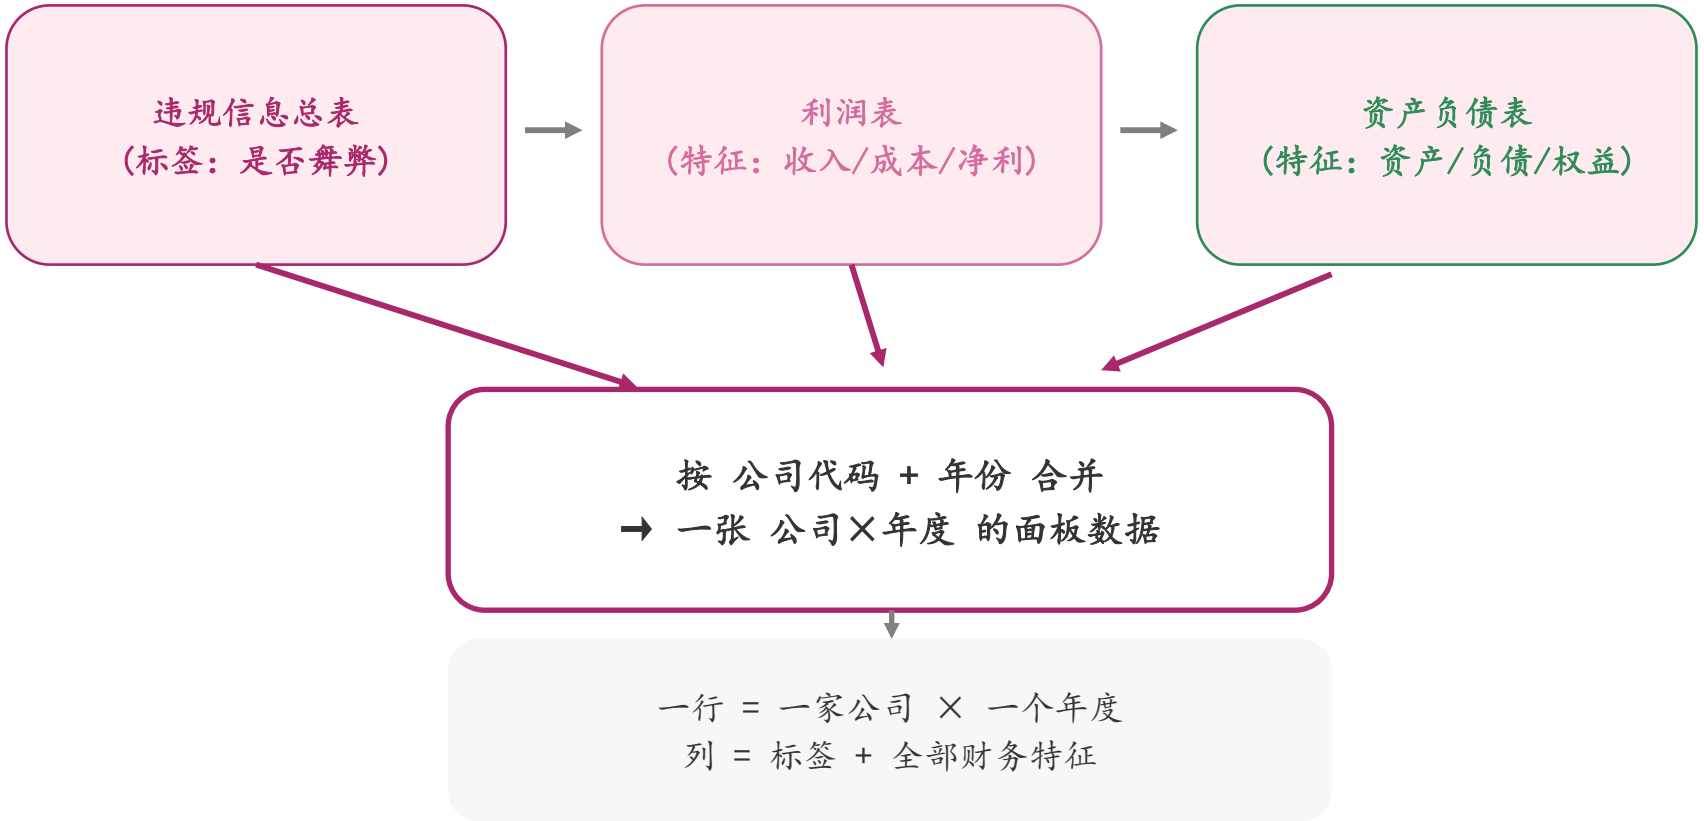
不用写得像论文那么长，抓重点、给我一份可复用的索引。

DATA.md 是给 Agent 的「数据基座」—— 后面所有步骤都先读它再干活（Day1 下午「数据基座」页会收束）

问题界定

为什么突然要合并：一张「面板数据」

三张表各有用途，但建模要的是一张「一家公司、一个年度、一行」的宽表 —— 这就是面板数据。



怎么合并才不犯错（键、口径、标签时点）→ 需要一份 PROJECT_RULES.md 写清楚规则

给 Agent 的第二条指令：把合并规则写成文档

把「怎么合并」的规则交给 Agent 起草 —— 我们审核定稿。这就是 PROJECT_RULES.md。

我要基于三张表构建财务舞弊预测模型，需要先合并成公司-年度面板数据。

请你起草一份 PROJECT_RULES.md，写清楚：

- 舞弊口径：哪些违规类型算（P2501-P2506），哪些排除
- 标签时点：按违规年度打标签，不用处罚公告日（防时间泄漏）
- 合并键：Symbol = Stkcd，Accper 对齐到 12-31 年报
- 合并方向：财务表 left join 标签，保留全部公司-年

先给一版大纲，我审完再定稿。

Human-in-the-Loop：DATA.md / PROJECT_RULES.md 都由 Agent 起草、人来审核；
定稿后所有后续步骤照它执行 —— 学完机器学习后，这份规则还会继续补「建模约束」

建模约束（数据划分、防泄漏、评估指标）→ Day2 上午补齐

定义舞弊 + 构造特征

舞弊定义：被监管机构处罚 = IsViolated = Y

只保留财务造假类：虚假记载/重大遗漏/会计处理不当

特征来自利润+资产负债表：负债率、流动比率、ROE…

产出 financial_merged.csv：公司×年度，特征+标签

定义舞弊 + 构造特征

本项目定义：被监管机构处罚 = 舞弊（IsViolated = Y）

P2503 虚假记载 / P2505 重大遗漏 / P2515 会计处理不当 —— 只保留财务造假类

从两张报表构造特征（公司 × 年度）：

资产负债率	流动比率	净资产收益率	营收增长率
总负债 / 总资产	流动资产 / 流动负债	净利润 / 平均净资产	同比增速（合并口径）

输出：financial_merged.csv —— 每行一家公司一年

8 个特征列 + 1 个标签列（is_fraud）

口径必须写进 PROJECT_RULES.md —— 回到上午的「统一口径」

给 Agent 的约束：时间泄漏红线

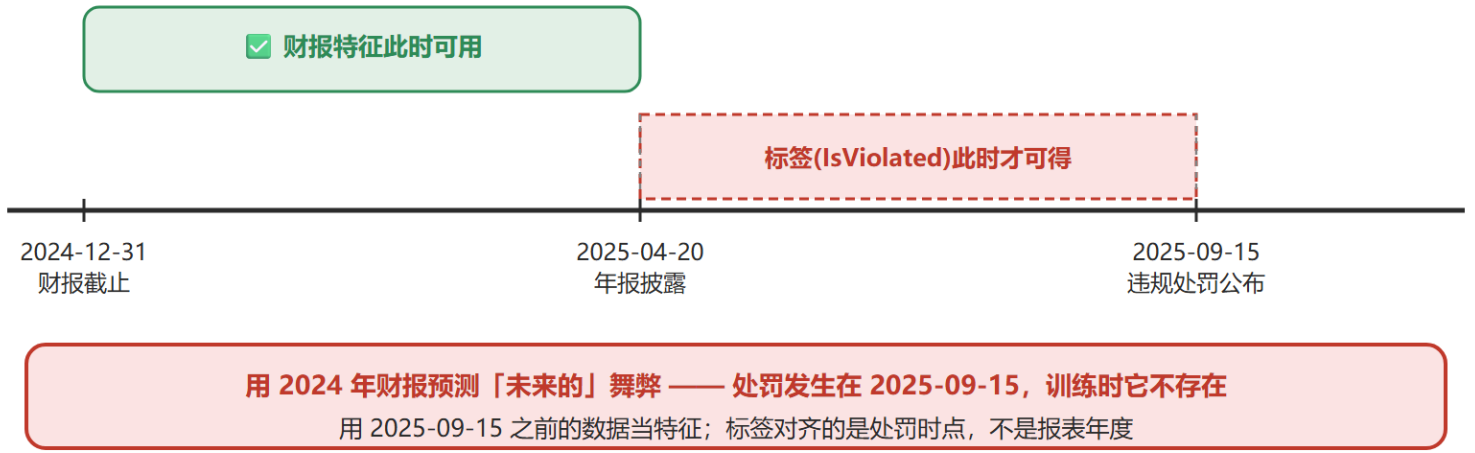
处罚发生在财报披露之后 —— 信息在时点上不存在

2024 年报 2025-04 披露，处罚 2025-09 才公布

特征只能用处罚日之前的数据，标签对齐处罚时点

两批数据混用 = 训练集偷看答案 = 数据泄漏

合并时的红线：标签必须晚于财报可得



用 2024 年财报预测「未来的」舞弊 —— 处罚发生在 2025-09-15，训练时它不存在

用 2025-09-15 之前的数据当特征；标签对齐的是处罚时点，不是报表年度

让 Agent 把合并数据画出来

合并完成后，先可视化再谈建模

舞弊公司 vs 正常公司的负债率分布对比

逐年违规事件数条形图：看样本量够不够

这一步发现的问题，直接写回 PROJECT_RULES

★ 前提一：训练和打分，用的是两批数据

- **训练用的是过去已知结果的公司**
- 打分用的是今天还不知道结果的靶子公司
- 两批数据混在一起 = 数据泄漏，成绩虚高

前提一：训练和打分，是两批数据

训练模型用：过去的数据

过去已知结果的公司

例：2018 年已经 ST 的样本

标签 = 真实发生过的事实

不能混！

打分对象：未来的数据

今天还不知道结果的公司

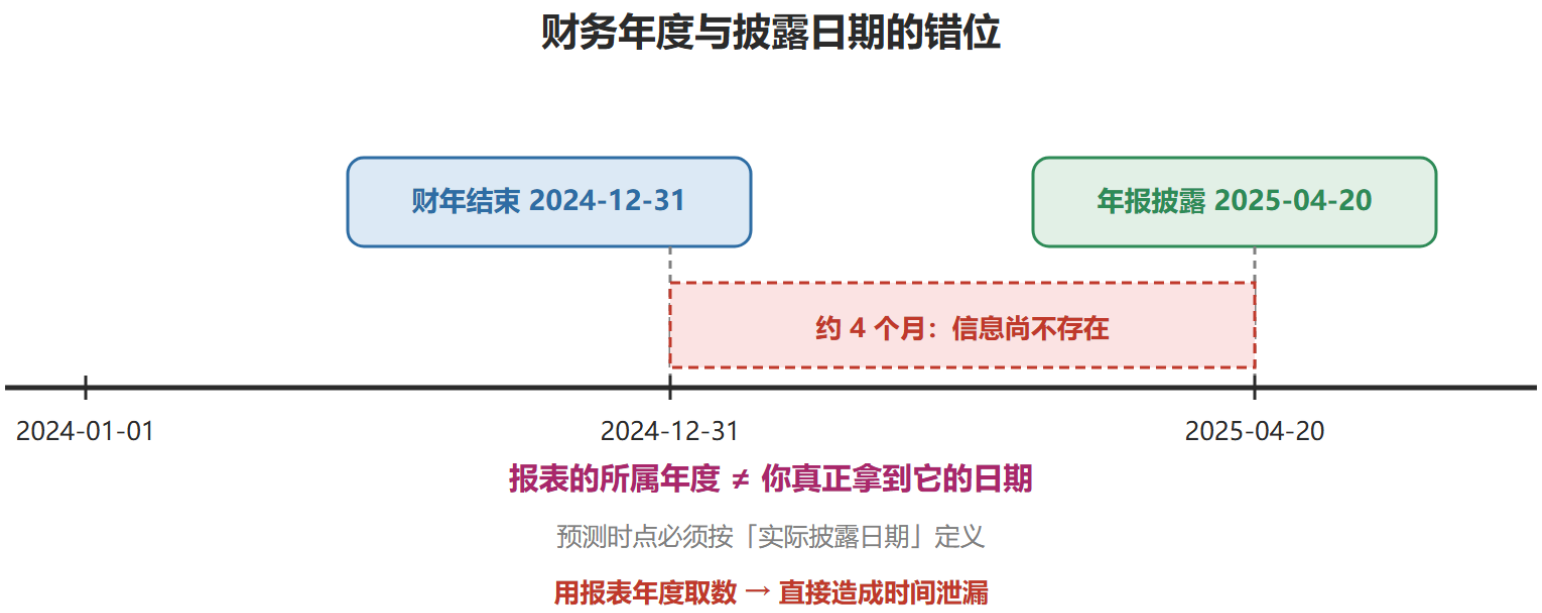
例：2026 年在市的上市公司

答案 = 我们要预测的目标

混了会怎样？模型偷看答案 → 虚高成绩（Day2 下午讲「数据泄漏」）

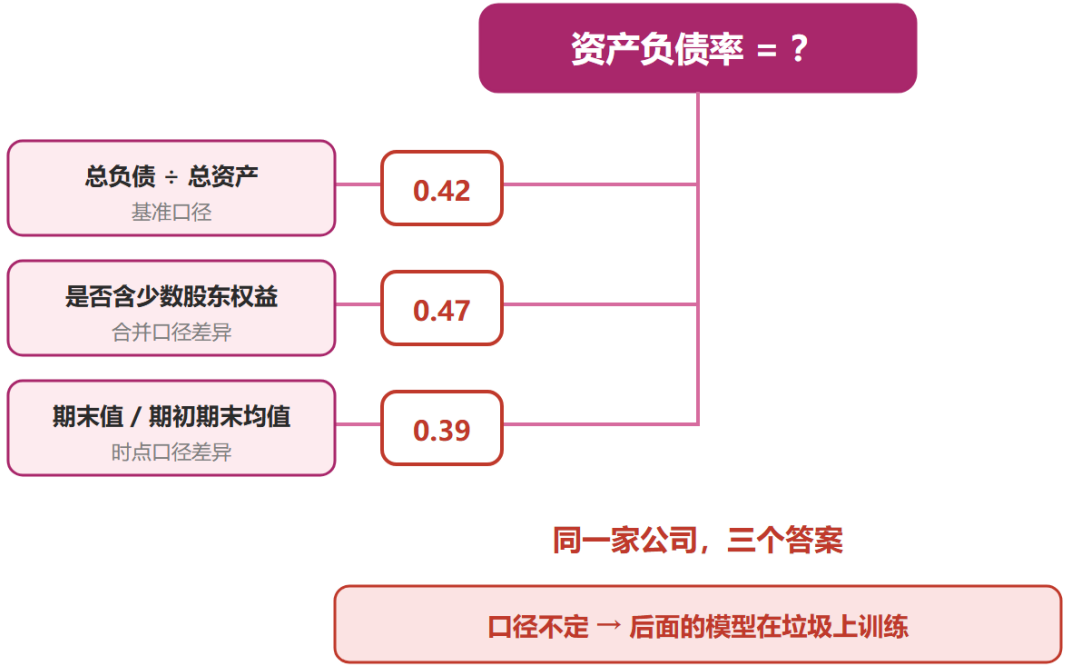
★ 前提二：财务年度 ≠ 信息可得时间

- **2024 年的年报，可能 2025 年 4 月才披露**
- 预测时点按实际披露日期定义，不是报表年度
- 按报表年度取数 → 直接造成时间泄漏



统一口径之一：字段怎么算

- **同一指标，三种算法算出三个不同的数**
- 口径不定，后面的模型就是在垃圾上训练
- 本项目的口径见下页清单，白纸黑字写死



字段口径清单（本项目）

指标	本项目采用口径
资产负债率	总负债 / 总资产，期末值，合并报表
流动比率	流动资产 / 流动负债，期末值
净资产收益率	净利润 / 平均净资产（期初期末均值）
营业收入增长率	同比，按合并口径
审计意见	标准无保留记为 0，其余按类型编码

统一口径之二：每条记录必须带什么

- **八个字段是底线：代码、期间、指标、数值…**
- 来源 + 获取时间是命根子
- 没有出处与时间，三个月后你自己都不敢用

一条标准记录必须带什么

公司代码	600519
会计期间	2024-12-31
指标名	资产负债率
数值	0.42
单位	比率
币种	CNY
来源	**巨潮年报 PDF 第 X 页**
获取时间	**2026-10-17**

没有这两行，
三个月后你自己都不敢用

三个月后能回溯，
才叫证据

统一口径之三：出问题时怎么办

- **缺失怎么办：先标注，按规则填充或直接丢弃，不许静默处理**
- 单位不统一怎么办：统一折算，并记录折算倍数
- 出现异常值怎么办：检测出来先标注，是错误才删，是真实就保留并注明
- 哪些事不许它自作主张：删行、改字段定义、跨源合并

产出：一份能用的项目规则文件

- **上午的成果物：PROJECT_RULES.md**
- 里面写清：字段口径、输出标准、异常处理约定
- 下午采数据时，Agent 直接读这份文件干活
- 换工具也没关系，规则不变、入口文件换一套即可

03

数据底层原理

编码 • 精度 • 类型 • 质量

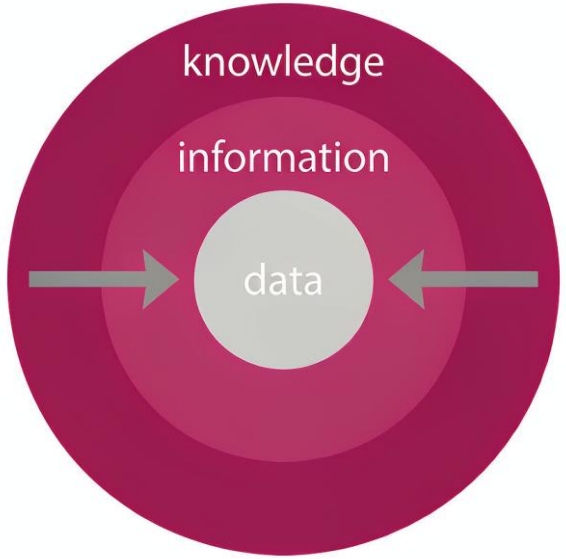
为什么还要讲数据是怎么存的

- **因为下午采回来的数据，各种奇怪问题都源于此**
- 乱码、精度丢失、数字变文本，全是编码惹的祸
- 数据 ≠ 信息 ≠ 知识，最底下那一层是字节
- 同一个字节，换一种解释，就是完全不同的东西

数据 ≠ 信息 ≠ 知识

概念	示例	区别
数据	温度计读数 38.5	原始事实
信息	体温偏高，可能发烧	数据被赋予含义
知识	38.5 + 持续高烧 = 去医院	可指导行动

- 计算机里的一切都是数据，但数据要被**编码成字节**，才能存储、计算。
- 本讲先回答：这些字节到底是怎么来的？

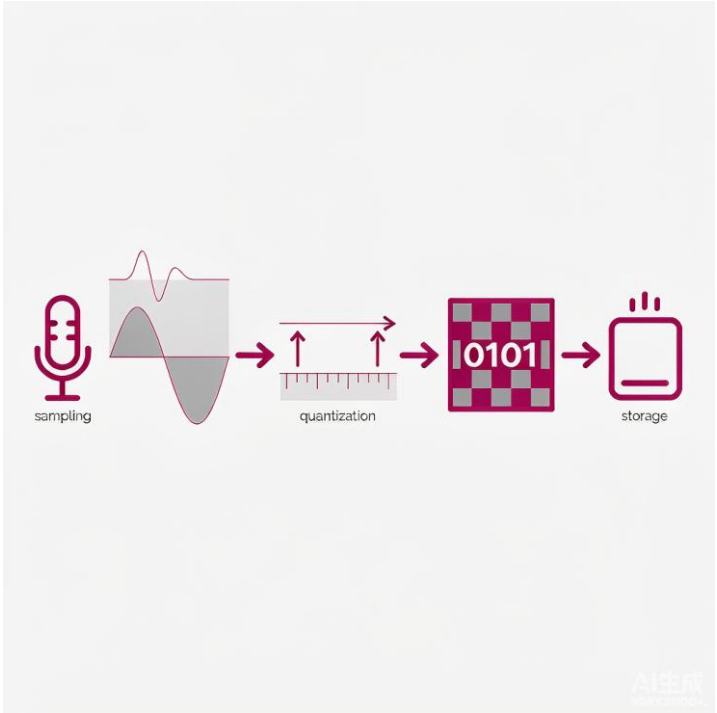


知识 ← 信息 ← 数据（示意）

从物理世界到比特：一条总路线

- **采样：** 连续信号 → 离散点（温度计每秒一次）
- **量化：** 连续值 → 离散值（38.5 → 39）
- **编码：** 数字 → 比特序列（39 → 00100111）
- **存储：** 比特序列写进硬盘 / 内存

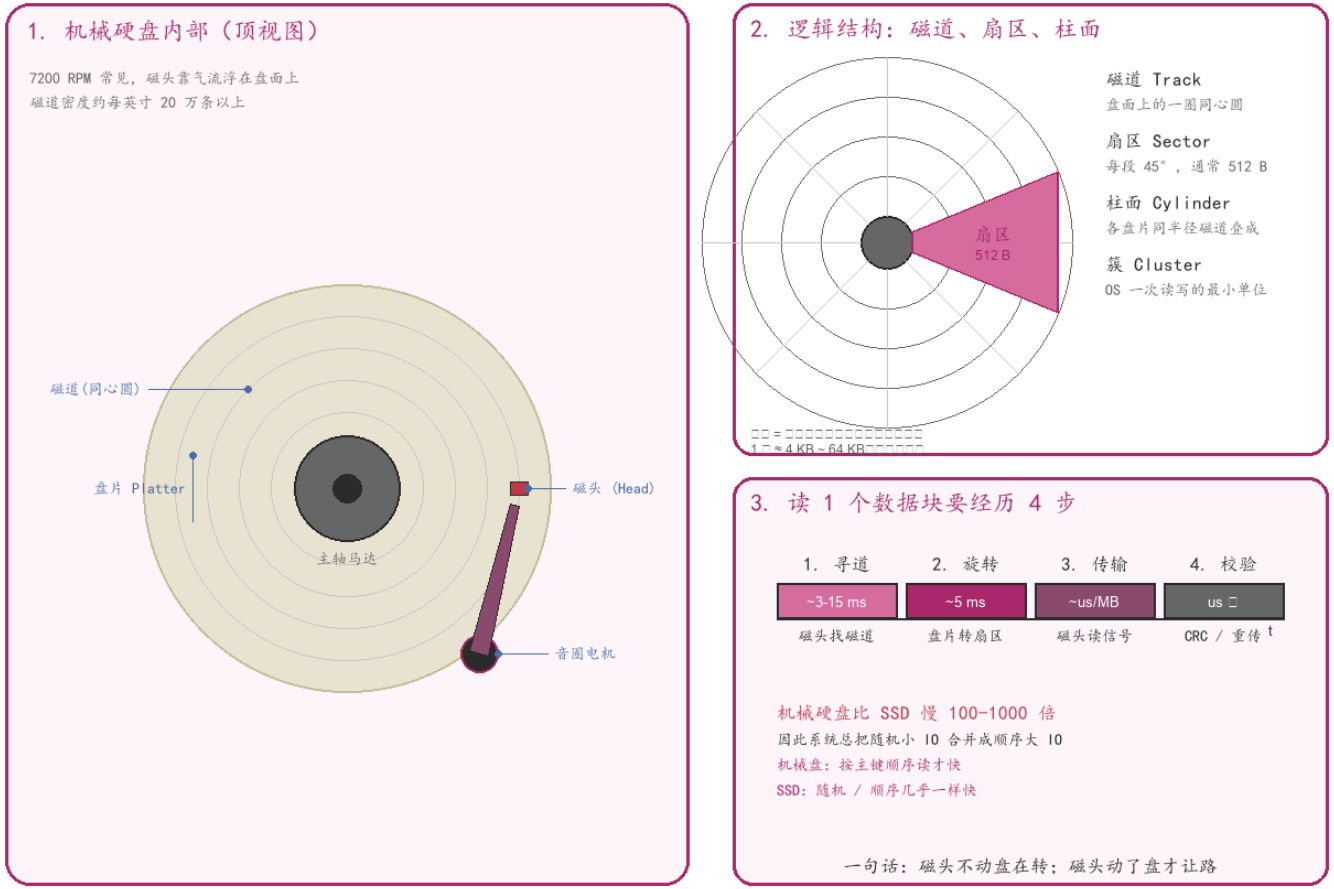
关键在"编码"那一格——同一串比特，换一种编码解释，**就变成完全不同的东西。**



采样 → 量化 → 编码 → 存储（示意）

硬盘：比特最终落脚的地方

- 机械硬盘 = 铝合金盘片 + 磁头 + 音圈电机 + 主马达
- 数据写在磁道上，磁道切分成扇区，每扇区通常 5 B
- **读数据 3 步：**
- 寻道：磁头径向移动到目标磁道（3–15 ms）
- 旋转：盘片旋转到目标扇区（平均 ~5 ms）
- 传输：磁头把磁场信号转成电信号读入缓存
- 机械盘慢在“寻道 + 旋转”；SSD 靠电信号直接读写



机械硬盘结构、磁道/扇区、读时序（示意）

整数：要么装得下，要么溢出

类型	位数	取值范围
int8	8	−128 ~ 127
int16	16	−32 768 ~ 32 767
int32	32	$\pm 2.1 \times 10^{9}$
int64	64	$\pm 9.2 \times 10^{18}$

- 最高位是符号位，其余位表示绝对值（补码）
- **溢出案例：**
- 千年虫：年份两位 → 2000 变 00
- 1996 阿丽亚娜 5 号火箭爆炸（int64→int16 溢出）
- 游戏金币超出 int32 上限变负数



8 位二进制 + 溢出位（示意）

浮点数：0.1 + 0.2 ≠ 0.3

类型	位数	精度（十进制）
float32	32	约 7 位有效数字
float64	64	约 15 位有效数字

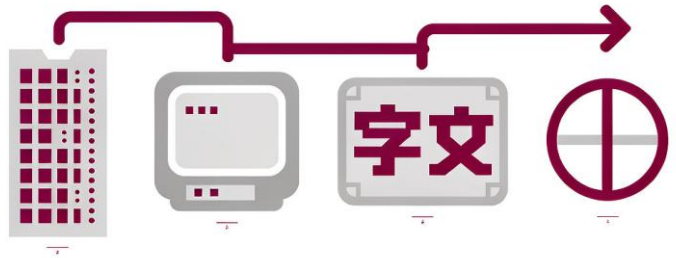
- IEEE 754：符号位(1) + 指数位(8/11) + 尾数位(23/52)
- 0.1 + 0.2 == 0.30000000000000004
- 财务系统永远不要用 float，要用定点数 / decimal
- 1991 爱国者导弹拦截失败（累积误差 0.34 秒）
- 试试看-27.625：二进制 `11011.101` → 规格化 `1.1011101×2⁴` → 指数 4+127=131 → 拼成 `1 10000011 10111010000000000000000`，即 `0xC1DD0000`



IEEE 754 二进制布局（示意）

文本：让每个字对应一个数字

- 计算机只懂数字，文本必须被**编码成数字**
- **两个核心问题：**
- **字符集**——多大的字库
- **编码方案**——每个字占多少字节
- 演进：ASCII → 各国扩展(GBK/Big5) → Unicode → UTF-8



字符集演进时间轴（示意）

ASCII：每个字母对应一个二进制

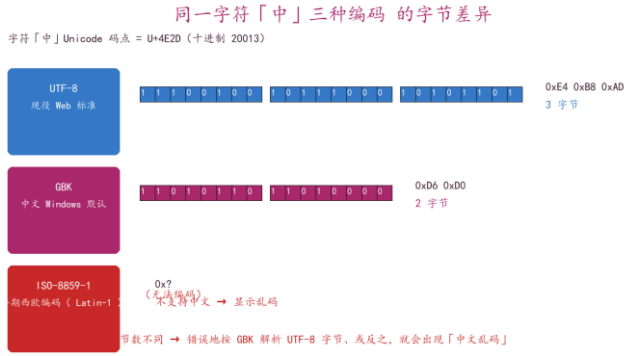
- ASCII = 0~127 共 128 个码点
- **规律：**'0'=48, 'A'=65, 'a'=97（大小写相差 32）
- 实际存储 1 字节（最高位恒为 0）
- **例：**'K' = 75 = 01001011



ASCII 码表（示意）

GBK：让中文也能存，但埋了雷

- GB2312(1980)：6763 简体汉字 + ASCII
- GBK(1995)：扩展到 21003 汉字，兼容 GB2312
- **核心困境：**
- GBK 无 BOM 标记，软件猜不到编码
- GBK 与 UTF-8 互转易失败（同一字节两套解释）
- **经典乱码：**"你好" → "浣犲ソ"
- **现在几乎所有新项目都强制 UTF-8**



三种编码下的乱码对比（示意）

UTF-8：变长编码，现役王者

Unicode 范围	UTF-8 字节数
U+0000 ~ U+007F	1 字节（兼容 ASCII）
U+0080 ~ U+07FF	2 字节
U+0800 ~ U+FFFF	3 字节
U+10000 ~ U+10FFFF	4 字节

- ASCII 文本仍 1 字节，老文件零成本兼容
- '中' = U+4E2D = 3 字节 UTF-8
- emoji 占 4 字节（GBK 不支持 → ?）
- **事实上的 Web 标准（>98% 网页）**



'中' 拆 3 字节、emoji 拆 4 字节（示意）

实战：把一行 CSV 拆开看看

```
id,name,score,join_date
001,张三,85.5,2024-09-01
```

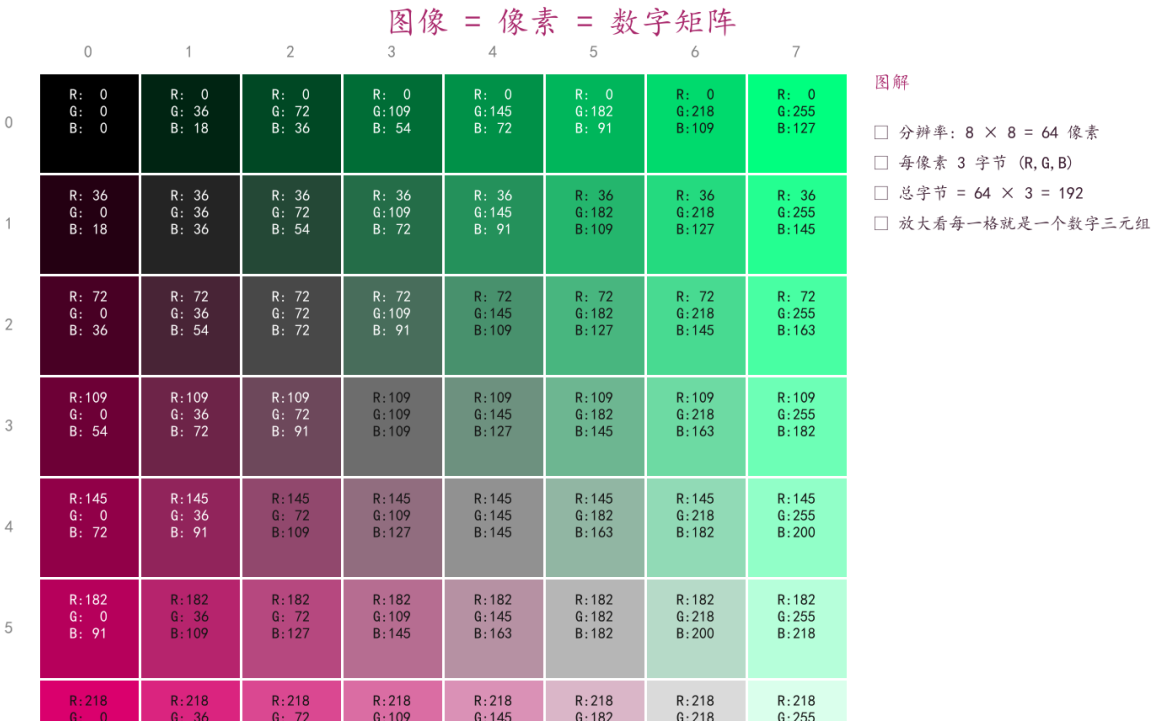
- '张三' 字段：每字 3 字节 UTF-8 = 6 字节（GBK 仅 4 字节）
- '85.5'：5 字节 ASCII（数字和 . 都是 ASCII）
- '2024-09-01'：10 字节 ASCII（年份是数字串，非时间戳）
- **文件大小 = 各字段字节数 + 逗号 + 换行**



一行 CSV 的字节级拆解（示意）

图像：每个像素就是一个数字

- 灰度图：每像素 0~255 一个数字
- 彩色图：每像素 RGB 三通道，共 3 个数字
- 1080p = 1920 × 1080 ≈ 207 万像素
- **单张 1080p RGB（无压缩）≈ 6 MB**
- **5 分钟 4K 视频（30fps）≈ 220 GB**

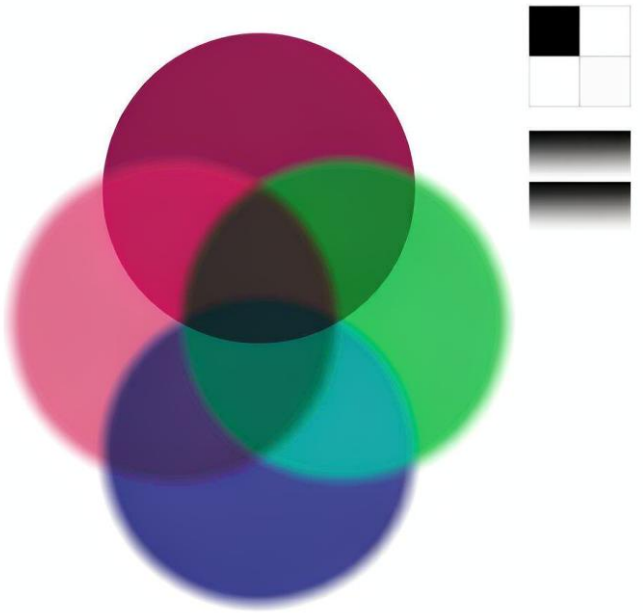


像素 = 数字矩阵（示意）

颜色：RGB / 灰度 / 二值

模式	单像素字节	适用场景
二值图	1 bit	文字扫描、文档
灰度图	1 字节	黑白照片、医学影像
RGB	3 字节	彩色照片
RGBA	4 字节	含透明通道（PNG、UI）

- 0xFF0000 = 红，0x00FF00 = 绿，0x0000FF = 蓝
- 16 进制色码 = # + 6 位 = RGB 三通道

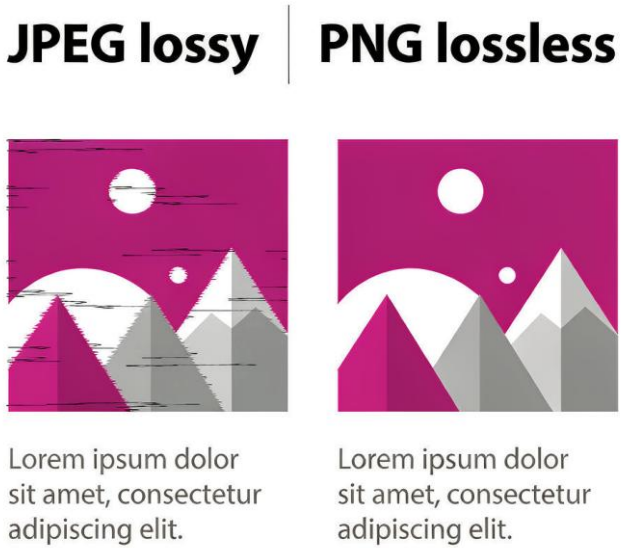


RGB 三原色叠加（示意）

压缩：丢掉一点细节，换来小很多

格式	类型	适合	不适合
JPEG	有损	照片	文字 / Logo / 截图
PNG	无损	Logo / 截图 / 透明	大照片
WebP	两者皆可	现代 web	老旧软件

- JPEG 三步：分块(8×8) → DCT 变换 → 量化丢高频
- **6 MB 原图 → JPEG q=85 ≈ 800 KB**
- "看上去一样"的两张图，大小可能差 10 倍

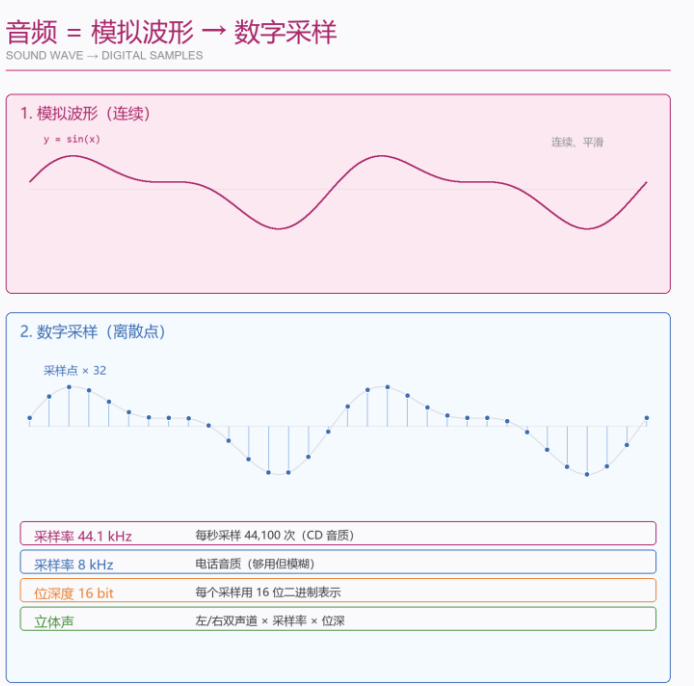


JPEG 有损 vs PNG 无损（示意）

音频：把声音切成无数个数字

参数	含义	典型值
采样率	每秒采多少点	44.1 kHz（CD）/ 48 kHz
位深度	每点量化精度	16 bit / 24 bit
声道数	单声道 / 立体声	1 / 2

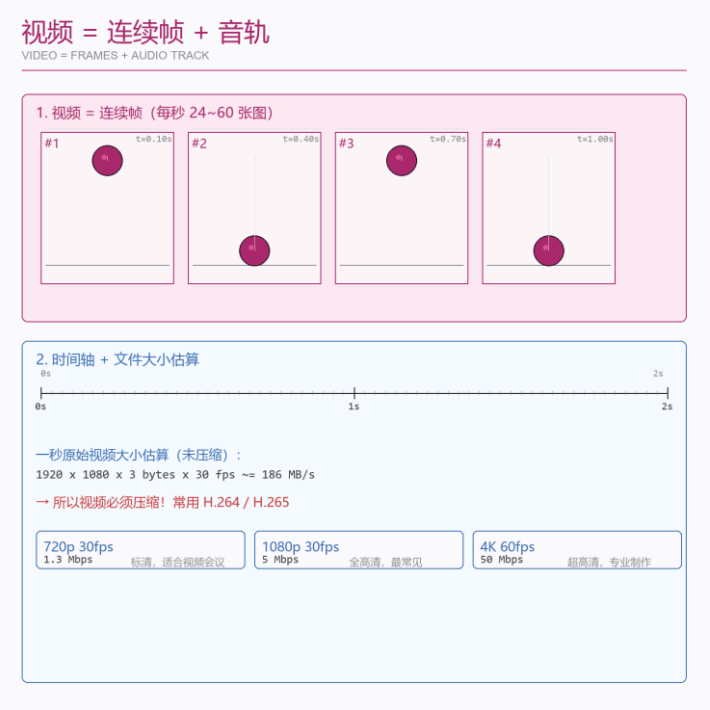
- **1 分钟 CD 音质 ≈ 10 MB**
- MP3 压缩比约 1:10 → 1 MB
- 比特率：128 kbps 够用 / 320 kbps 透明



声波采样与数字化（示意）

视频：每秒 30/60 张图 + 音轨

- 30 fps × 5 分钟 = 9000 帧 ≈ 54 GB（原始）
- 压缩技巧：
- 空间压缩：帧内 JPEG
- 时间压缩：帧间预测（只存变化区域）— H.264
- 5 分钟 1080p MP4 ≈ 100~200 MB

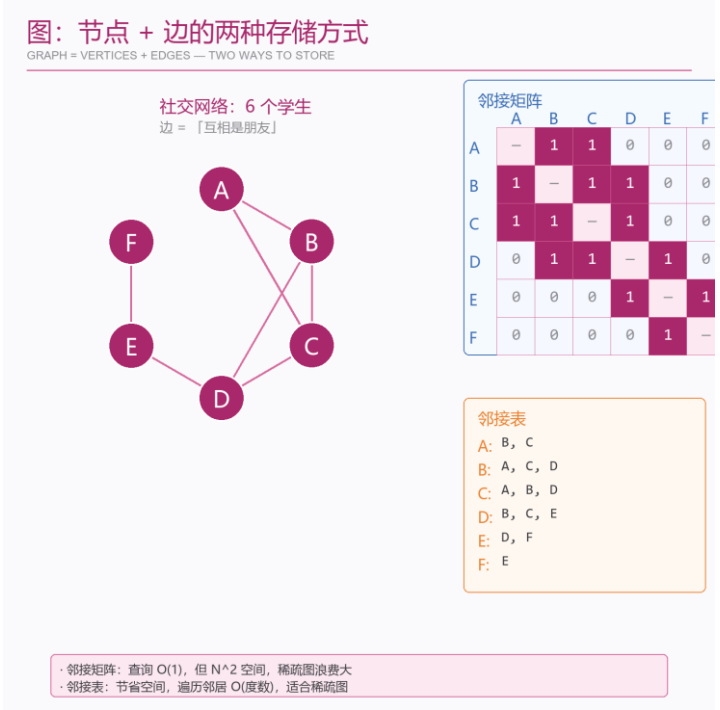


帧序列 + 帧间压缩（示意）

图：节点和边的两种存储方式

存储方式	空间复杂度	适合
邻接矩阵	$O(V^2)$	稠密图（边多）
邻接表	O(V+E)	稀疏图（边少）

- 微信 12 亿用户，邻接矩阵 = 1.44×10^{19} 格
- 完全不可能，必须用邻接表
- "微信怎么算你可能认识的人？"——图算法
- 数据规模决定存储结构



邻接矩阵 vs 邻接表（示意）

回顾：从物理世界到比特

数据类型	存储关键点	典型编码
数字	整数位宽、浮点精度	int8/64、float32/64
文本	字符集 + 变长编码	ASCII、UTF-8
图像	像素矩阵 + 颜色通道	RGB、JPEG、PNG
音频	采样率 + 位深度	PCM、MP3
视频	帧序列 + 帧间压缩	H.264、MP4
图	节点 + 边	邻接矩阵、邻接表
时序	时间戳 + 数值	CSV、Parquet

一句话总结：任何数据在计算机里都是字节，怎么解释看编码。

两类最常见的"特殊数据"

图数据（推荐 / 反欺诈 / 知识图谱）

from,to,weight	边表：谁和谁有关
A,B,0.8	转账关系
B,C,0.5	担保关系

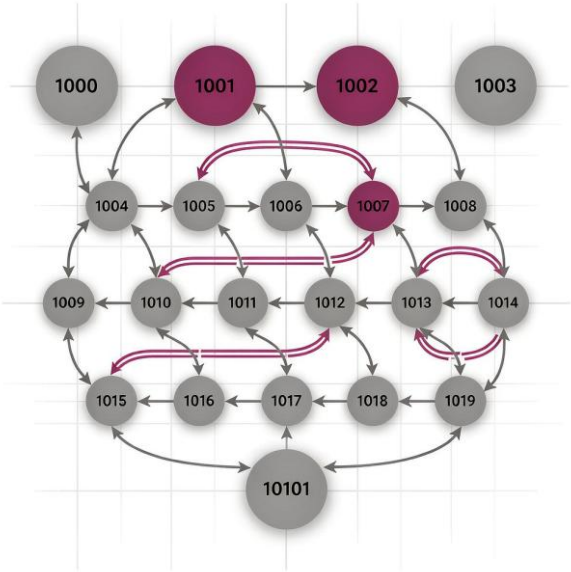
- 学术合作图 ➡ 引文网络分析

time,close,volume	K线/面板
2024-01-02,10.5,1200	日收盘
2024-01-03,10.8,980	日收盘

- 股票 K 线 / 心电图 / 服务器访问量

两张表都是 CSV：图 = 边表（谁连谁），时序 = 时间戳+数值

行内逗号分隔，一行一条记录 —— 这就是它们在磁盘上的样子



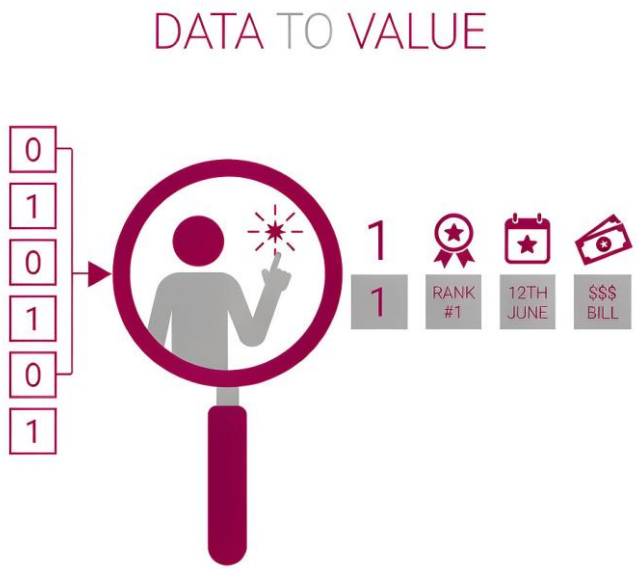
转账图（示意）



股票 K 线

上节我们看了"机器怎么存"

- 上节末尾：'85.5' 在硬盘上是 5 个 ASCII 字节
- 解析后是数值，可以运算（85.5 + 10 = 95.5）
- **但解析前，先要决定"这是什么类型"**
- **同样是 1 和 2：**
- 数字 1 + 2 = 3（可加减）
- **排名1 + 2 = 3（无意义，序数）**



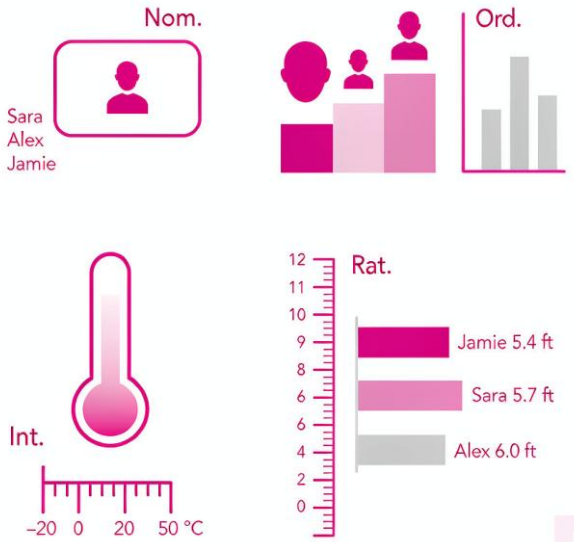
比特串 → 不同含义（示意）

四种数据类型：决定你能用哪些运算

类型	别名	关键能力	示例
标称 Nominal	定类	只能比"是不是"	性别、血型、城市
序数 Ordinal	定序	可以比大小	教育程度、满意度
区间 Interval	定距	可以加减	摄氏温度、年份
比率 Ratio	定比	还可以乘除	收入、年龄、身高

记忆口诀：

标=分类 | 序=排序 | 区=加减 | 比=乘除



四种尺度（示意）

类型决定方法：一张表讲清

数据类型	集中趋势	离散程度	分布形态	典型可视化
标称	众数	异众比率	频数表	条形图 / 饼图
序数	中位数 / 四分位数	四分位距 IQR	频数表	条形图
区间	均值 / 中位数	标准差 / 方差	直方图	直方图 / 折线图
比率	均值 / 中位数 / 几何均值	标准差 / 变异系数	直方图 / 密度图	直方图 / 箱线图

- **收入是比率 → 用均值合理；教育程度是序数 → 用均值荒谬**
- 异众比率 = 1 − 众数频率；变异系数 CV = 标准差 / 均值

这张表先记轮廓，公式在 Orange 实践时再上手。

编码：标称/序数录入计算机时要先编码 —— 男生→0 女生→1

对标称来说编码大小没有意义；模型只接受浮点数，字符串特征必须先编码

为什么？机器学习模型只认浮点数 —— 统一编码后模型才能读

一个真实的例子：某公司员工画像

字段	取值示例	数据类型	为什么这样判
employee_id	E001 ~ E005	纯标识符	不参与分析，仅识别
department	财务/市场/IT/HR/销售	标称	类别分类，无顺序
education	高中<本科<硕士<博士	序数	有高低但差距不等
salary	8000 ~ 50000 元	比率	有真零，可加减乘除
satisfaction	1 ~ 5 星	序数	无真零，1 星≠零满意

- 接下来 5 分钟，我们用这个表演示每种类型如何统计。

为什么求「教育程度」的均值是荒谬的

- **教育程度是序数：小学 < 中学 < 大学，有顺序但间隔不相等**
- 求均值预设了「间隔相等」这个不成立的前提
- 正确做法：用众数、中位数、频数分布
- 同理：信用评级 AA、A、BBB 也不能直接求平均

针对员工数据：5 种统计方法

department • 标称

- 频数各 1；无众数 → 异众比率 = 1 − 1/5 = 0.8；条形图

education • 序数

- 排序：高中<本科<本科<硕士<博士；中位数=本科；IQR=1 档

✗ 不能求"均值 2.0"

salary • 比率

- 均值=26000；标准差≈16431；CV≈63%；直方图/箱线图

satisfaction • 序数

- 数据 2,3,3,4,5；中位数=3 星；条形图

✗ 不能求"均值 3.4 星"

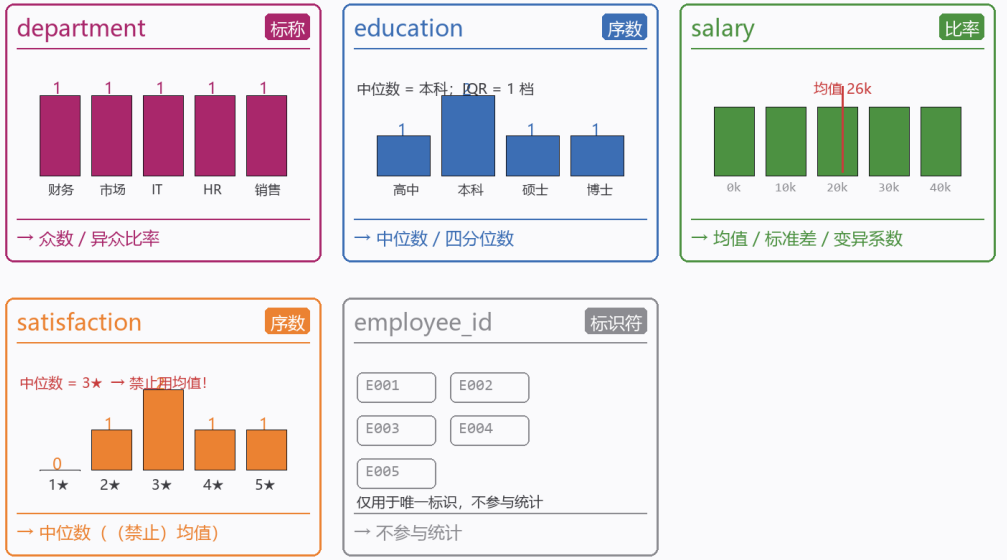
employee_id • 标识符

- 不参与分析，仅识别

5 种统计方法（示意）

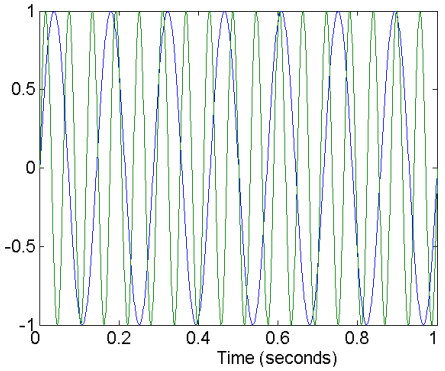
员工画像：5 字段对应 5 种统计方法

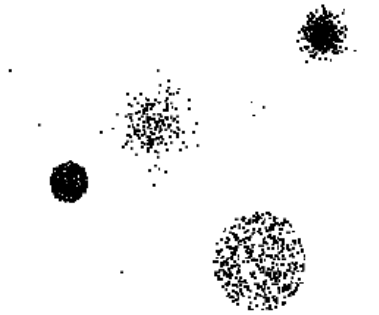
5 FIELDS → 5 STATISTICAL METHODS



数据质量：现实世界的 6 类脏数据

类别	现象	例子
缺失值	字段为空	用户没填年龄
异常值	偏离正常范围	工资 = -100，年龄 = 200
重复值	同一记录多次出现	订单 ID 重复
不一致	同一字段格式混乱	"男"/"M"/"male" 混用
噪声	小幅随机波动	传感器读数抖动
偏差	取样不均	问卷只发给年轻人





怎么修补、剔除 → 下节课讲

缺失值

员工表里年龄空着

id, age, dept	表头
1, , IT	年龄缺失
2, 29, HR	正常
3, 31, ,	部门缺失

缺失 = 字段为空 —— 员工 1 的年龄是空的

处理：先标注，不静默删（财务里缺失可能是信号）

行 3 缺部门：填「其他」或按规则丢弃

异常值

工资 -100 元

id, salary	表头
1, 8000	正常
2, -100	负数！不可能
3, 9000	正常
4, 999999	大得离谱

异常值 = 偏离合理范围 —— 工资不可能为负

检测：3σ / IQR / 业务规则

先判断是错误还是真相：-100 是录入错，999999 可能是真实高薪

重复值

同一订单出现两次

order_id,amount	表头
1001,500	第一次
1001,500	重复！
1002,800	正常

重复值 = 同一记录出现多次 —— order_id 1001 出现了两次

检测：主键唯一性检查

不查会怎样？金额汇总翻倍

不一致

性别三种写法

id,gender	表头
1,男	中文
2,M	英文
3,male	全称
4,男	中文

不一致 = 同一字段格式混乱 —— 男 / M / male 是同一个意思

后果：groupby 会拆成三组，统计全错

处理：统一映射表，归一成一种写法

噪声

传感器读数抖动

time,value	表头
09:00:01,25.3	正常
09:00:02,25.4	正常
09:00:03,78.1	噪声毛刺
09:00:04,25.2	正常

噪声 = 小幅随机波动 —— 78.1 是传感器毛刺

特征：和邻居差异巨大，但非系统性

处理：滑动平均 / 3σ 剔除

偏差

问卷只发给年轻人

age, score	表头
18, 4. 5	只采访了年轻人
22, 4. 2	样本偏斜
25, 4. 8	中老年没被采样
20, 4. 6	统计结论失真

偏差 = 取样不均 —— 问卷只发给年轻人

样本 ≠ 总体：结论无法推广到全人群

处理：分层抽样，保证各层占比

读表第一坑：说明行混入表头

现象：Excel 前几行是中文说明行，不是数据

证券代码	证券简称	统计截止日期
证券代码	证券简称	统计截止日期
没有单位	没有单位	没有单位
000001	深发展A	1990-12-31

↑ 前 2 行是指南，第 3 行才是真数据

后果：

- 整列 dtype 退化成文本，sum / mean / 排序全部失效
- 且不报错——悄悄算错

对策：

- 读入后跳过说明行（skiprows）
- 或按“6 位证券代码”格式过滤真数据

AI 协作要点：

DATA.md 里 AI 应主动标出“表头有 N 行需剔除”——学生要能看出这条写没写对

练一练：财报里这些字段分别是什么类型

- **先自己判，再揭晓**
- 行业代码长得像数字，其实是标称
- 「是否 ST」是二分类，不是数字

财报字段	取值示例	数据类型	为什么
证券代码 000001	6 位数字	标称	数字但无大小
行业代码 C39	字母+数字	标称	分类不排序
是否 ST	1 / 0	标称(二分类)	非连续
资产负债率	0.42	比率	有真零可乘除
审计意见	标准/保留	序数	有优劣顺序
净利润增长率	-0.12	比率	可正可负
员工人数	3500	比率	可加乘

字段类型的两处暗礁：前导零与常量列

暗礁① 前导零：000001 变成 1

现象：

- 证券代码 000001 读进 Excel/Python 变成 1，前导零丢失

后果：

- 与行业表 / 违规表 join 时对不上，公司错配
- 000001 和 1 被视为两个不同的公司

对策：

- 代码类字段一律按文本读，再补零 zfill(6)
- 教训：长得像数字≠是数字（呼应前页类型判断）

暗礁② 常量列：一列全是一个值

现象：

- 某列 6,819 行全为 0（如“近两年净利为负”标志全为 0）

后果：

- 对预测毫无区分力，白占一列、拖慢模型

对策：

- 全表唯一值 ≤1 的列：识别后删除并留痕
- 疑似常量列先看计数，别盲删

AI 协作要点：

两个陷阱 AI 都应在 DATA.md / 质量报告中主动上报——这是学生审稿的考点

Orange：拖拽式数据探索

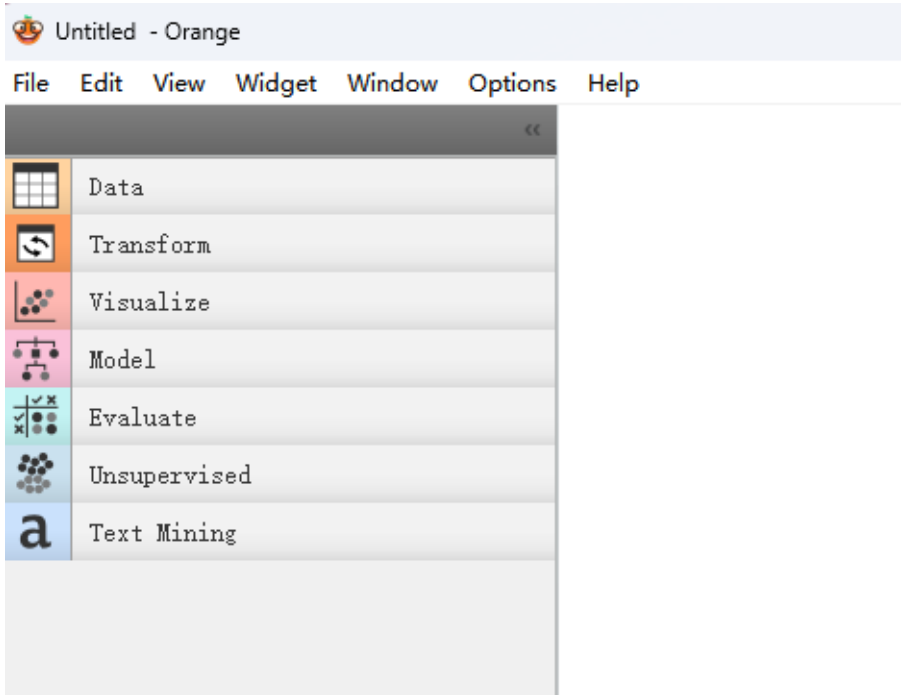
- 开源可视化数据挖掘工具（零代码）

界面三区：

- 左：widget 栏（File / Visualize / Model）
- 中：画布（拖拽区）
- 双击 widget 打开设置面板

基础流：

- File → Data Table → 看到原始数据



Orange 界面

任务一：识别每个字段的类型

iris.csv:

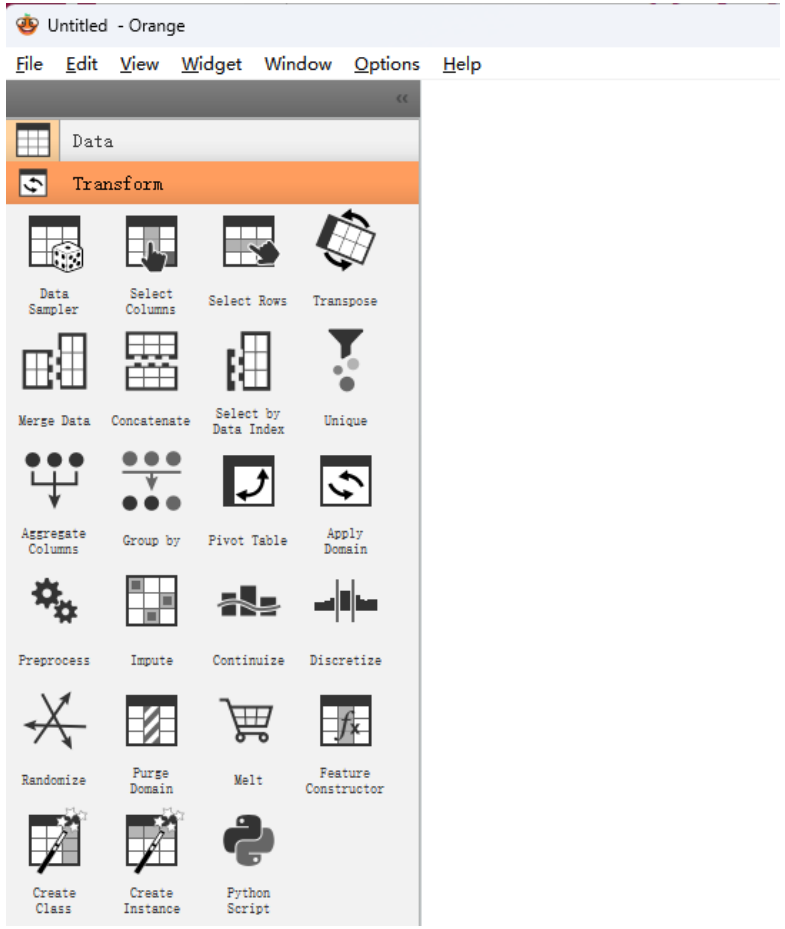
- sepal/petal 长度宽度 → 连续型
- species → 类别型

titanic.csv:

- Age（连续，有缺失）、Fare（连续，有异常）
- Sex / Embarked / Pclass → 类别型
- Name → 文本型（不分析）

用 Select Columns:

- Name 移到 Meta；Age/Fare 设为 Features



Select Columns

任务二：分布描述统计

字段	均值	中位数	标准差	最小	最大
sepal_length	5.84	5.80	0.83	4.3	7.9
petal_length	3.76	4.35	1.76	1.0	6.9
petal_width	1.20	1.30	0.76	0.1	2.5



titanic 类别列频数：

- Sex：male=577，female=314（异众比率≈0.35）
- Embarked：S=644，C=168，Q=77
- Pclass：3=491，1=216，2=184



Statistics / Distributions

任务三：把数据"画"出来

3.1 直方图 / 箱线图

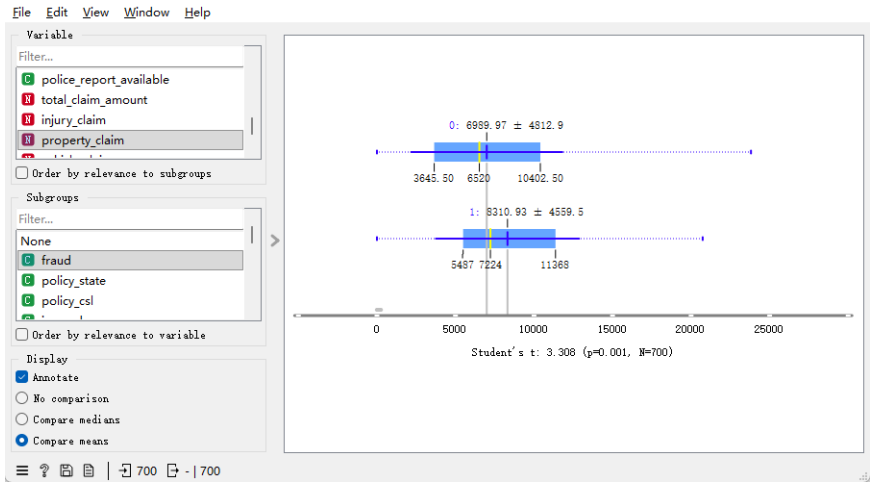
- Box Plot 看 iris 四个连续列

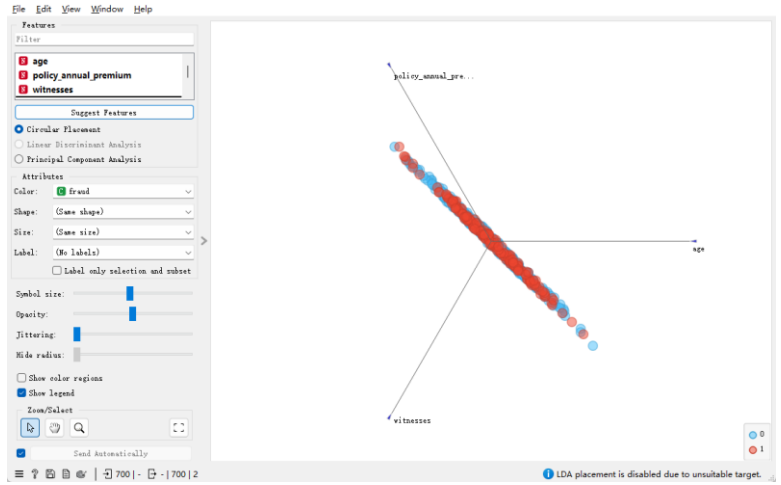
3.2 分布图

- Distributions 看 Sex / Pclass / Embarked

3.3 散点图

- X=petal_length, Y=petal_width, Color=species
- **setosa 独立成簇 ➜ 这就是"模式"**





Box Plot / Scatter Plot

任务四：在数据里"找茬"

问题 1 · 缺失值

- Age 列 count=714 < 891，缺失 177 条

问题 2 · 异常值

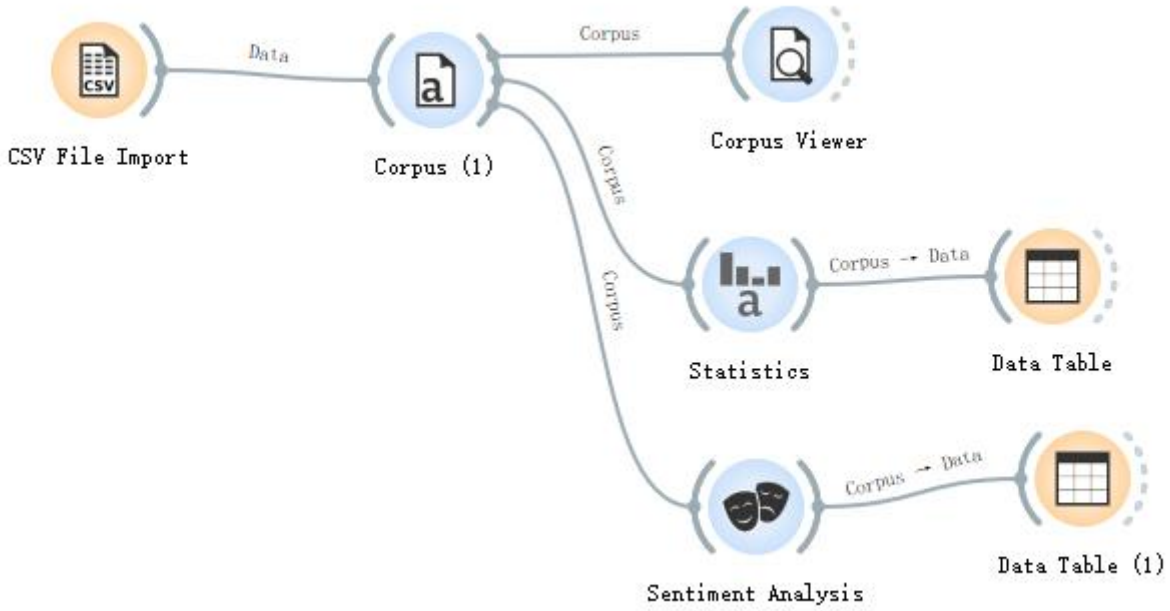
- Box Plot 看 Fare，找票价 > 500 的异常旅客

问题 3 · 不一致

- 检查 Sex 是否混入"Male"/"male"等写法

结论对应24"6 类脏数据"对照表，理论与实践闭环。

文本数据导入


Data
Corpus
Corpus
Corpus
Corpus → Data
Corpus → Data
CSV File Import
Corpus (1)
Corpus Viewer
Statistics
Data Table
Sentiment Analysis
Data Table (1)

04

小结与下午预告

三件事串起来

小结：上午三件事串起来

- **Agent 是执行者，但执行的前提是你先把话说清楚**
- 五问 + 两前提 + 三口径，就是「把话说清楚」的具体内容
- 而要说清楚，你得先懂数据的脾气——编码、精度、类型
- 下午：带着这份规则，去把数据洗干净、看明白、取回来