TREE
CLUSTER

决策树与树模型

从一棵树到一片森林，再到「聚类」看数据自己长成什么样

Day 2 下午 • 画得出 • 讲得清 • 用得上

深圳大学 • 经济学院
主讲：杨楷
kindyang.github.io

00

开场

Why Trees & Clusters

下午要回答的两个问题

- **问题一：这家公司会不会出事？—— 决策树与它的家族**
- 问题二：不看标签的话，这些公司自己会分成几类？—— 聚类
- 上午讲了有哪些模型、怎么评判，下午专攻你真的能看懂它在想什么的那种
- 每做完一步，我们都要把结论画出来

01

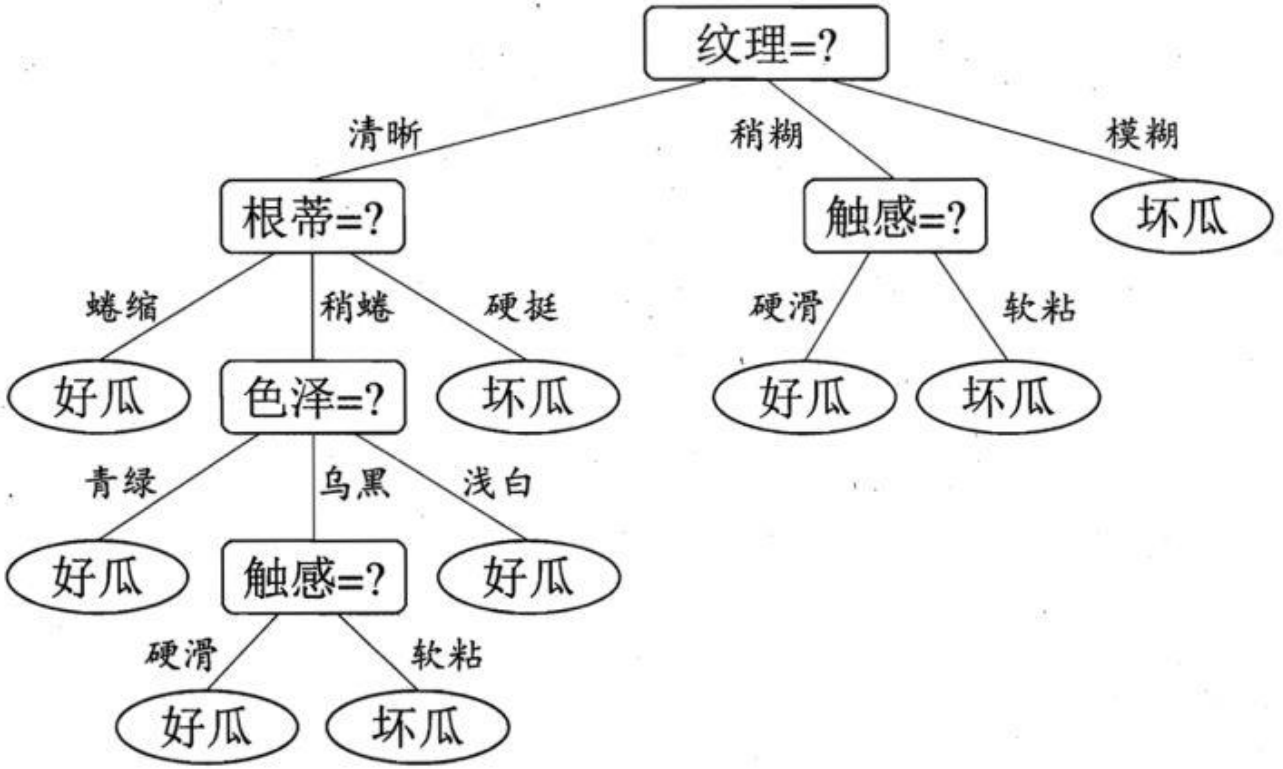
决策树原理

定义 • 建立 • 信息增益与 Gini • ID3

决策树（decision tree）——定义

- **决策树是以实例为基础的归纳学习算法：从一组无次序、无规则的元组中推理出决策树表示形式的分类规则**
- 类似于流程图的树结构：
- 每个内部节点 = 在一个属性上的测试
- 每个分支 = 一个测试输出
- 每个树叶节点 = 类或类分布
- 本讲按「基本介绍 → 如何建立 → 节点分裂方法」展开

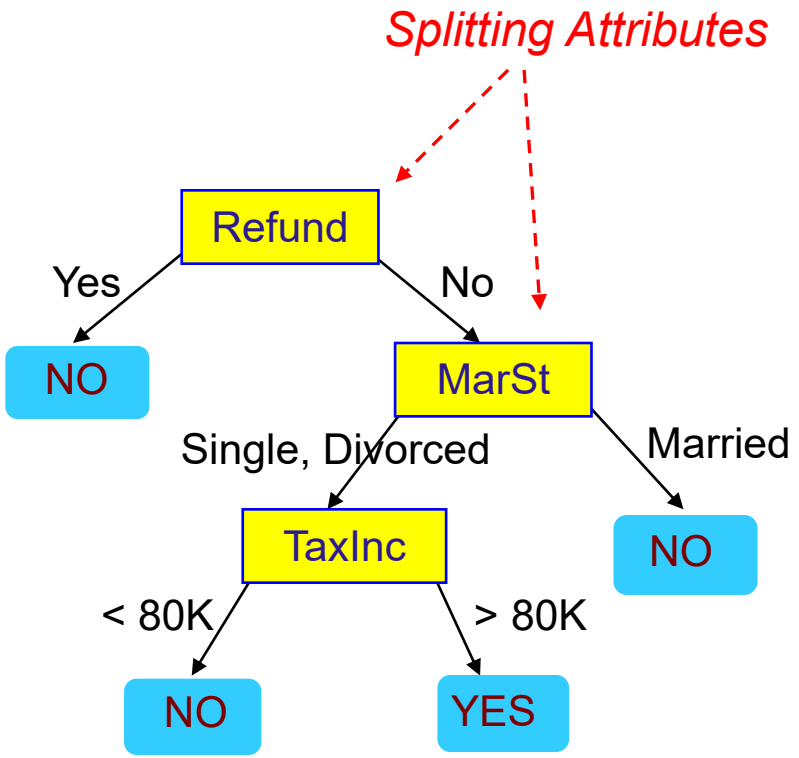
怎么买瓜？


纹理=?
清晰
稍糊
模糊
根蒂=?
触感=?
坏瓜
蜷缩
稍蜷
硬挺
硬滑
软粘
好瓜
色泽=?
坏瓜
好瓜
坏瓜
青绿
乌黑
浅白
好瓜
触感=?
好瓜
硬滑
软粘
好瓜
坏瓜

一个决策树的例子（Refund 例子）

Tid	Refund	Marital Status	Taxable Income	Cheat
		categorical	categorical	continuous	class
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

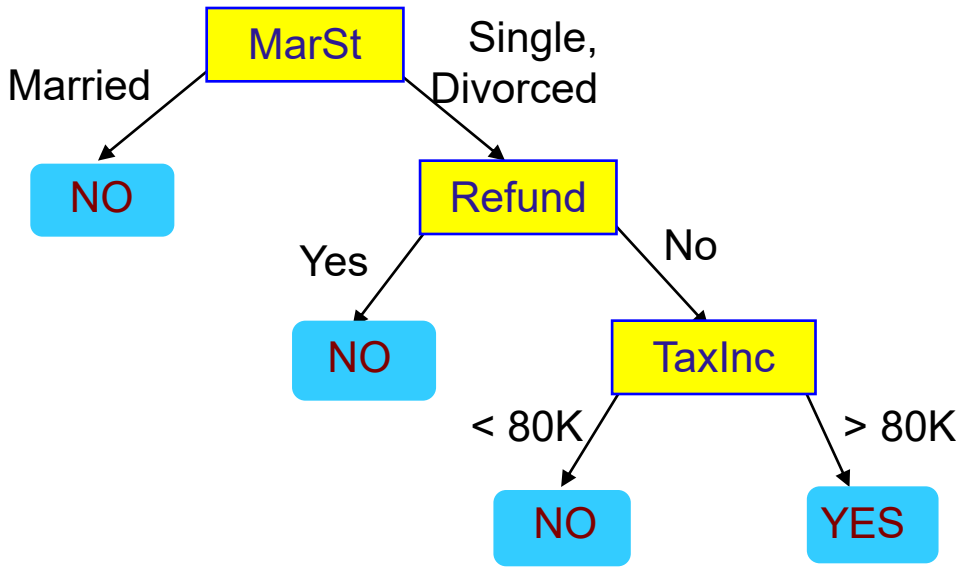
训练数据



模型：决策树

另一个决策树的例子

	categorical	categorical	continuous	class
Tid	**Refund**	**Marital Status**	**Taxable Income**	**Cheat**
1	Yes	Single	125K	**No**
2	No	Married	100K	**No**
3	No	Single	70K	**No**
4	Yes	Married	120K	**No**
5	No	Divorced	95K	**Yes**
6	No	Married	60K	**No**
7	Yes	Divorced	220K	**No**
8	No	Single	85K	**Yes**
9	No	Married	75K	**No**
10	No	Single	90K	**Yes**



决策树归纳分类

- 什么是决策树？
  - 类似于流程图的树结构
  - 每个内部节点表示在一个属性上的测试
  - 每个分枝代表一个测试输出
  - 每个树叶节点代表类或类分布
- 决策树的使用：对未知样本进行分类
  - 通过将样本的属性值与决策树相比较

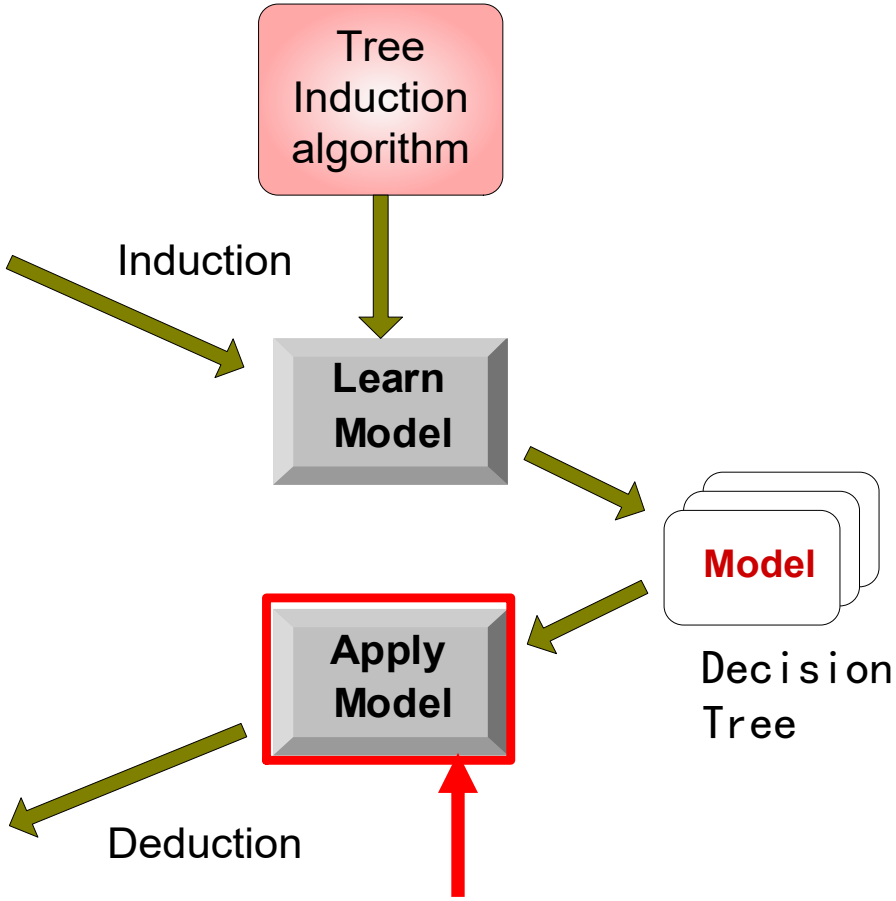
决策树分类任务

Tid	Attrib1	Attrib2	Attrib3	Class
1	Yes	Large	125K	No
2	No	Medium	100K	No
3	No	Small	70K	No
4	Yes	Medium	120K	No
5	No	Large	95K	Yes
6	No	Medium	60K	No
7	Yes	Large	220K	No
8	No	Small	85K	Yes
9	No	Medium	75K	No
10	No	Small	90K	Yes

Training Set

Tid	Attrib1	Attrib2	Attrib3	Class
11	No	Small	55K	?
12	Yes	Medium	80K	?
13	Yes	Large	110K	?
14	No	Small	95K	?
15	No	Large	67K	?

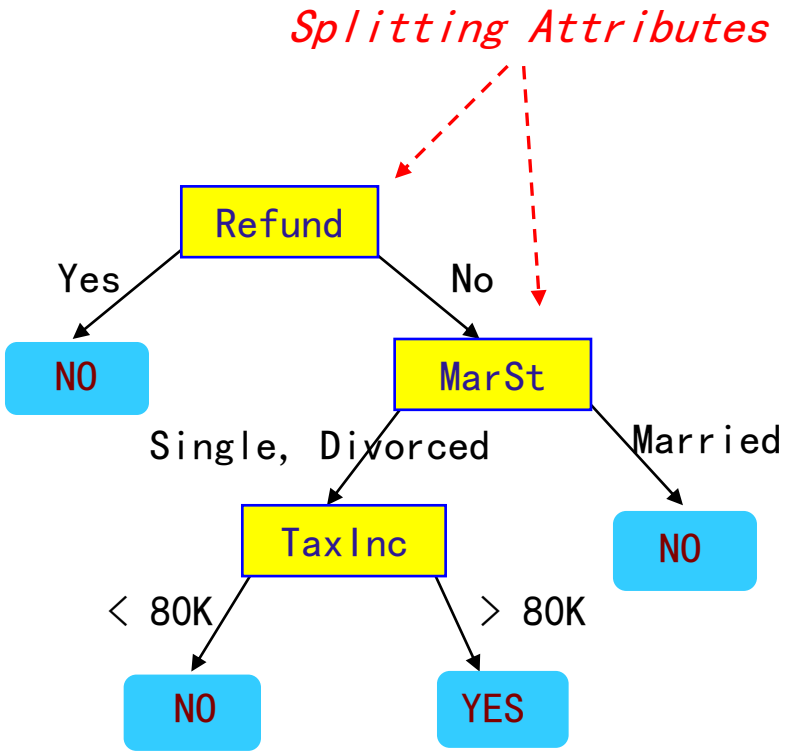
Test Set



应用决策树进行分类

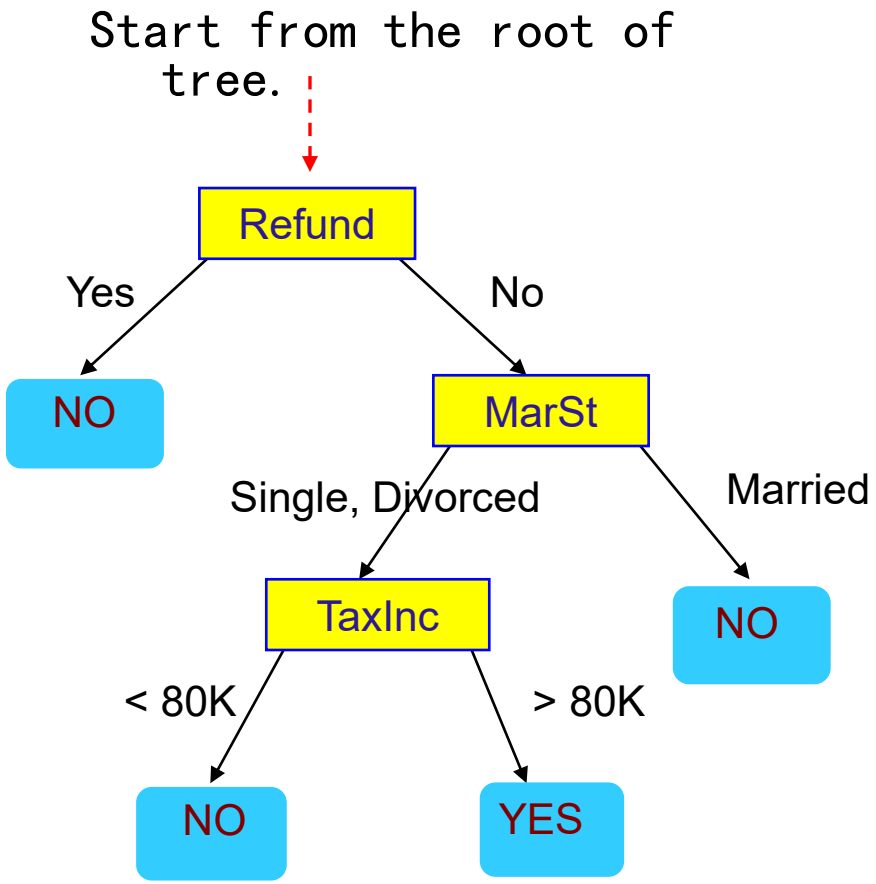
	categorical	categorical	continuous	class
Tid	**Refund**	**Marital Status**	**Taxable Income**	**Cheat**
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

训练数据



模型： 决策树

应用决策树进行分类



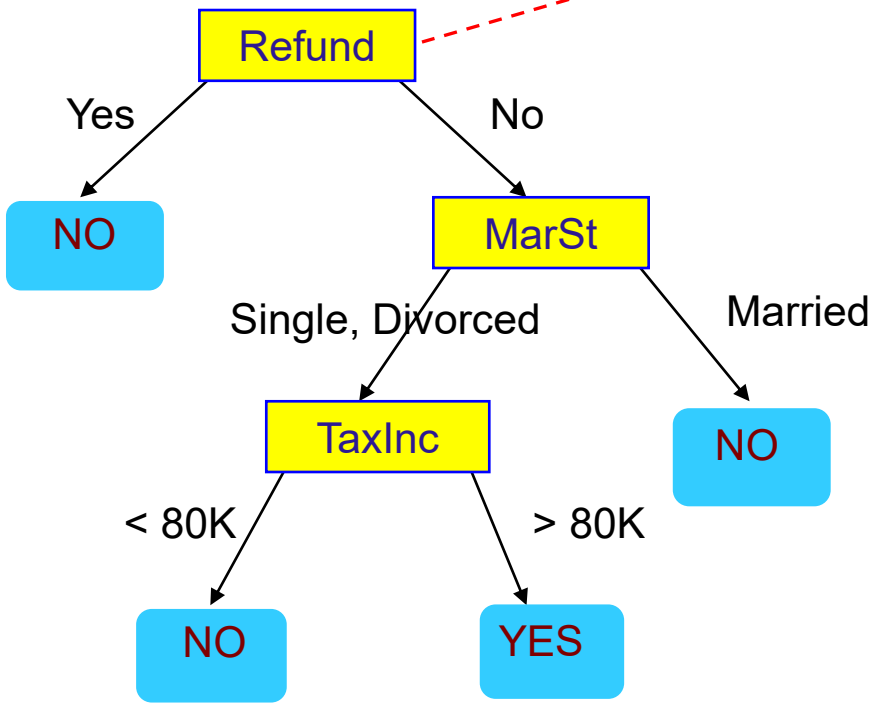
测试数据

Refund	Marital Status	Taxable Income	Cheat
No	Married	80K	?

应用决策树进行分类

测试数据

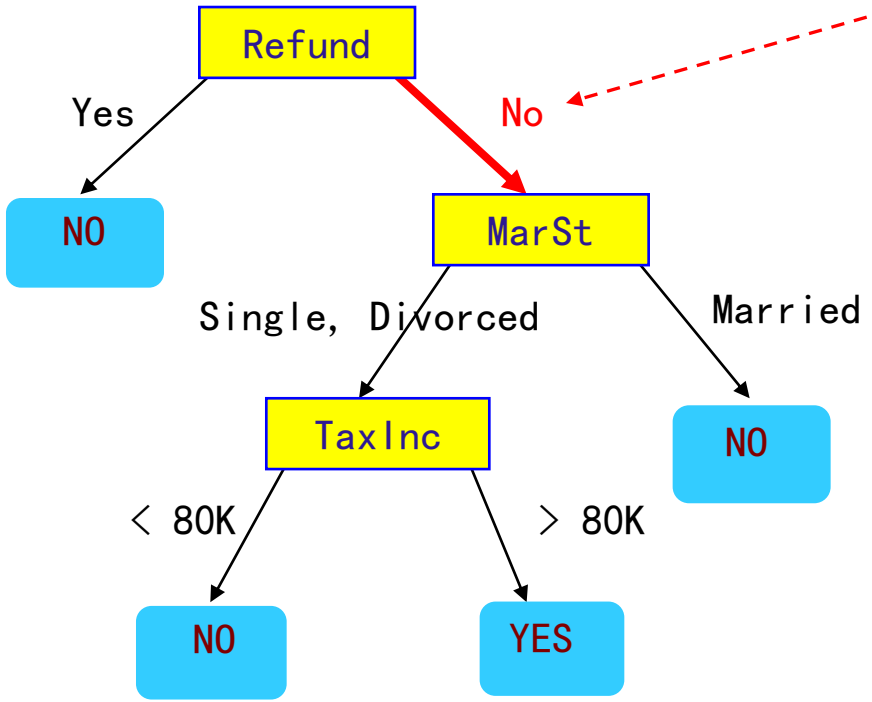
Refund	Marital Status	Taxable Income	Cheat
No	Married	80K	?



应用决策树进行分类

测试数据

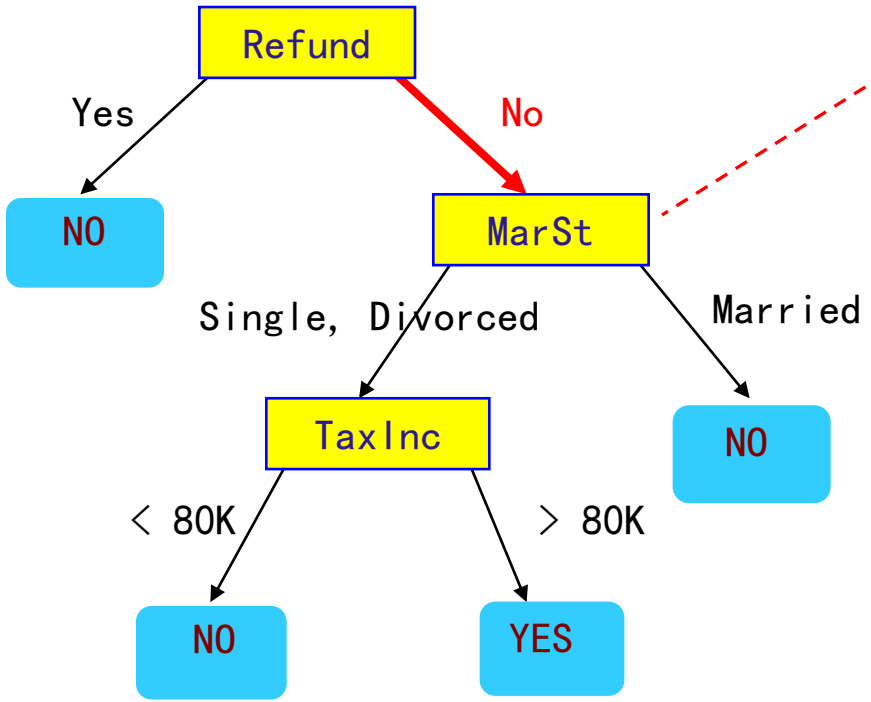
Refund	Marital Status	Taxable Income	Cheat
No	Married	80K	?



应用决策树进行分类

测试数据

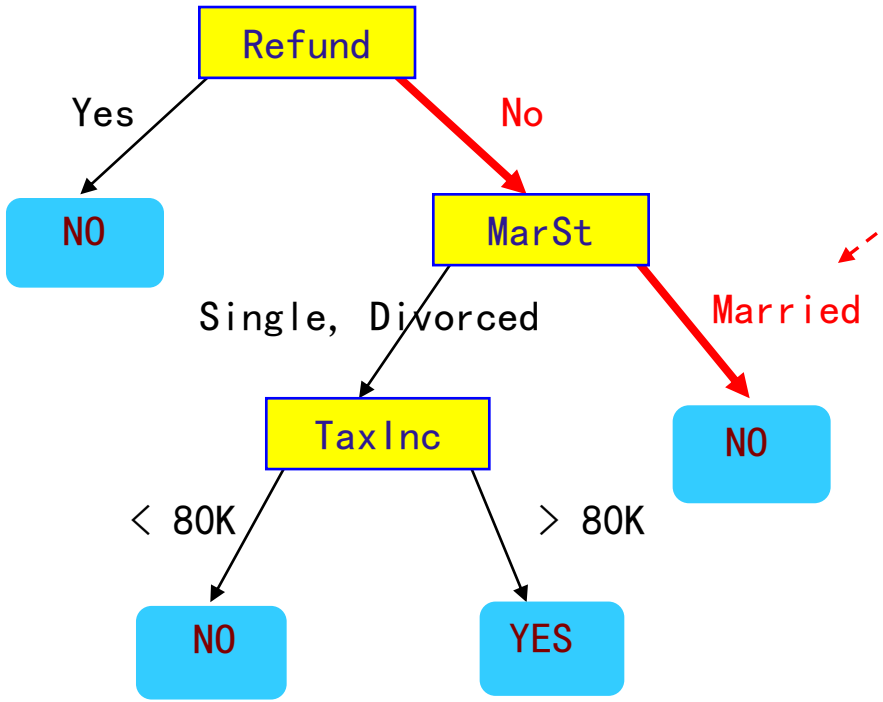
Refund	Marital Status	Taxable Income	Cheat
No	Married	80K	?



应用决策树进行分类

测试数据

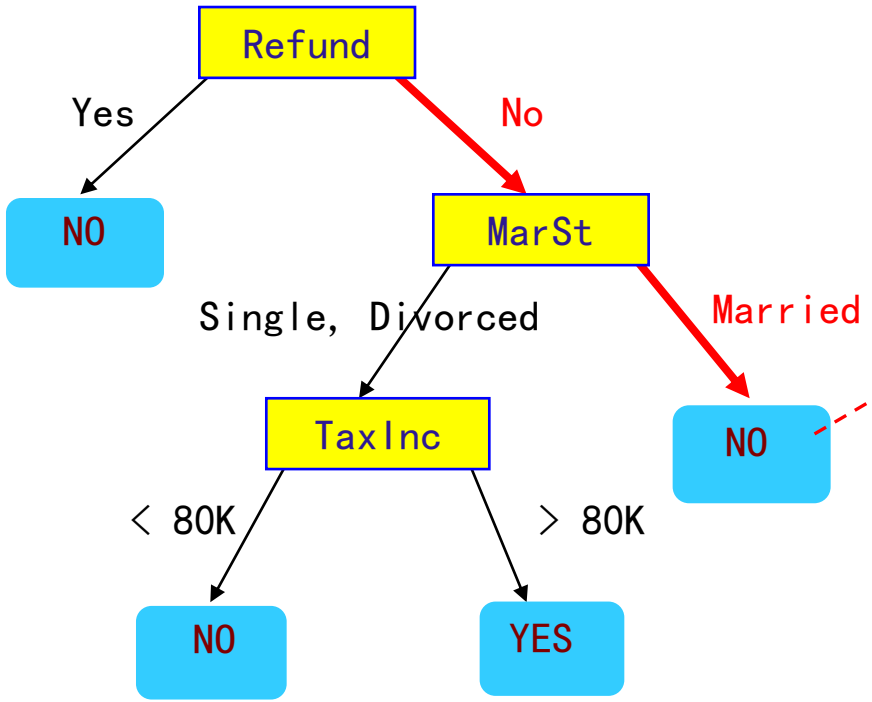
Refund	Marital Status	Taxable Income	Cheat
No	Married	80K	?



应用决策树进行分类

测试数据

Refund	Marital Status	Taxable Income	Cheat
No	Married	80K	?



Assign Cheat to "No"

本讲提纲

- 决策树基本介绍
- 如何建立决策树
  - 属性分裂
  - Hunt算法
- 节点分裂方法
  - 信息增益
  - Gini Index

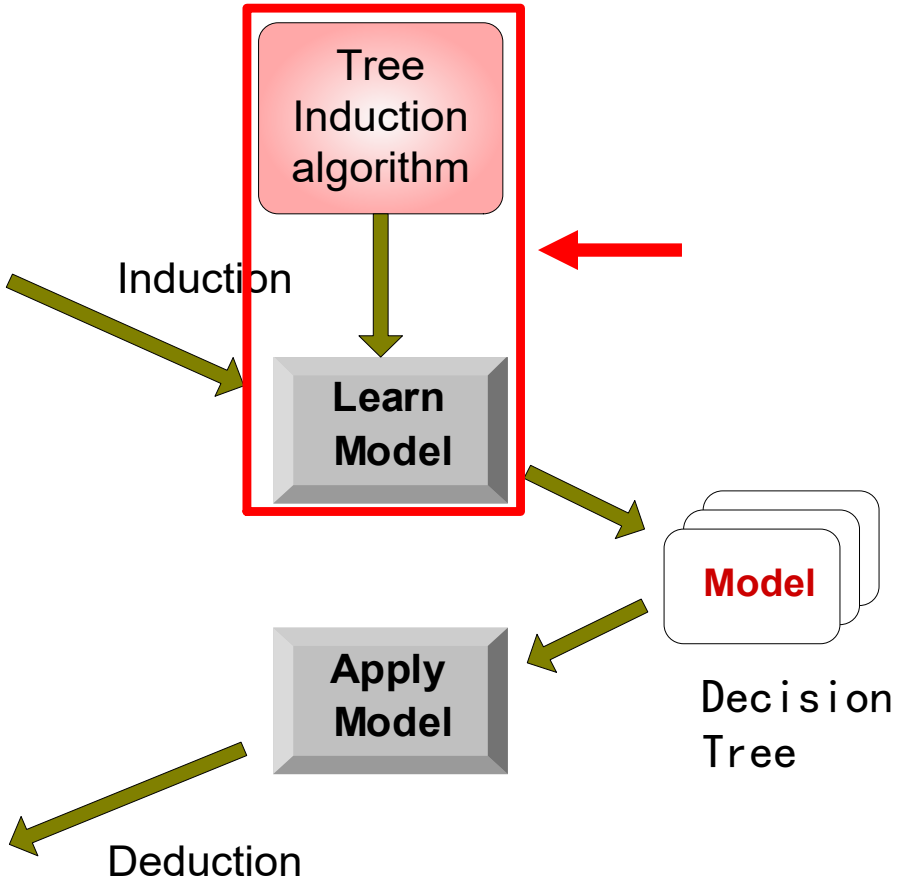
如何建立决策树

Tid	Attrib1	Attrib2	Attrib3	Class
1	Yes	Large	125K	No
2	No	Medium	100K	No
3	No	Small	70K	No
4	Yes	Medium	120K	No
5	No	Large	95K	Yes
6	No	Medium	60K	No
7	Yes	Large	220K	No
8	No	Small	85K	Yes
9	No	Medium	75K	No
10	No	Small	90K	Yes

Training Set

Tid	Attrib1	Attrib2	Attrib3	Class
11	No	Small	55K	?
12	Yes	Medium	80K	?
13	Yes	Large	110K	?
14	No	Small	95K	?
15	No	Large	67K	?

Test Set



如何建立决策树

- 决策树的生成由两个阶段组成
  - 决策树构建
    - 开始时，所有的训练样本都在根节点
    - 通过选定的属性，来**划分样本**
  - 树剪枝
    - 许多分枝反映的是训练数据中的噪声和孤立点，树剪枝试图检测和剪去这种分枝

Outlines

本讲提纲

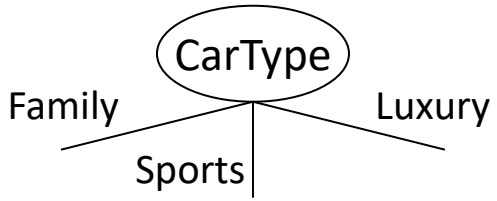
- 决策树基本介绍
- 如何建立决策树
  - 属性分裂
  - Hunt算法
- 节点分裂方法
  - 信息增益
  - Gini Index

表示属性测试条件的方法

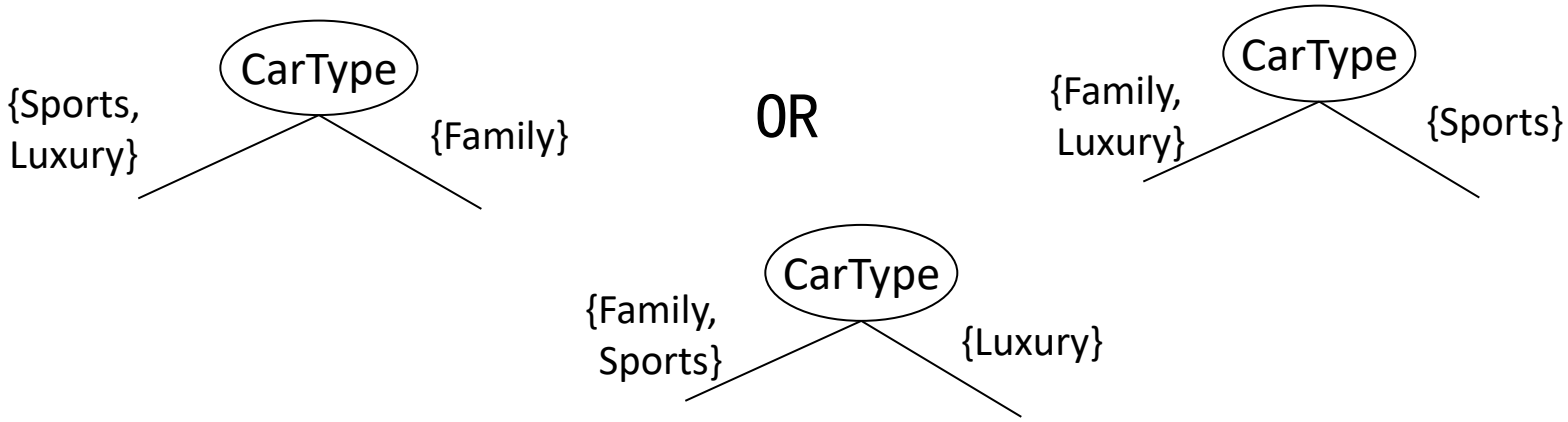
- 依赖于属性的类型
  - 标称
  - 序数
  - 连续
- 依赖于划分的路数
  - 2 路划分
  - 多路划分

基于标称属性的分裂

- 多路划分：划分数（输出数）取决于该属性不同属性值的个数.

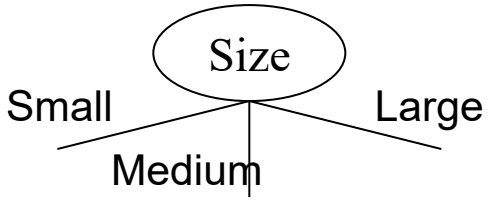


- 二元划分： 划分数为2，这种划分要考虑创建k个属性值的二元划分的所有$2^{k-1}-1$种方法.

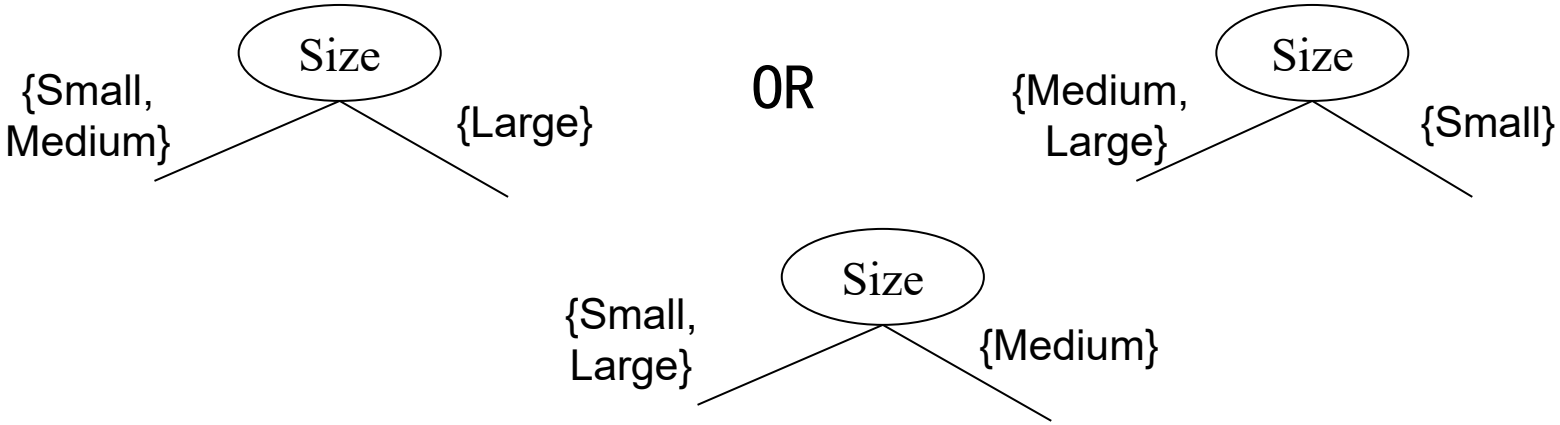


基于序数属性的划分

- 多路划分：划分数（输出数）取决于该属性不同属性值的个数.



- 二元划分：划分数为2，需要保持序数属性值的有序性.

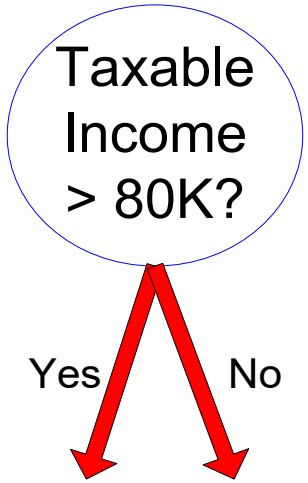


基于连续属性的划分

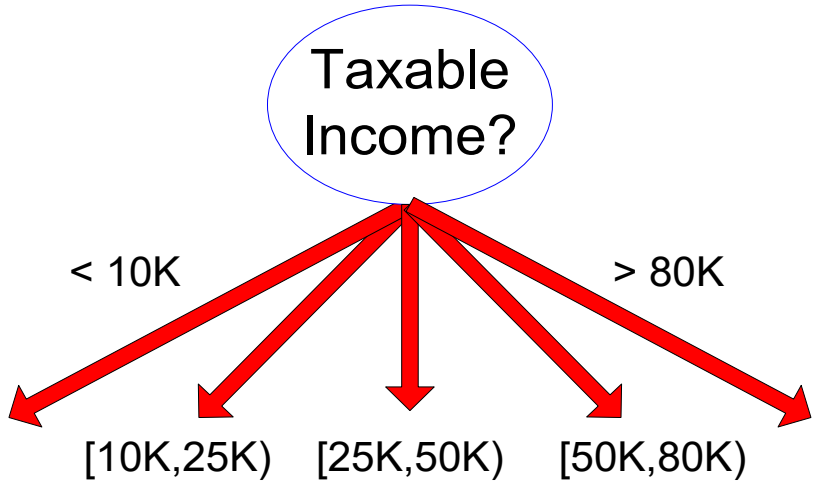
- 多路划分：$v_i \leqslant A < v_{i+1}$（$i=1, \cdots, k$）

- 二元划分：（$A < v$）or （$A \geq v$）
  - 考虑所有的划分点，选择一个最佳划分点v

基于连续属性的划分



(i) Binary split



(ii) Multi-way split

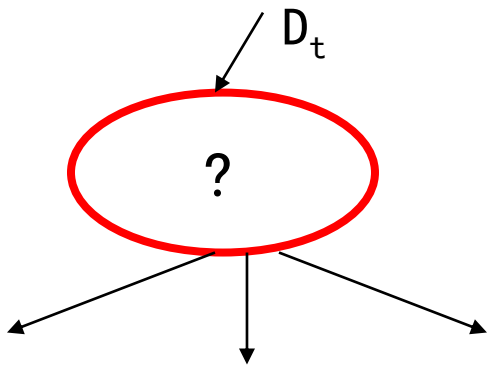
本讲提纲

- 决策树基本介绍
- 如何建立决策树
  - 属性分裂
  - Hunt算法
- 节点分裂方法
  - 信息增益
  - Gini Index

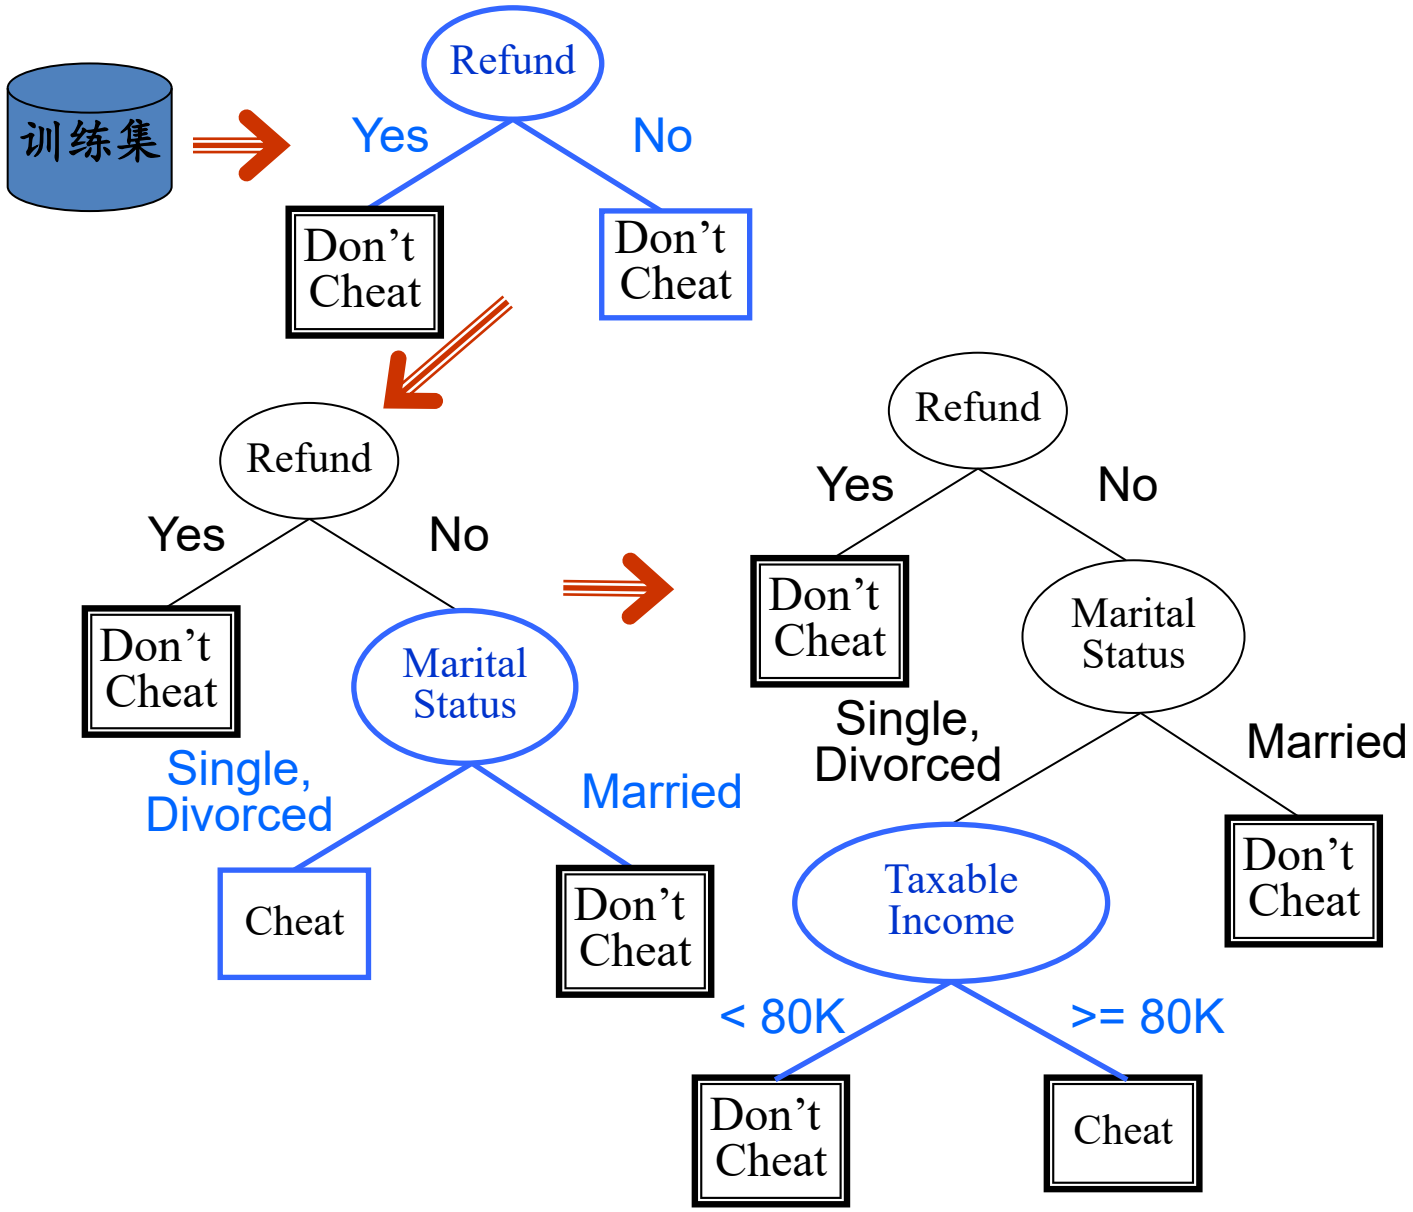
Hunt 算法

- 设 D_t 是与结点t相关联的训练集
- 算法步骤：
  - 如果D_t中所有记录都属于同一个类 y_t，则t是叶结点，用y_t标记
  - 如果D_t中包含属于多个类的记录，则选择一个属性测试条件，将记录划分成较小的子集。对于测试条件的每个输出，创建一个子结点，并根据测试结果将D_t中的记录分布到子结点中。然后，对于每个子结点，递归地调用该算法。

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

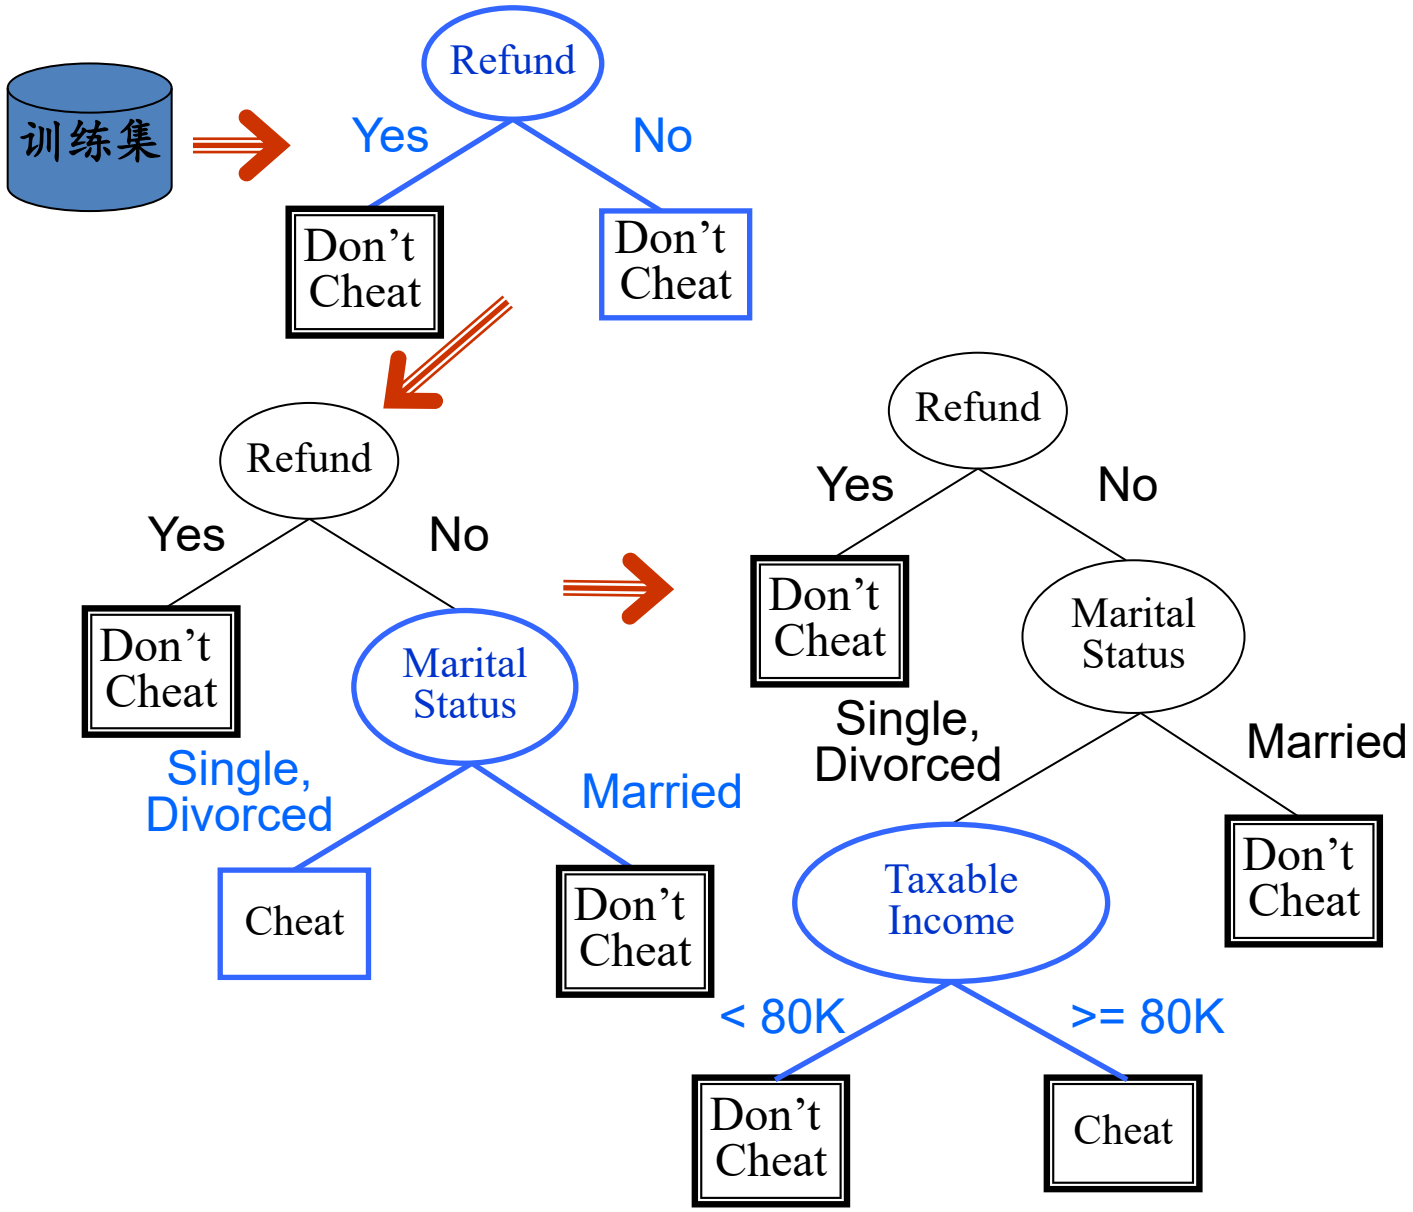


Hunt 算法



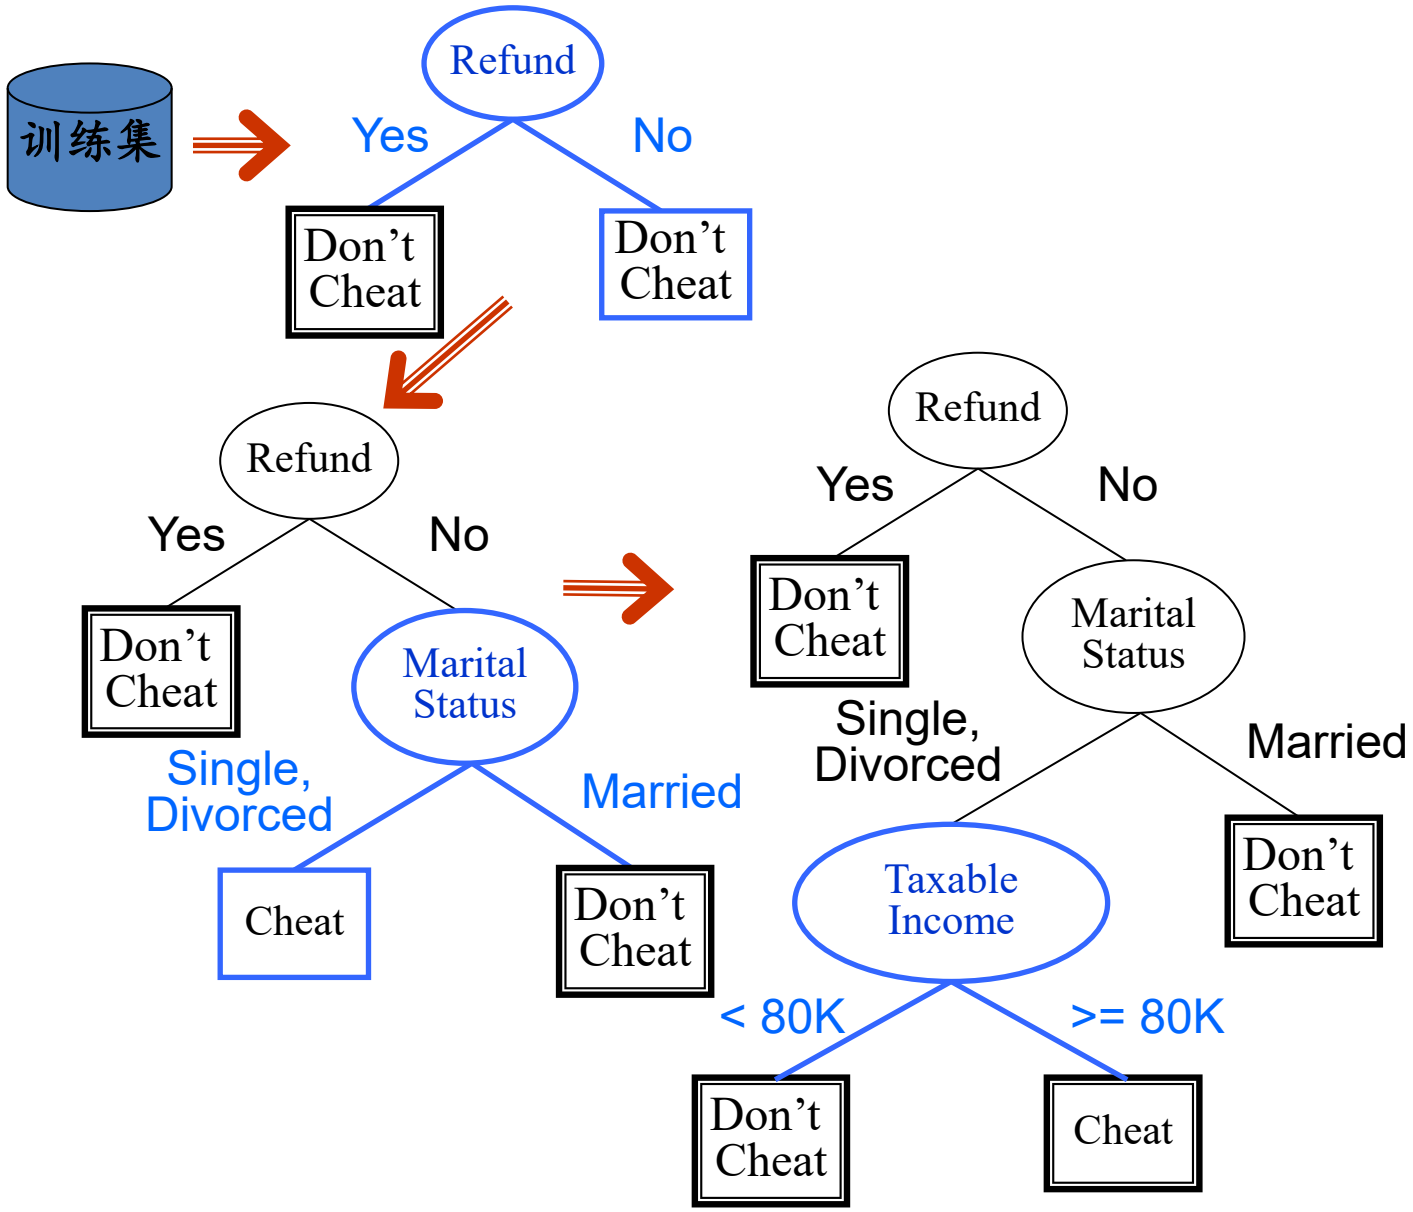
Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Hunt 算法



Tid	Refund	Marital Status	Taxable Income	Cheat
2	No	Married	100K	No
3	No	Single	70K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Hunt 算法



Tid	Refund	Marital Status	Taxable Income	Cheat
3	No	Single	70K	No
5	No	Divorced	95K	Yes
8	No	Single	85K	Yes
10	No	Single	90K	Yes

本讲提纲

- 决策树基本介绍
- 如何建立决策树
  - 属性分裂
  - Hunt算法
- **节点分裂方法**
  - 信息增益
  - Gini Index

分裂属性选择

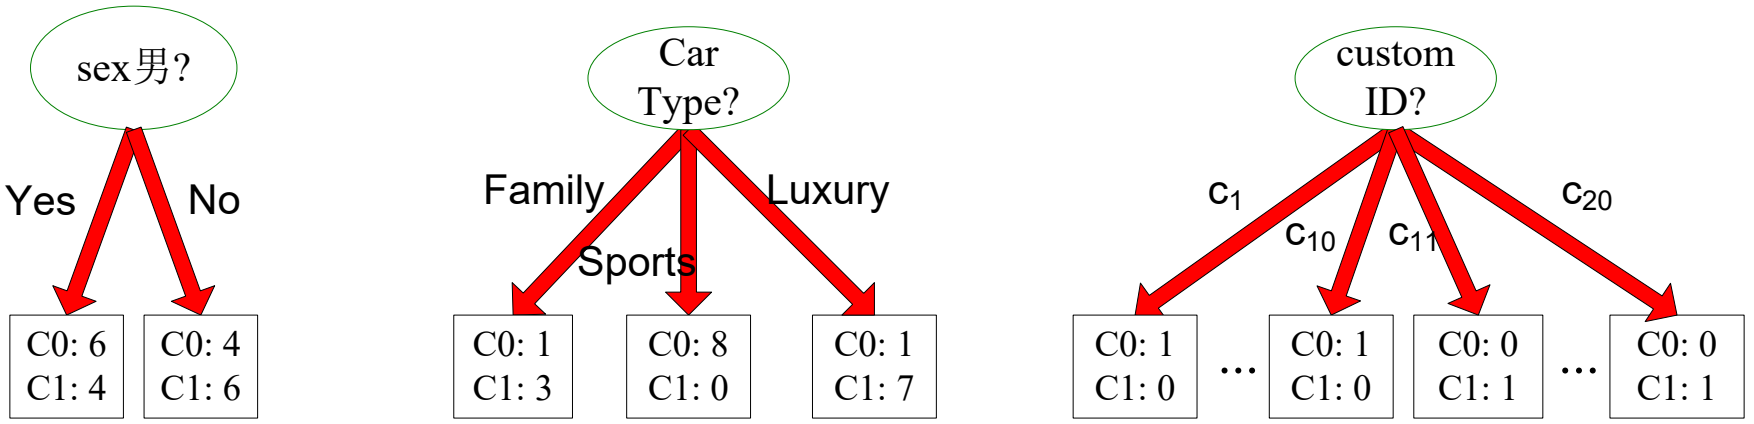
- 通过描述属性可以减少类标属性的不确定性。
  - 如：由番茄、茄子、黄瓜三种蔬菜，现在对蔬菜分类。在不给任何描述时，该蔬菜可能是番茄、茄子、黄瓜三种之一，不确定性大。
  - 给出该蔬菜是“长形”形状描述时，该蔬菜可能是茄子、黄瓜两种之一，不确定性减少。
  - 在给出该蔬菜是“紫的”颜色描述时，只可能是茄子了，不确定性为零。

分裂属性选择

- 虽然通过描述属性可以减少类标属性的不确定性，但是不同描述属性减少类标属性不确性的程度不同，即不同描述属性对减少类标属性不确定性的贡献不同。
  - 如：假设有番茄、茄子、黄瓜三种蔬菜，对某蔬菜分类，形状描述与颜色描述的贡献是不同的。
  - 在给出蔬菜的颜色描述时，如果颜色是红的，则该蔬菜是番茄；如果颜色是紫的，则该蔬菜是茄子；如果颜色是绿的，则该蔬菜是黄瓜，不确定性减少为0。
  - 在给出该蔬菜形状时，如果形状是圆的，则该蔬菜是番茄；如果形状是长的，则该蔬菜可能是茄子，也可能是黄瓜，不确定性还是存在。

分裂属性选择

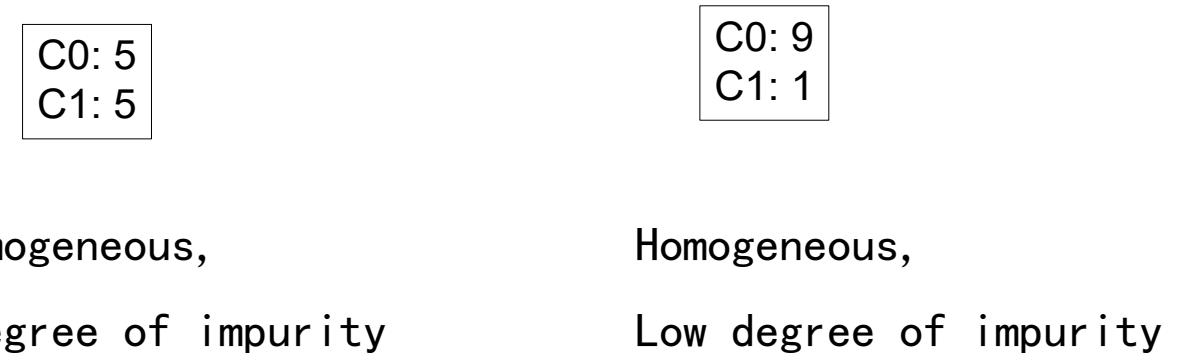
训练集：10 个记录 class 0,
10 个记录 class 1



哪个是最好的？

分裂属性选择

- 贪婪算法：
  - 优先选择具有同质化分布（Homogeneous）的节点
- 需要一种衡量节点**纯性**的方法：



节点纯性衡量方法

- 信息增益
- Gini Index

本讲提纲

- 决策树基本介绍
- 如何建立决策树
  - 属性分裂
  - Hunt算法
- 节点分裂方法
  - 信息增益 - ID3算法
  - Gini Index

信息熵的概念 – 信息能否度量 ？

物质、能量和信息是构成客观世界的三大要素。

信息（information）是什么?

至今信息还没有一个公认的定义

一般定义：常常把消息中有意义的内容称为信息。

信息熵的概念 – 什么是信息量



认识问题的过程：

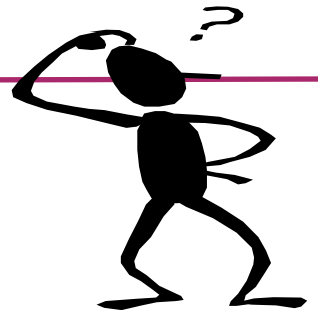
当我们对一问题毫无了解时，对它的认识是不确定的，在对问题的了解过程中，通过各种途径获得信息，逐渐消除了不确定性，获得的信息越多，消除的不确定性也越多。我们可以用消除不确定性的多少来度量信息量的大小。

例：会堂有20排、每排20个座位。找一个人。

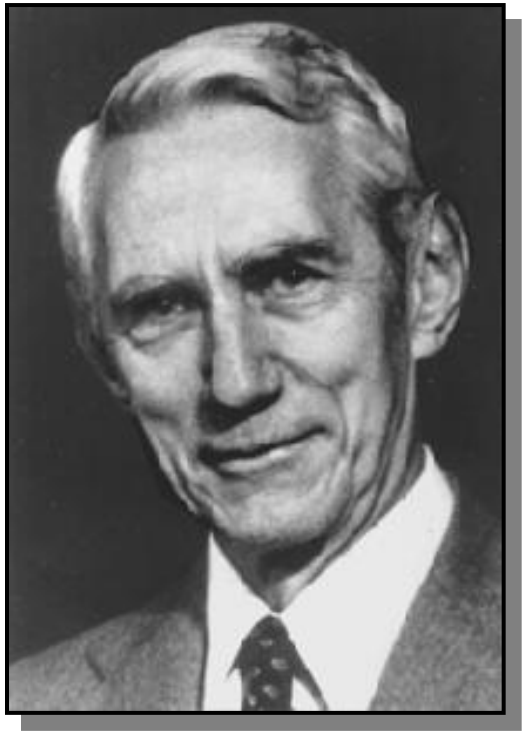
甲告诉消息：此人在第10排；

乙告诉消息：此人在第10排、第10座。

信息熵的概念



是否存在信息量的度量公式 ？



Claude Elwood Shannon (April 30, 1916 – February 24, 2001) has been called "the father of information theory".

1948年，美国数学家、信息论的创始人Shannon在题为“通讯的数学理论”的论文中指出：“信息是用来消除随机不定性的东西”。并应用概率论知识和逻辑方法推导出了信息量的计算公式。

信息熵的概念 - 信息量

公理1：信息量是事件发生概率的连续函数；

公理2：信息量是有限值；

公理3：如果事件A和事件B的发生是相互独立的，则获知事件A和事件B将同时发生的信息量是单独获知两事件发生的信息量之和。

设事件发生的概率为P，

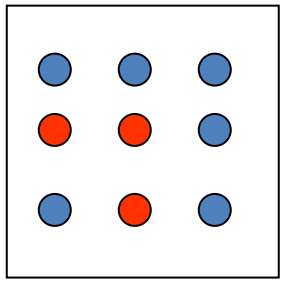
则满足上述公理的信息量函数为

$$I = -c \cdot \log_a p$$

为应用方便，可取c=1，a=e，单位为奈特（nat）

$$I = -\ln p$$

信息熵的概念 - 信息量



信息量函数　　I= -lnp　　如何体现不确定性的消除?

设$P(A)=\frac{M}{N}=p,$

其中N为基本事件总数，M为事件A所包含的基本事件数，

将N看成总的不确定性，M为事件A所包含的不确定性，

从而获知事件A发生后，共消除的不确定性为$N-M$。

将变量取对数后，不影响数值大小的单调性，

又能和事件发生的概率联系起来。

将$\ln N$看成总的不确定性，$\ln M$为事件A所包含的不确定性。

从而获知事件A发生后，共消除的不确定性为

$$\ln N-\ln M=-\ln p$$

信息熵的概念 - 信息量

例：会堂有20排、每排20个座位。找一个人。

甲告诉消息(A)：此人在第10排；

乙告诉消息(B)：此人在第10座。

$$P(A)=\frac{1}{20},\quad I=-\ln\frac{1}{20}=2.996$$

$$P(B)=\frac{1}{20\times 20},\quad I=-\ln\frac{1}{400}=5.991$$

由信息量公式 I= -Inp 可知 I 是 p 的单调下降函数

信息熵(Entropy)的概念

- 定义 I（X） 的数学期望

$$E(I(X)) = \sum_{i=1}^{n} p_i I(x_i) = -\sum_{i=1}^{n} p_i \ln p_i$$

- 称为随机变量X的平均自信息，又称X的信息熵或熵。

$$Entropy(X) = -\sum_{i=1}^{n} p_i \ln p_i$$

信息熵的直观意义

X	甲赢	乙赢
P	0.9	0.1

X	甲赢	乙赢
P	0.5	0.5

H 变量的不确定性越大，H 熵也就越大，把它搞清楚所需要的信息量也就越大。

$H=0.325$

$H=0.693$

一个系统越是有序，信息熵就越低；反之，一个系统越是混乱，信息熵就越高。所以，信息熵也可以说是系统有序化程度的一个度量。

熵的性质

- 连续非负性
- 对称性
- 扩展性
- 可加性
- 极值性：

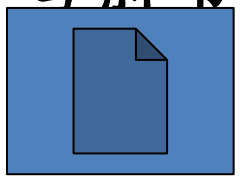
当$p_1 = p_2 = \cdots = p_n$时,即事件发生的可能性相同时，
熵取得最大值　　$H_n = \ln n$

基于 Information Gain的划分

- 选择具有最大信息增益的属性作为当前节点的测试属性。
- 该属性使得对结果划分中的样本分类所需的信息量最小，并反映划分的最小随机性。
- 用信息增益这种信息论的理论方法，使得对一个对象分类所需要的期望测试数目达到最小，并确保找到一棵简单的树。

基于 Information Gain的划分

- 怎样计算信息增益（information gain）
  - 信息增益被定义为原始分割的熵与划分以后各分割的熵累加得到的总熵之间的差。
  - 信息增益是指划分前后进行正确预测所需的信息量之差。
  - 选择具有最高信息增益的属性作为当前节点的测试属性。



基于 Information Gain的划分

- 给定结点t的 Entropy值计算 ：

$$Entropy(t) = -\sum_j p(j \mid t) \log_2 p(j \mid t)$$

$p(j \mid t)$ 是在结点t中，类j发生的概率.

– 当类分布均衡时， Entropy值达到最大值

计算 Entropy的例子

$$Entropy(t) = -\sum_j p(j \mid t) \log_2 p(j \mid t)$$

C1	0
C2	6

P(C1) = 0/6 = 0　　P(C2) = 6/6 = 1

Entropy = - 0 log 0 - 1 log 1 = - 0 - 0 = 0

C1	1
C2	5

P(C1) = 1/6　　P(C2) = 5/6

Entropy = - (1/6) $\log_2$ (1/6) - (5/6) $\log_2$ (1/6) = 0.65

C1	2
C2	4

P(C1) = 2/6　　P(C2) = 4/6

Entropy = - (2/6) $\log_2$ (2/6) - (4/6) $\log_2$ (4/6) = 0.92

计算 Entropy的例子

- Information Gain:

$$GAIN_{split} = Entropy(p) - \left(\sum_{i=1}^{k} \frac{n_i}{n} Entropy(i) \right)$$

n_i = 孩子结点 i的记录数,

n = 父结点 p的记录数.

– 在 ID3 and C4.5中使用

如何建立决策树

- Hunt算法
- 决策树归纳的设计问题
  - 如何分裂训练记录
    - 怎样为不同类型的属性指定测试条件?
    - 怎样评估测试条件?
- ID3算法

ID3算法

- ID3算法是一种经典的决策树学习算法，由Quinlan于1979年提出。ID3算法的基本思想是，以信息熵为度量，用于决策树节点的属性选择，每次优先选取信息量最多的属性，亦即能使熵值变为最小的属性，以构造一颗熵值下降最快的决策树，到叶子节点处的熵值为0。此时，每个叶子节点对应的实例集中的实例属于同一类。

ID3决策树算法例子

计数	年龄	收入	学生	信誉	归类：买计算机？
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

ID3决策树算法例子

计数	年龄	收入	学生	信誉	归类：买计算机？
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

第1步计算决策属性的熵

决策属性“买计算机？”。
该属性分
两类：买/不买
S1(买)=641
S2(不买)= 383
S=S1+S2=1024

P1=641/1024=0.6260
P2=383/1024=0.3740

$I(S1,S2)=I(641,383)$
$=-P1Log_2P1-P2Log_2P2$
$=-(P1Log_2P1+P2Log_2P2)$
$=0.9537$

ID3决策树算法例子

计数	年龄	收入	学生	信誉	归类：买计算机？
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

第2步计算条件属性的熵

条件属性共有4个。分别是年龄、收入、学生、信誉。
分别计算不同属性的信息增益。

ID3决策树算法例子

计数	年龄	收入	学生	信誉	归类：买计算机？
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

第2-1步计算年龄的熵

年龄共分三个组：

青年、中年、老年

青年买与不买比例为128/256

S1（买）=128

S2（不买）= 256

S=S1+S2=384

P1=128/384

P2=256/384

I（S1，S2）=I（128，256）

$=-P1Log_2P1-P2Log_2P2$

$=-(P1Log_2P1+P2Log_2P2)$

=0.9183

ID3决策树算法例子

计数	年龄	收入	学生	信誉	归类：买计算机？
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

第2-2步计算年龄的熵

年龄共分三个组：

青年、中年、老年

中年买与不买比例为256/0

S1（买）=256

S2（不买）= 0

S=S1+S2=256

P1=256/256

P2=0/256

I（S1，S2）=I（256，0）

$=-P1Log_2P1-P2Log_2P2$

$=-(P1Log_2P1+P2Log_2P2)$

=0

ID3决策树算法例子

计数	年龄	收入	学生	信誉	归类：买计算机？
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

第2-3步计算年龄的熵

年龄共分三个组：

青年、中年、老年

老年买与不买比例为125/127

S1（买）=125

S2（不买）=127

S=S1+S2=252

P1=125/252

P2=127/252

$I(S1, S2)=I(125, 127)$

$=-P1Log_2P1-P2Log_2P2$

$=-(P1Log_2P1+P2Log_2P2)$

$=0.9157$

ID3决策树算法例子

计数	年龄	收入	学生	信誉	归类：买计算机？
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

第2-4步计算年龄的熵

年龄共分三个组：

青年、中年、老年

所占比例

青年组 384/1025=0.375

中年组 256/1024=0.25

老年组 384/1024=0.375

计算年龄的平均信息期望

E（年龄）=0.375*0.9183+

0.25*0+

0.375*0.9157

=0.6877

G（年龄信息增益）

=0.9537-0.6877

=0.2660 （1）

ID3决策树算法例子

计数	年龄	收入	学生	信誉	归类：买计算机？
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

第3步计算收入的熵

收入共分三个组：

高、中、低

E（收入）=0.9361

收入信息增益=0.9537−0.9361

=0.0176 （2）

ID3决策树算法例子

计数	年龄	收入	学生	信誉	归类：买计算机？
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

第4步计算学生的熵

学生共分二个组：

学生、非学生

E（学生）=0.7811

年龄信息增益=0.9537−0.7811

=0.1726 （3）

ID3决策树算法例子

计数	年龄	收入	学生	信誉	归类：买计算机？
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

第5步计算信誉的熵

信誉分二个组：

良好，优秀

E（信誉）= 0.9048

信誉信息增益=0.9537−0.9048

=0.0453 （4）

ID3决策树算法例子

计数	年龄	收入	学生	信誉	归类：买计算机？
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买

第6步计算选择节点

年龄信息增益=0.9537−0.6877
=0.2660 （1）

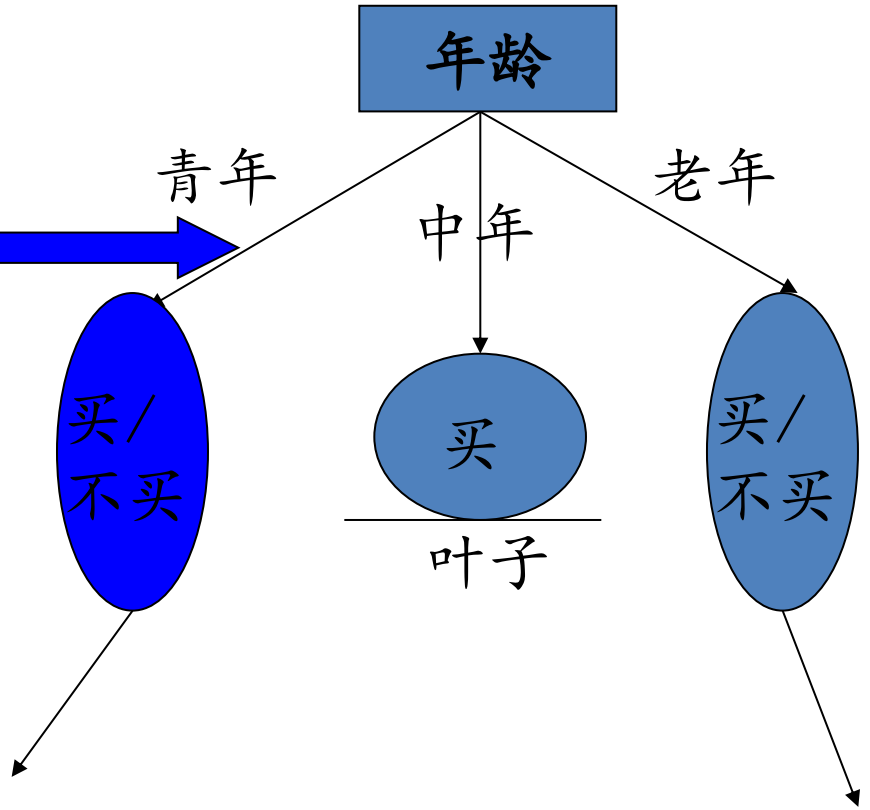
收入信息增益=0.9537−0.9361
=0.0176 （2）

年龄信息增益=0.9537−0.7811
=0.1726 （3）

信誉信息增益=0.9537−0.9048
=0.0453 （4）

ID3决策树算法例子

计数	年龄	收入	学生	信誉	归类：买计算机？
64	青	高	否	良	不买
64	青	高	否	优	不买
128	青	中	否	良	不买
64	青	低	是	良	买
64	青	中	是	优	买



ID3决策树算法例子

计数	年龄	收入	学生	信誉	归类：买计算机？
64	青	高	否	良	不买
64	青	高	否	优	不买
128	青	中	否	良	不买
64	青	低	是	良	买
64	青	中	是	优	买

青年买与不买比例为128/256

S1（买）=128
S2（不买）= 256
S=S1+S2=384

P1=128/384
P2=256/384

I (S1, S2) =I (128, 256)
=−P1Log2P1−P2Log2P2
=− (P1Log2P1+P2Log2P2)
=0. 9183

ID3决策树算法例子

计数	年龄	收入	学生	信誉	归类：买计算机？
64	青	高	否	良	不买
64	青	高	否	优	不买
128	青	中	否	良	不买
64	青	低	是	良	买
64	青	中	是	优	买

如果选择收入作为节点
分高、中、低

I(0, 128)=0
比例：
128/384=0.3333

I(64, 128)=0.9183
比例： 192/384=0.5

I(64, 0)=0
比例：
64/384=0.1667

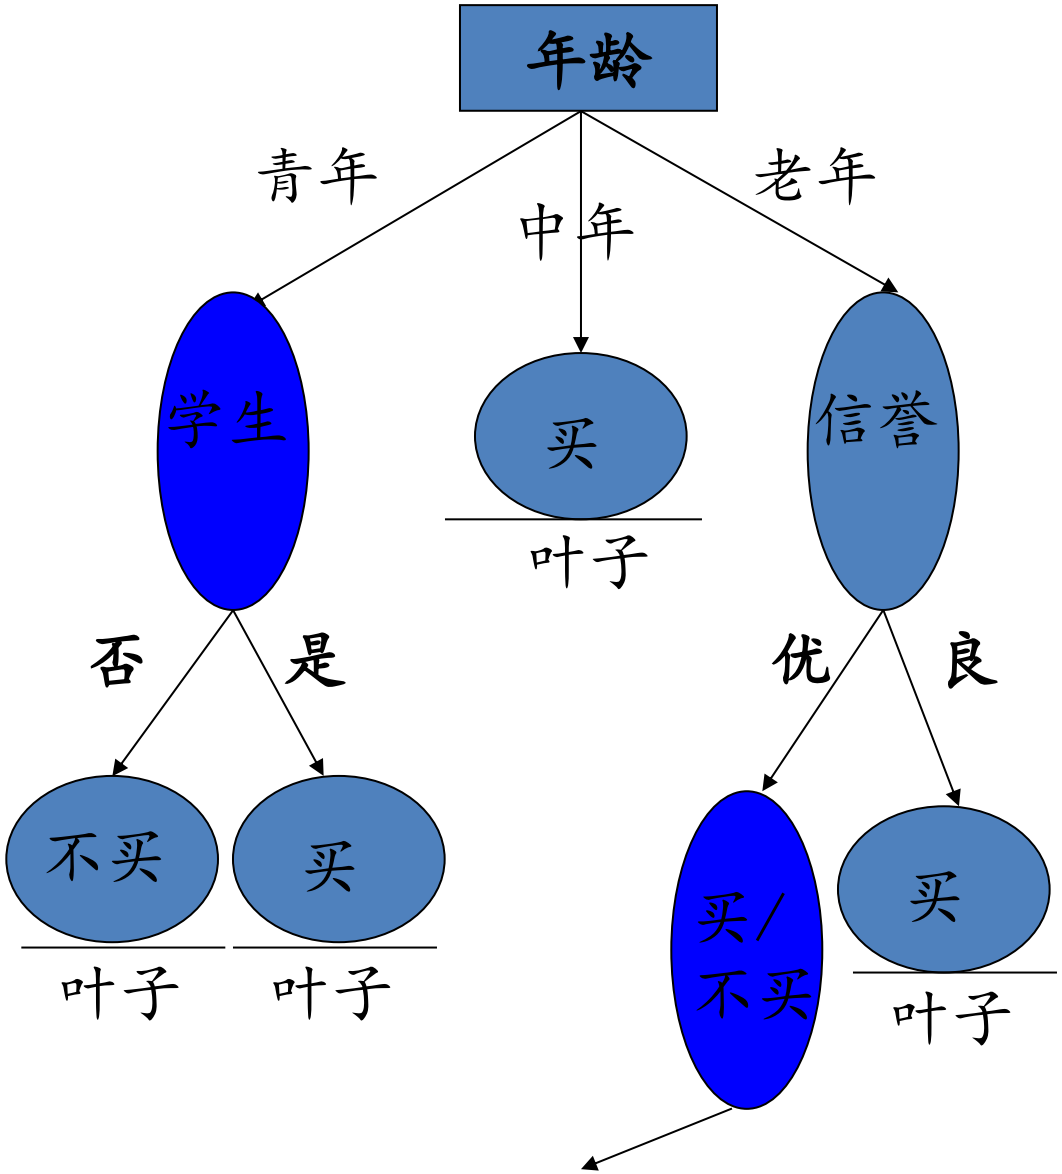
平均信息期望（加权总和）：

E(收入) = 0.3333 * 0 + 0.5 * 0.9183 + 0.1667 * 0 = 0.4592

Gain(收入) = I(128, 256) - E(收入)=0.9183 - 0.4592 = 0.4591

ID3决策树算法例子

计数	年龄	收入	学生	信誉	归类：买计算机？
64	青	高	否	良	不买
64	青	高	否	优	不买
128	中	高	否	良	买
60	老	中	否	良	买
64	老	低	是	良	买
64	老	低	是	优	不买
64	中	低	是	优	买
128	青	中	否	良	不买
64	青	低	是	良	买
132	老	中	是	良	买
64	青	中	是	优	买
32	中	中	否	优	买
32	中	高	是	良	买
63	老	中	否	优	不买
1	老	中	否	优	买



ID3算法流程

1. 决定分类属性
2. 对目前的数据表，建立一个节点N
3. 如果数据库中的数据都属于同一个类，N就是树叶，在树叶上标出所属的类
4. 如果数据表中没有其他属性可以考虑，则N也是树叶，按照少数服从多数的原则在树叶上标出所属类别
5. 否则，根据平均信息期望值E或GAIN值选出一个最佳属性作为节点N的测试属性
6. 节点属性选定后，对于该属性中的每个值：
7. 从N生成一个分支，并将数据表中与该分支有关的数据收集形成分支节点的数据表，在表中删除节点属性那一栏。如果分支数据表非空，则运用以上算法从该节点建立子树。转步骤3。

决策树中分类规则获取

- 决策树所表示的分类知识可以被抽取出来并可用IF-THEN 分类规则形式加以表示。

- 从决策树的根结点到任一个叶结点所形成的一条路径就构成了一条分类规则。

- 沿着决策树的一条路径所形成的属性-值偶对就构成了分类规则条件部分（IF 部分）中的一个合取项，叶结点所标记的类别就构成了规则的结论内容（THEN 部分）。

- IF-THEN分类规则表达方式易于被人理解，且当决策树较大时， IF-THEN规则表示形式的优势就更加突出。

- Example

IF *age* = “<=30” AND *student* = “*no*” THEN *buys_computer* = “*no*”

IF *age* = “<=30” AND *student* = “*yes*” THEN *buys_computer* = “*yes*”

IF *age* = “31…40” THEN *buys_computer* = “*yes*”

IF *age* = “>40” AND *credit_rating* = “*excellent*” THEN *buys_computer* = “*no*”

IF *age* = “<=30” AND *credit_rating* = “*fair*” THEN *buys_computer* = “*yes*”

ID3算法应用-在电信行业应用实例（1）

通过ID3算法来实现客户流失的预警分析，找出客户流失的特征，以帮助电信公司有针对性地改善客户关系，避免客户流失　　利用决策树方法进行数据挖掘，一般有如下步骤：数据预处理、决策树挖掘操作，模式评估和应用。

电信运营商的客户流失有三方面的含义：一是指客户从一个电信运营商转网到其他电信运营商，这是流失分析的重点。二是指客户月平均消费量降低，从高价值客户成为低价值客户。三、指客户自然流失和被动流失。

在客户流失分析中有两个核心变量：财务原因／非财务原因、主动流失／被动流失。

客户流失可以相应分为四种类型：其中非财务原因主动流失的客户往往是高价值的客户。他们会正常支付服务费用，并容易对市场活动有所响应。这种客户是电信企业真正需要保住的客户。

ID3算法应用-在电信行业应用实例（2）

数据预处理

数据挖掘的处理对象是大量的数据，这些数据一般存储在数据库系统中（该用户相关数据存储在其CRM中），是长期积累的结果。但往往不适合直接挖掘，需要做数据的预处理工作，一般包括数据的选择(选择相关的数据)、净化(消除冗余数据)、转换、归约等。数据预处理工作准备是否充分，对于挖掘算法的效率乃至正确性都有关键性的影响。

该公司经过多年的电脑化管理，已有大量的客户个人基本信息(文中简称为客户信息表)。在客户信息表中，有很多属性，如姓名用户号码、用户标识、用户身份证号码(转化为年龄)、在网时间（竣工时间）、地址、职业、用户类别、客户流失（用户状态）等等，数据准备时必须除掉表中一些不必要的属性，一般可采用面向属性的归纳等方法去掉不相关或弱相关属性。

ID3算法应用-在电信行业应用实例（3）

属性删除

将有大量不同取值且无概化操作符的属性或者可用其它属性来代替它的较高层概念的那些属性删除。比如客户信息表中的用户标识、身份证号码等，它们的取值太多且无法在该取值域内找到概化操作符，应将其删除，得到表1。

表1　客户信息表

年龄	学历	职业	缴费方式	在网时长	费用变化率	客户流失
58	大学	公务员	托收	13	10%	NO
47	高中	工人	营业厅缴费	9	42%	NO
26	研究生	公务员	充值卡	2	63%	YES
28	大学	公务员	营业厅缴费	5	2.91%	NO
32	初中	工人	营业厅缴费	3	2.3%	NO
42	高中	无业人员	充值卡	2	100%	YES
68	初中	无业人员	营业厅缴费	9	2.3%	NO

ID3算法应用-在电信行业应用实例（4）

属性概化：用属性概化阈值控制技术沿属性概念分层上卷或下钻进行概化。

文化程度分为3类：W1初中以下(含初中)，W2高中(含中专)，W3大学(专科、本科及以上)；

职业类别：按工作性质来分共分3类：Z1—Z3；

缴费方式：托收：T1,营业厅缴费：T2,充值卡：T3。

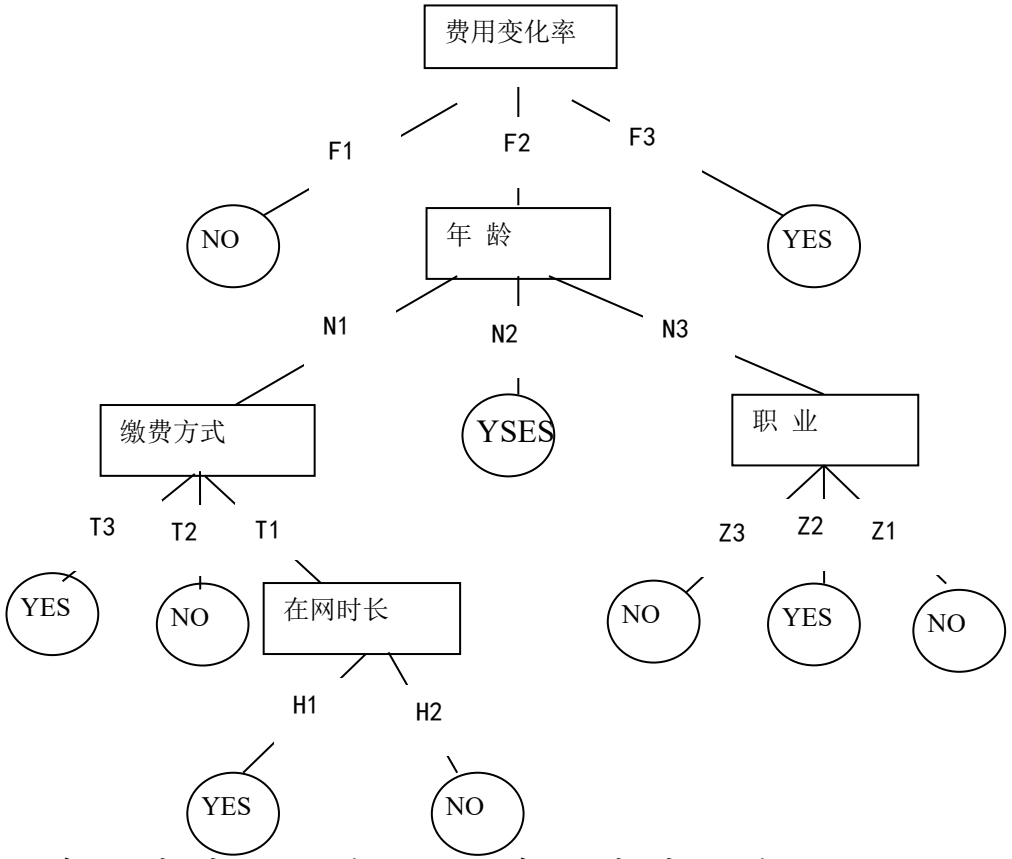
连续型属性概化为区间值：表中年龄、费用变化率和在网时间为连续型数据，由于建立决策树时，用离散型数据进行处理速度最快，因此对连续型数据进行离散化处理，根据专家经验和实际计算信息增益，在“在网时长”属性中，通过检测每个划分，得到在阈值为5年时信息增益最大，从而确定最好的划分是在5年处，则这个属性的范围就变为{<=5,>5：H1,H2}。而在“年龄”属性中，信息增益有两个锋值，分别在40和50处，因而该属性的范围变为{<=40,>40-<=50,>50}即变为{青年，中年，老年：N1,N2,N3}；费用变化率：指（（当月话费—近3个月的平均话费）/近3个月的平均话费）×%>0，F1:<=30%，F2:30%-99%，F3:=100%变为{F1,F2,F3}。

ID3算法应用-在电信行业应用实例（5）

表2　转化后的客户信息表

年龄	学历	职业	缴费方式	开户时间	费用变化率	客户流失
N3	W3	Z1	T1	H2	F1	NO
N2	W2	Z2	T2	H2	F2	NO
N1	W3	Z1	T3	H1	F2	YES
N1	W3	Z1	T2	H1	F1	NO
N1	W1	Z2	T2	H1	F1	NO
N2	W2	Z3	T3	H1	F3	YES
N3	W1	Z3	T1	H2	F1	NO

ID3算法应用-在电信行业应用实例（6）



在图中，NO表示客户不流失，YES表示客户流失。从图可以看出，客户费用变化率为100%的客户肯定已经流失；而费用变化率低于30%的客户；即每月资费相对稳定的客户一般不会流失，费用变化率在30%～99%的客户有可能流失，其中年龄在40～50岁之间的客户流失的可能性非常大，而年龄低于40岁的客户，用充值卡缴费的客户和在网时间较短的客户容易流失；年龄较大的客户，则工人容易流失。

02

树模型家族

Bagging • Boosting • 怎么选

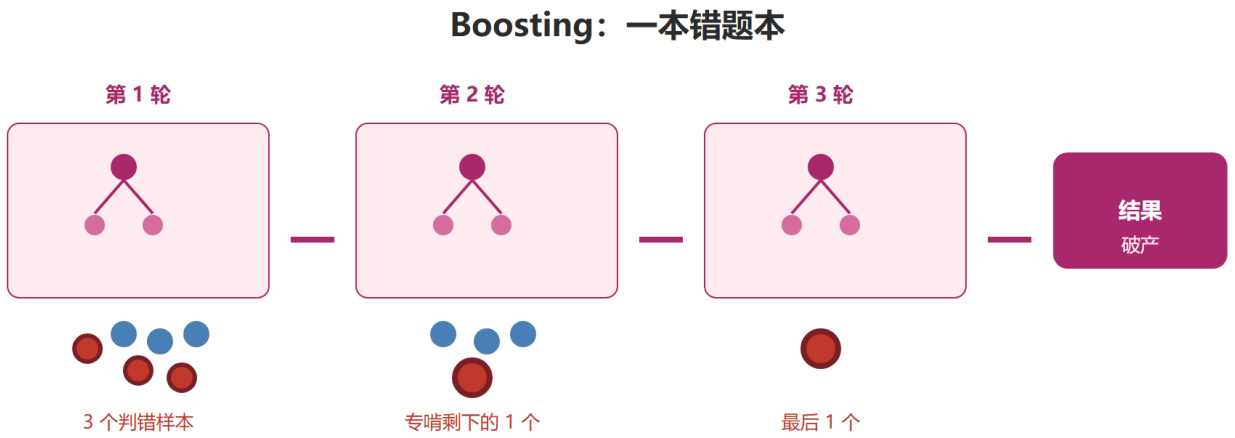
一棵树不够稳，那就种一片森林

- **单棵树的问题：数据稍微变一点，树形就变**
- 思路一 Bagging：多棵树各自学，最后投票
- 思路二 Boosting：一棵棵接力，后一棵专攻前一棵的错误
- 两者都能提准确率，代价是越来越难解释

Bagging 与随机森林



Boosting：一本错题本



后面的树专啃前面啃不动的骨头

随机森林是并行投票，GBDT 是串行补漏

类比：学生刷题，第一遍做错的抄进错题本，第二遍专门刷错题本

GBDT / XGBoost / LightGBM 都是这个思路的不同实现

两种思路怎么选

对比项	随机森林	GBDT / XGBoost
训练方式	并行，各自独立	串行，接力纠错
抗噪能力	较强	对异常值更敏感
调参难度	低，默认就能用	高，参数互相影响
常见表现	稳	通常更准

其他模型：只讲什么时候用

其他模型：只讲什么时候用

逻辑回归	决策树	随机森林 / GBDT	SVM	KNN
必须跑的基线	最能讲清楚的	通常最准	小样本高维	最简单的参照物
系数能直接解释方向 审稿人常要求补	可画出规则路径 业务讲稿首选	表格数据主力 比赛常用	特征多、样本少 昔日王者	解释成本最低 baseline 参考

先用基线定底线，再谈复杂模型

今天不推导任何一个公式，只记适用范围

一个合格的项目：逻辑回归基线 + 决策树可解释 + 森林/GBDT 冲准确率

03

模型评估与指标详解

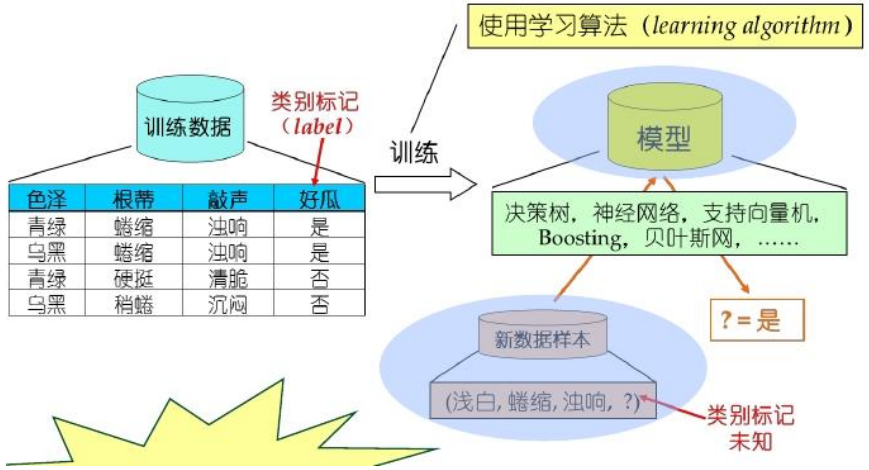
评估方法 • 性能度量 • 指标选择

这一章要讲什么：模型评估与指标

- **上午讲过：模型要「比武选冠军」，怎么比？**
- 下午专攻：每一个衡量指标是什么、什么时候用
- 全程用一个例子：破产预测（6,819 家公司，220 家破产）

为什么评估这么重要

- **模型训练完，怎么知道它靠不靠谱？**
- 泛化误差：在「未来」新样本上的误差——这才是关心的
- 经验误差：在训练集上的误差——会骗人（背答案）
- 我们的破产模型：训练集 96% 准，不代表新公司也 96% 准



过拟合 vs 欠拟合

- **过拟合：把训练集背下来，新数据不会——树太深**
- 欠拟合：还没学会，训练集都不准——树太浅
- 破产场景：过拟合的树会把「偶然特征」当规律
- 目标是：在训练集与未知数据之间取平衡

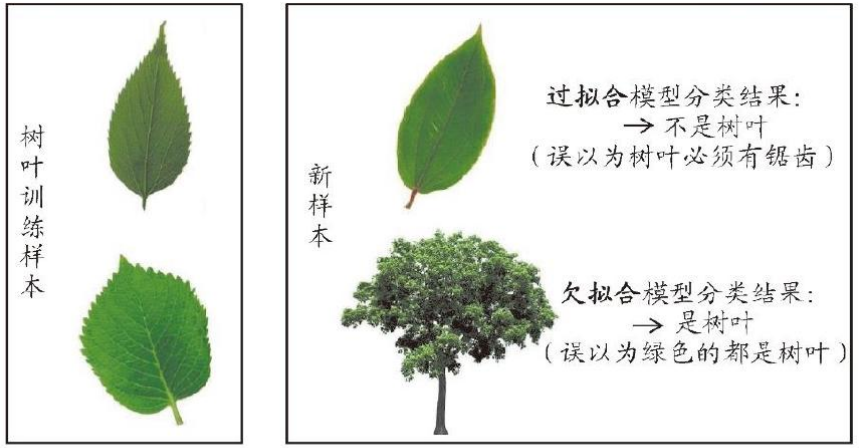


图 2.1 过拟合、欠拟合的直观类比

评估方法总览：测试集从哪来

- **三个关键问题：测试结果怎么来？性能怎么比？差别可不可信？**
- 测试集必须与训练集「互斥」——没见过的题才考得出水平
- 常见方法：留出法 / 交叉验证 / 自助法
- 破产数据：我们用的是分层留出 + 5 折交叉验证

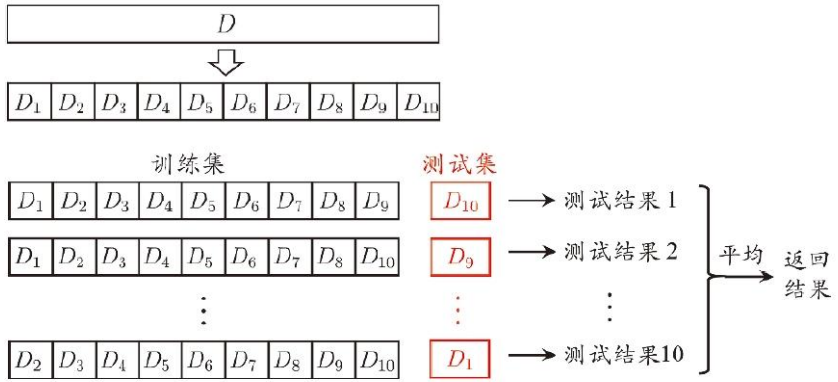


图 2.2 10 折交叉验证示意图

留出法（hold-out）

- **把数据按比例切两半：70% 训练 / 30% 测试**
- 注意：保持正负比例一致（分层采样）——破产组 3.23% 要同样分
- 多次重复划分更稳（随机划分 100 次取平均）
- 测试集不宜过大或过小（1/5 ~ 1/3）

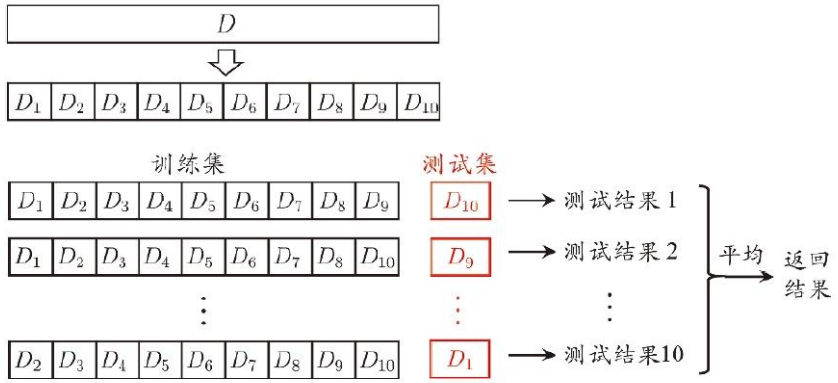


图 2.2 10 折交叉验证示意图

K 折交叉验证

- **把数据切成 K 份，轮流拿 1 份当测试、其余训练**
- K=5：每次用 80% 训练、20% 测试，跑 5 次取平均
- K=m（样本数）→ 留一法 LOO：每次只留 1 个样本
- 破产数据用 5 折：每个公司都被当过「新公司」考一次

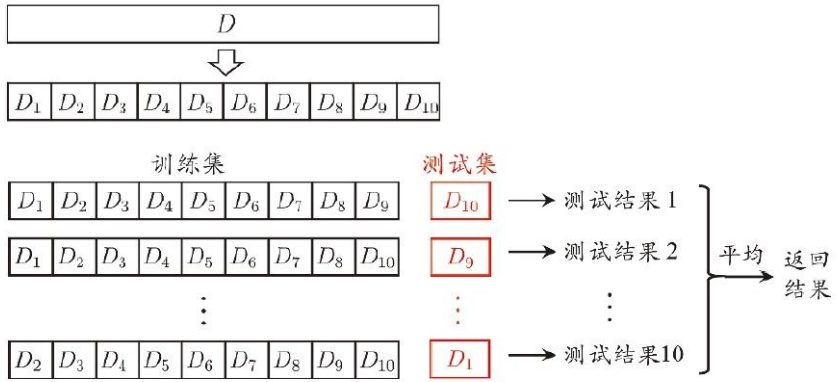


图 2.2 10 折交叉验证示意图

自助法（bootstrap）

- **有放回抽样：从原数据随机抽，可能抽到重复样本**
- 约 36.8% 的样本不会被抽到——这些就是「天然测试集」
- 训练集与原样本同规模，但分布略有改变
- 适用：数据量小时；破产数据 6,819 家足够大，不常用

训练集 / 验证集 / 测试集三分

- **训练集：学规律（作业）**
- 验证集：调参数（模拟考）——上午讲过
- 测试集：最终考一次（高考）——锁死不许碰
- 破产项目：调完树深度，最后才碰测试集

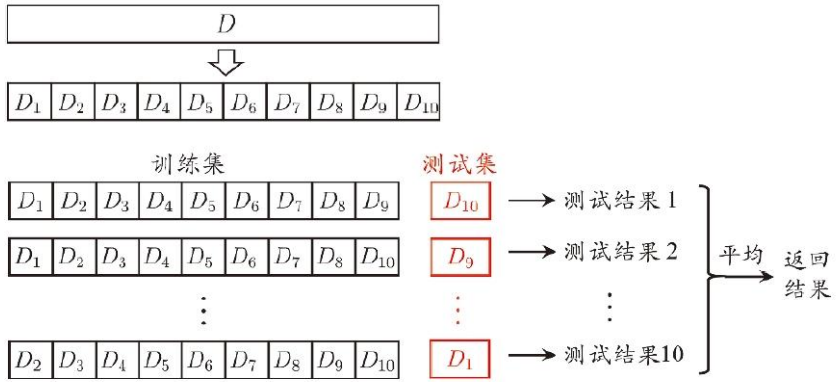


图 2.2 10 折交叉验证示意图

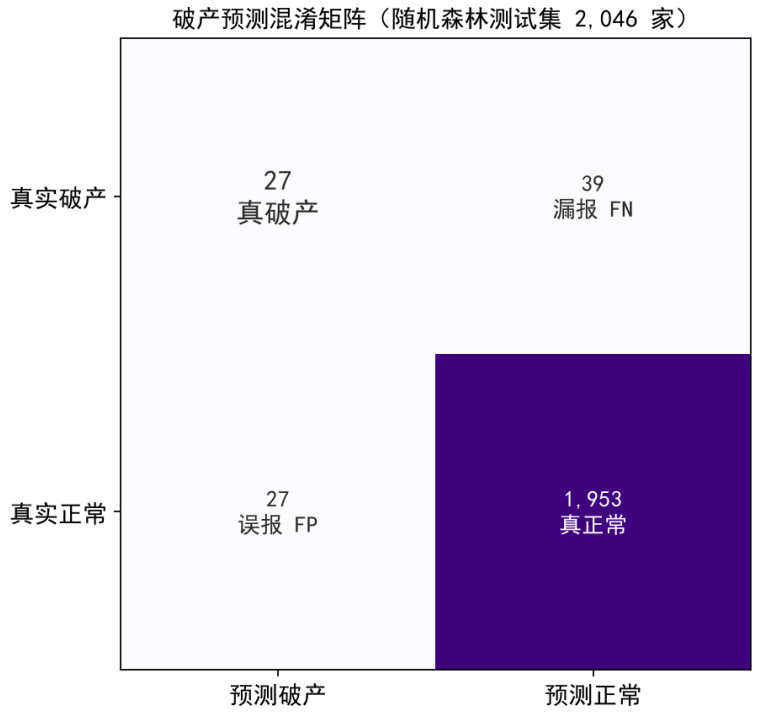
混淆矩阵：把预测结果摆进一张表

- **两行两列：实际 vs 预测，谁对谁错一目了然**
- TP：真破产，被判破产（正确）
- TN：真正常，被判正常（正确）
- FP：真正常，被判破产（误报）
- FN：真破产，被判正常（漏报——最危险）



破产数据上的混淆矩阵长什么样

- **假设模型预测 6,819 家：判 200 家破产、6,619 家正常**
- 真实：220 家破产，6,599 家正常
- TP=150，FN=70（漏掉 70 家真破产！）
- TN=6,519，FP=80（误报 80 家正常）
- 这张表是后面所有指标的地基



准确率 Accuracy：最直观也最会骗人

- **Accuracy = 猜对的 / 总数 = (TP+TN) / (TP+TN+FP+FN)**
- 破产数据：6,819 家里猜对 6,669 家 → 97.8%！
- 但 220 家破产只抓到 150 家 → 漏了 70 家
- 97.8% 很高，却可能一家真破产都拦不住——为什么？

$$\begin{aligned} \mathrm{acc}(f;D) &= \frac{1}{m}\sum_{i=1}^{m}\mathbb{I}\left(f\left(\boldsymbol{x}_i\right)=y_i\right) \\ &= 1-E(f;D)\ . \end{aligned}$$

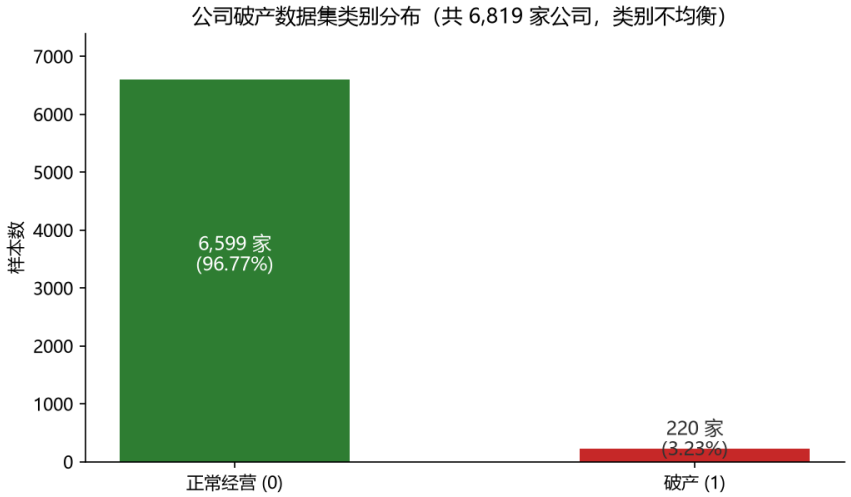
错误率 Error Rate：准确率的另一面

- **Error rate = 猜错的 / 总数 = (FN+FP) / C**
- 与 Accuracy 相加等于 1：猜对+猜错 = 全部
- 破产数据：猜错 150 家 → 错误率 2.2%
- 只看错误率同样会漏掉「错误的类型」

$$E(f;D)=\frac{1}{m}\sum_{i=1}^{m}\mathbb{I}\left(f\left(\boldsymbol{x}_i\right)\neq y_i\right)$$

为什么不均衡数据上准确率是骗人的

- **破产只占 3.23%：模型「全都判正常」就 96.77% 准确**
- 但这个模型一家破产都抓不到——毫无用处
- 准确率被「多数类」主导，少数类的表现被淹没
- 结论：数据不均衡时，要看针对少数类的指标



查准率 Precision：判成破产的，有多少是对的

- **Precision = TP / (TP+FP)——「你喊的都对吗」**
- 破产场景：判了 230 家破产，实际 150 家真破产 → 65.2%
- 高 Precision：抓得准，误报少
- 代价：宁可少判，也不要冤枉——适合「误报代价高」的场景

查全率 Recall：真破产的，抓到了多少

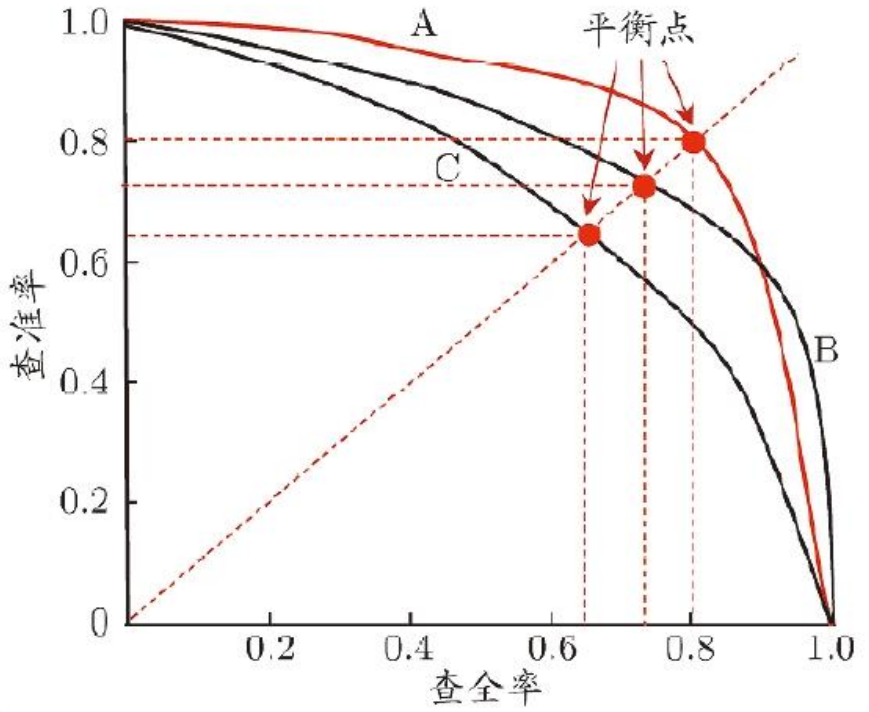
- **Recall = TP / (TP+FN)——「该抓的都抓到了吗」**
- 破产场景：220 家真破产抓到 150 家 → 68.2%
- 高 Recall：漏报少，危险分子都拦下
- 代价：可能误伤无辜——适合「漏报代价高」的场景
- 破产预测：漏报 ≫ 误报 → 优先保 Recall

一个表记住四个格子

	预测破产	预测正常
真破产	TP（正确拦截）	FN（漏报！最危险）
真正常	FP（误报）	TN（正确放行）

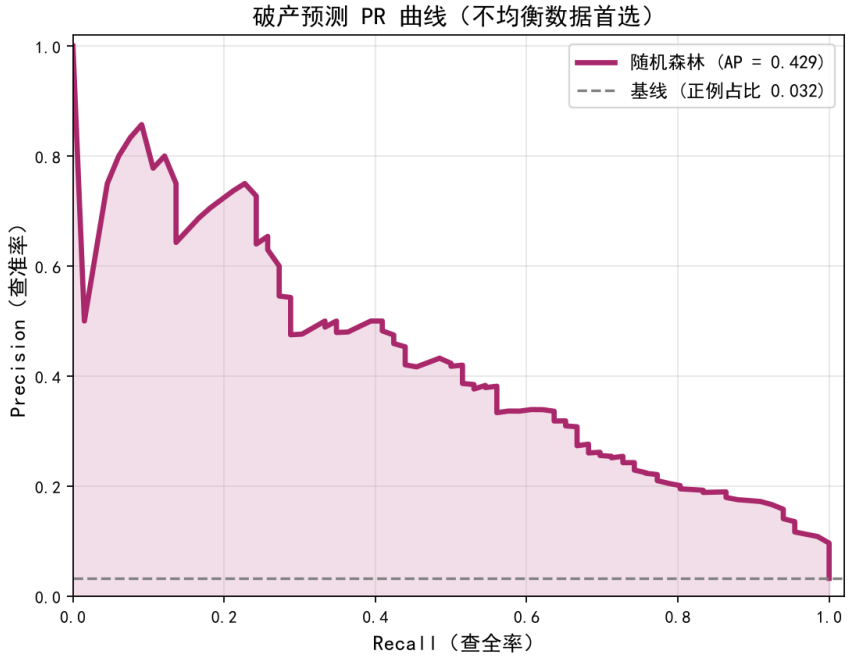
为什么不能同时拉满：Precision-Recall 权衡

- **阈值往严里调（>80% 才算破产）→ 判得少但准 → Precision 高，Recall 低**
- 阈值往松里调（>5% 就算破产）→ 判得多 → Recall 高，Precision 低
- 像跷跷板：一边上去另一边下来
- 破产场景：宁可误报也不能漏报 → 阈值往松调



PR 曲线：Precision-Recall 的全景

- **每个阈值算一个（Recall，Precision），连成曲线**
- 曲线越靠右上越好
- 破产数据：少数类（破产）识别能力看 PR 曲线最真实
- PR-AUC = 曲线下面积：不均衡数据的首选对比指标



F1：查准率与查全率的综合分

- **F1 = 2 × (P × R) / (P + R)——调和平均**
- 两边都重要、又要一个数时用 F1
- 破产场景：F1 用于「模型比武表」的主排序指标
- 调和平均的脾气：P 和 R 差太远，F1 就低

$$F1 = \frac{2 \times P \times R}{P + R} = \frac{2 \times TP}{\text{样例总数} + TP - TN}$$

Fβ：给查全率加权重

- $F\beta = (1+\beta^2) \times (P \times R) / (\beta^2 \times P + R)$
- β>1：更看重 Recall（漏报贵）——破产场景
- β<1：更看重 Precision（误报贵）
- F1 是 β=1 的特例

$$F_\beta = \frac{(1+\beta^2) \times P \times R}{(\beta^2 \times P) + R}$$

宏平均 vs 微平均：多个混淆矩阵怎么合并

- **宏平均：每个类算指标再取平均——每个类地位相等**
- 微平均：把混淆矩阵加起来再算——大类的表现主导
- 多分类、多次训练时用
- 破产二分类：一般不用，了解即可

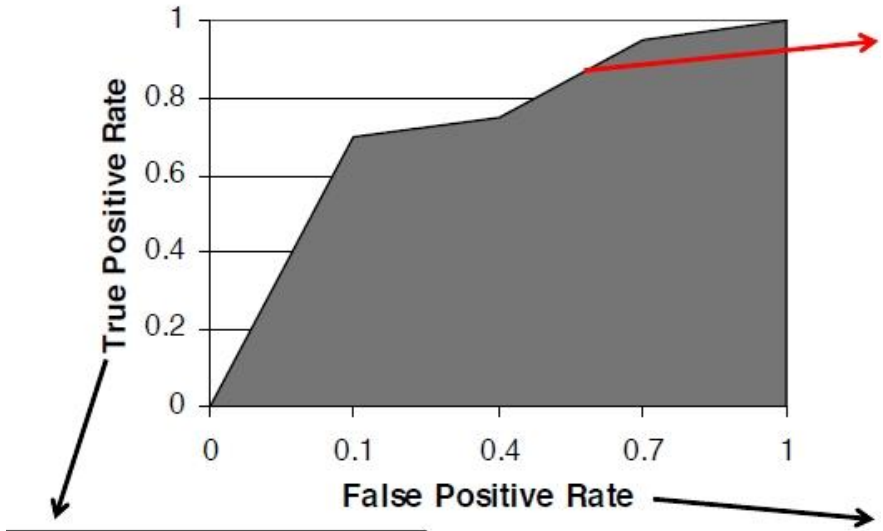
$$\text{macro-}P = \frac{1}{n}\sum_{i=1}^{n} P_i \ ,$$

$$\text{macro-}R = \frac{1}{n}\sum_{i=1}^{n} R_i \ ,$$

$$\text{macro-}F1 = \frac{2 \times \text{macro-}P \times \text{macro-}R}{\text{macro-}P + \text{macro-}R} \ .$$

ROC 曲线：换一种视角看模型

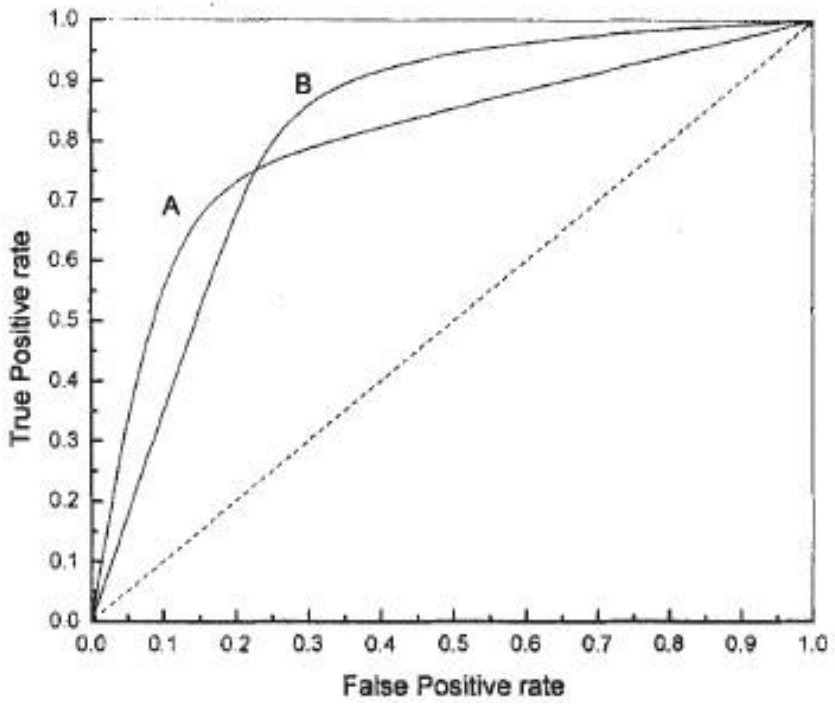
- **两个新指标：TPR（真例率）、FPR（假例率）**
- TPR = TP / (TP+FN)——与 Recall 是同一个数！
- FPR = FP / (FP+TN)——误报率
- 每个阈值算一个 (FPR, TPR)，连成 ROC 曲线
- 破产场景：TPR 想把破产都抓出来，FPR 不想冤枉正常



$$tpr = \frac{TP}{TP + FN} = \frac{TP}{m_+}$$

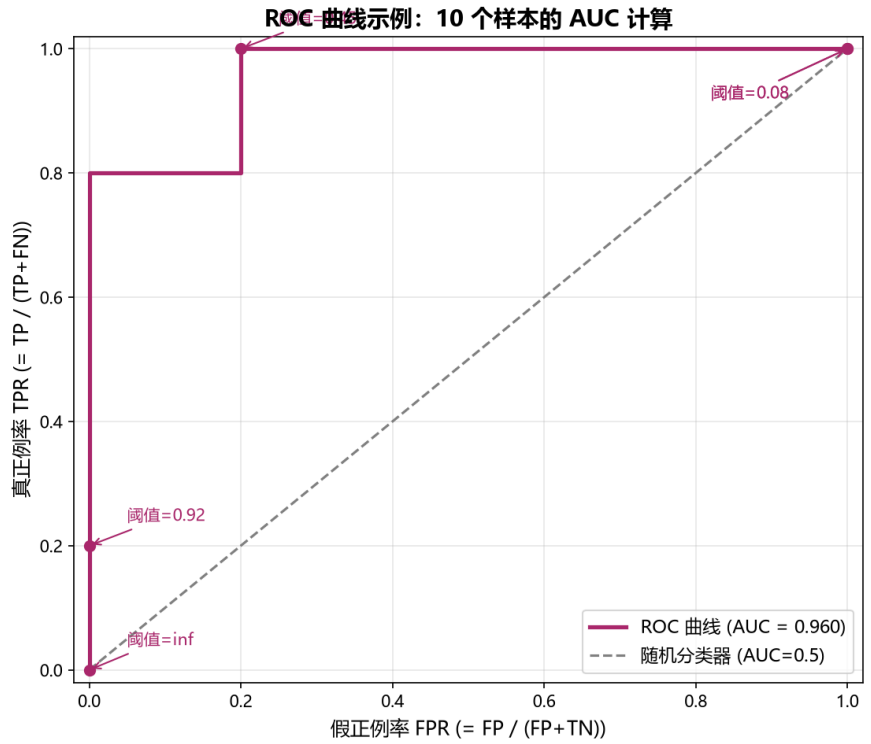
怎么看 ROC 曲线

- **横轴 FPR、纵轴 TPR；曲线越靠左上越好**
- 对角线 = 随机猜测（和抛硬币一样）
- 破产模型：曲线高高翘起 ➡ 显著优于随机
- 左上角那个点：TPR 高且 FPR 低的完美状态



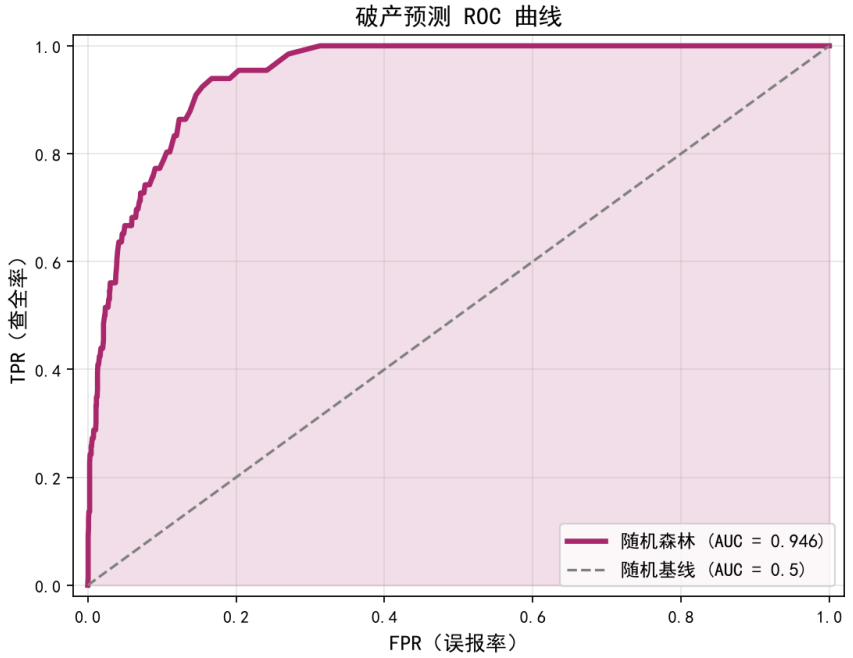
AUC：曲线下面积的数字版

- **AUC = ROC 曲线下方的面积**
- 范围 0.5（随机）~ 1.0（完美）
- AUC=0.96 的直觉：随机抽一对（破产 vs 正常），96% 概率模型能把破产排前面
- 与阈值无关：AUC 衡量「排序能力」，不看具体阈值



破产数据上的 ROC 曲线（真实绘制）

- 用上午训练好的模型在测试集上画 ROC
- AUC ≈ 0.9x：模型对破产/正常有很好的排序能力
- 对比随机基线（对角线）
- 这张图就是「模型比武表」里 AUC 那列的数字来源

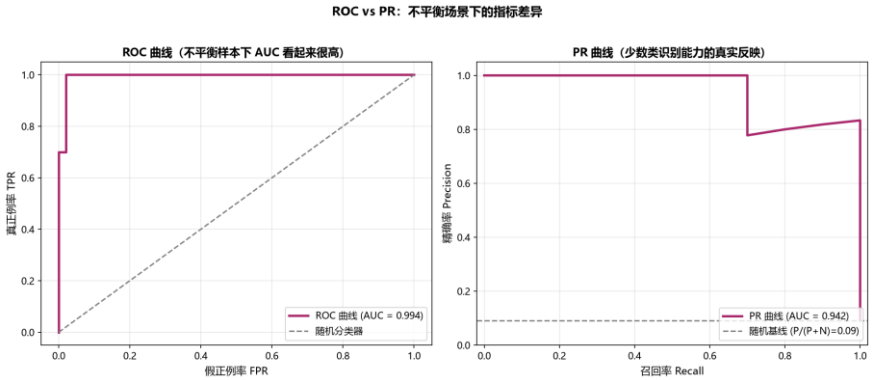


AUC 的两个重要性质

- **性质 1：对类分布不敏感——FPR 只看负例、TPR 只看正例**
- 性质 2：与决策阈值无关——换阈值曲线不换
- 破产数据 3.23% 极不均衡：AUC 仍可横向对比模型
- 注意：类分布极端时，AUC 会「虚高」，需配 PR-AUC 一起看

ROC-AUC vs PR-AUC：什么时候用哪个

- **均衡数据：ROC-AUC 足够**
- 极度不均衡（如破产 3.23%）：PR-AUC 更真实
- 原因：ROC 里 FPR 分母很大（6,599 正常），假阳被稀释
- 破产对比模型：PR-AUC 为主，ROC-AUC 作参考



三个核心决策维度

- **维度 1 标签分布：正负样本比例，决定哪些指标会失效**
- 维度 2 错误代价：误报 vs 漏检哪个更贵，决定保 P 还是保 R
- 维度 3 评估目标：要排序能力（阈值无关）还是要落地决策（阈值相关）

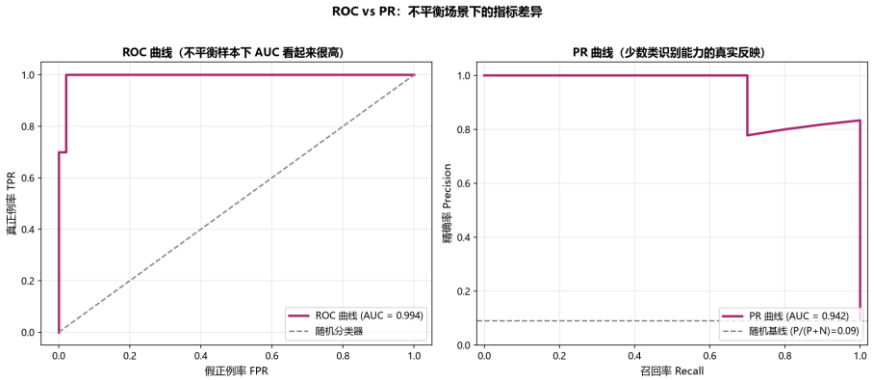


各指标适配一张表

指标	标签分布	错误代价	排序?	破产场景
ROC-AUC	均衡；不平衡辅助	对称	是	参考指标
PR-AUC	极度不平衡首选	不对称	是	模型对比主力
Recall	不限，常用于不平衡	漏检≫误报	否	业务落地主力
Precision	不限	误报≫漏检	否	辅助
F1	均衡/轻度不平衡	对等	否	比武排序
Accuracy	严格均衡	完全对等	否	破产场景禁用

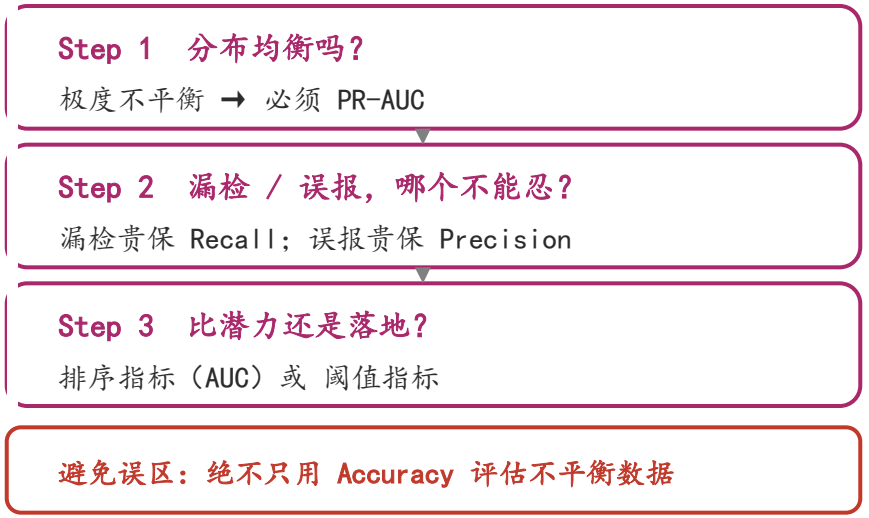
破产识别的指标组合（重点页）

- **场景：正样本 3.23%，漏检代价 ≫ 误报**
- 模型对比阶段：PR-AUC 为主，ROC-AUC 作参考
- 业务落地阶段：Recall 为主，Precision 辅助
- 一句话：先看分布，再看代价，最后选主指标



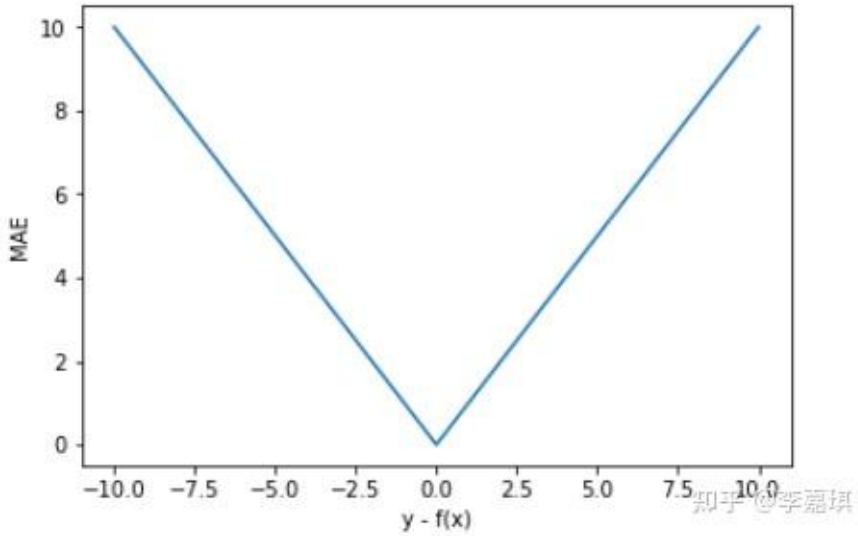
选择指标的决策流程

- **Step 1：分布均衡吗？→ 极度不平衡必须 PR-AUC**
- Step 2：漏检和误报哪个不能忍？→ 漏检贵保 Recall，误报贵保 Precision
- Step 3：比潜力还是落地？→ 排序指标 or 阈值指标
- 避免误区：永远不要只用 Accuracy 评估不平衡数据



回归任务的指标：MSE 均方误差

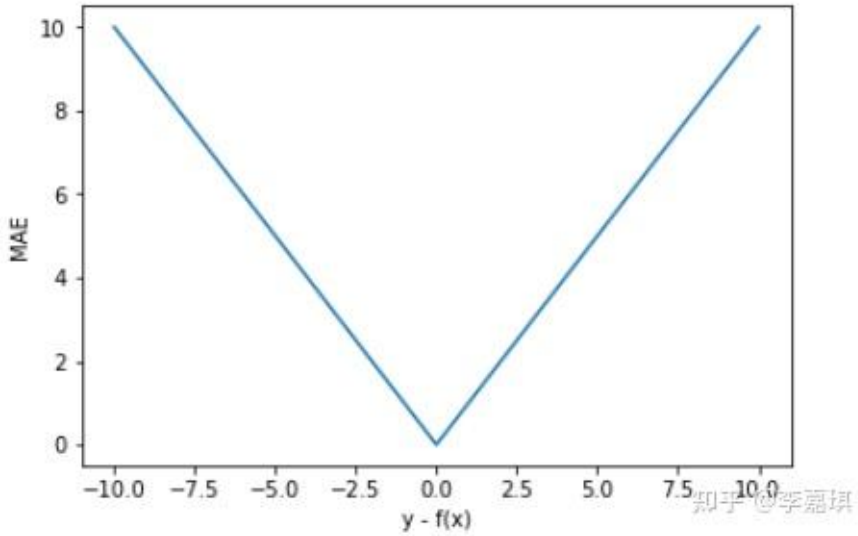
- **MSE = 预测值与真实值差的平方求平均**
- 惩罚大误差：差 10 的平方是 100，差 1 的平方是 1
- 破产延伸：预测违约概率时衡量偏差
- 缺点：对离群点敏感



知乎@李嘉琪

MAE 平均绝对误差

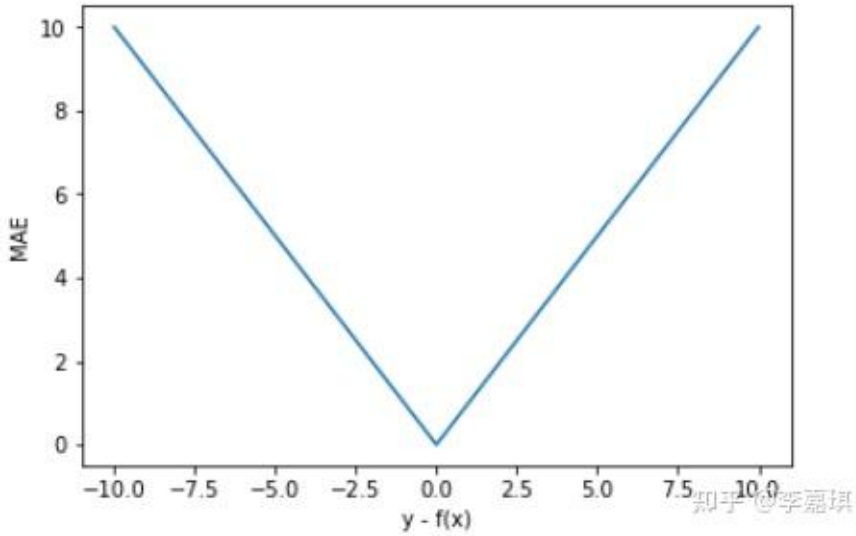
- **MAE = 预测值与真实值差的绝对值求平均**
- 比 MSE 对离群点更宽容
- 缺点：在 0 点不可导，求解困难
- 两者都要时：MSE 放大异常，MAE 更稳健



知乎 @李嘉琪

R^2 决定系数

- **R^2 = 1 − 残差平方和 / 总平方和**
- 解释：模型解释了数据多少比例的波动
- R^2=1 完美，R^2=0 不如直接用均值
- 破产延伸：预测股价/评分这类连续值用



知乎@李嘉琪

Grid Search：自动调参

- **超参数多时，手调不现实**
- Grid Search：把每个参数的所有候选组合都跑一遍
- 例：树深 3 种 × 叶节点 4 种 = 12 次训练
- 破产项目：调树深度、森林棵数用网格搜索



比较检验：模型差别可不可信

- **两个模型 F1 差 0.02，是真的差还是随机波动？**
- 两学习器：交叉验证 t 检验、McNemar 检验
- 多学习器：Friedman + Nemenyi 后续检验
- 破产比武：AUC 差 0.005 不显著，别被小数点骗了

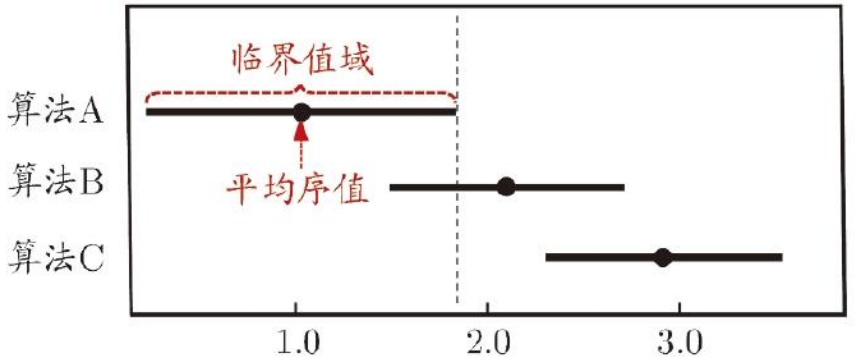


图 2.8 Friedman 检验图

偏差-方差窘境

- **偏差：模型太简单，系统性地学不准**
- 方差：模型太复杂，数据稍微变就大起大落
- 训练不足 → 偏差主导；训练过度 → 方差主导
- 破产场景：浅树偏差大，深树方差大——剪枝就是在权衡

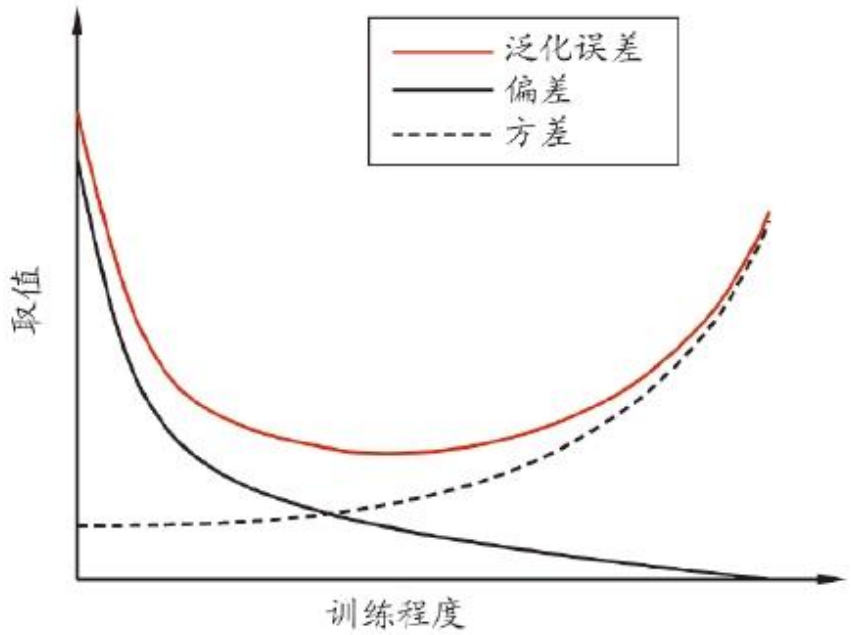


图 2.9 泛化误差与偏差、方差的关系示意图

小结：一页记住指标怎么选

情况	主指标
数据均衡、代价对称	Accuracy / F1 / ROC-AUC
极度不均衡	PR-AUC
漏检贵（破产/欺诈）	Recall
误报贵（营销/风控拦截）	Precision
都要一个数	F1

04

实机演示：两个数据集

破产预测 + 财务舞弊

演示安排：同一套流程跑两遍（Orange + WorkBuddy 双轨）

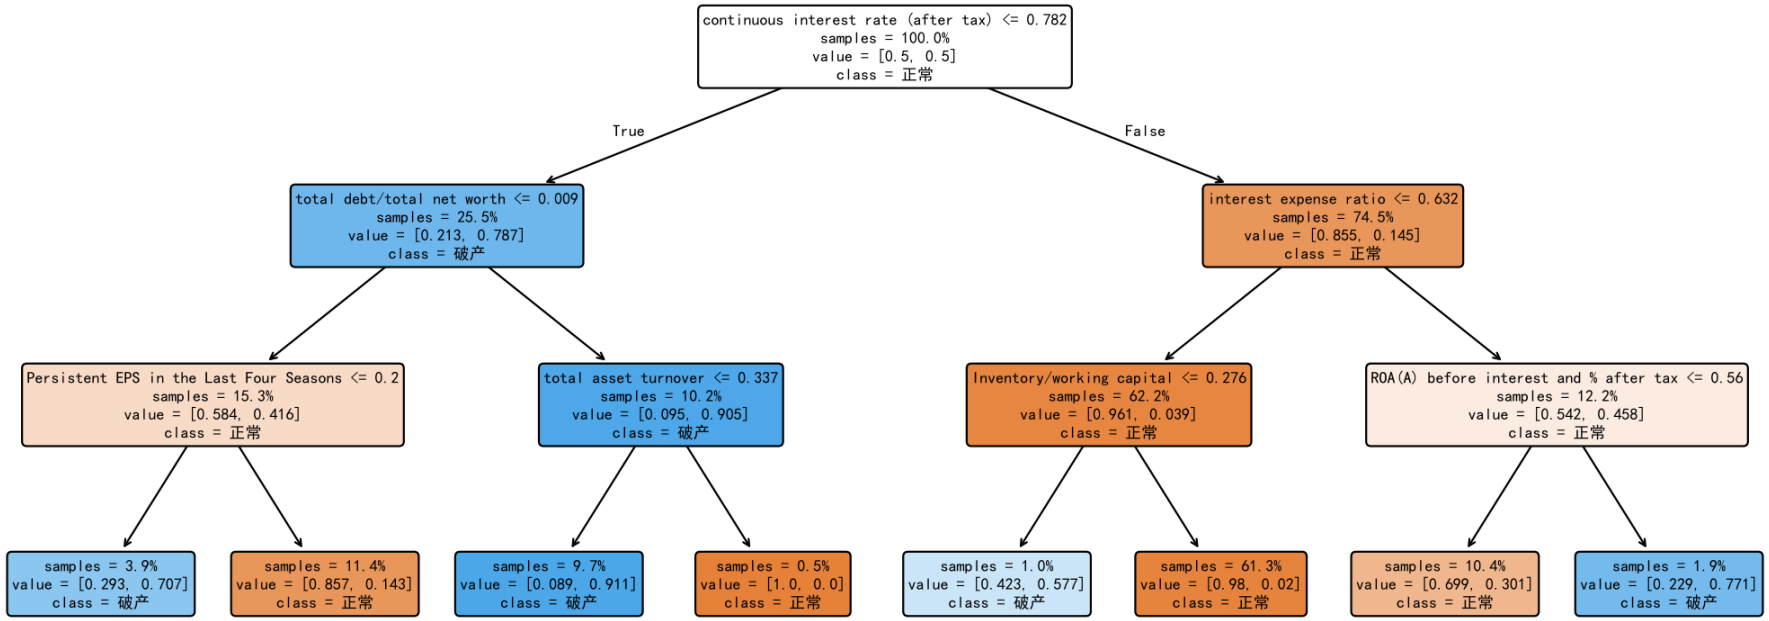
- **第一遍：破产预测数据集（先导公开课用过的数据）**
- 第二遍：财务舞弊数据集
- 两遍流程完全相同：训练 → 画树 → 读图 → 看特征重要性
- 工具分工：Orange 拖组件主演示（上午刚学会），WorkBuddy 同步对照跑一遍
- 对比才是重点：两个任务看重的指标不一样

数据集一：破产预测

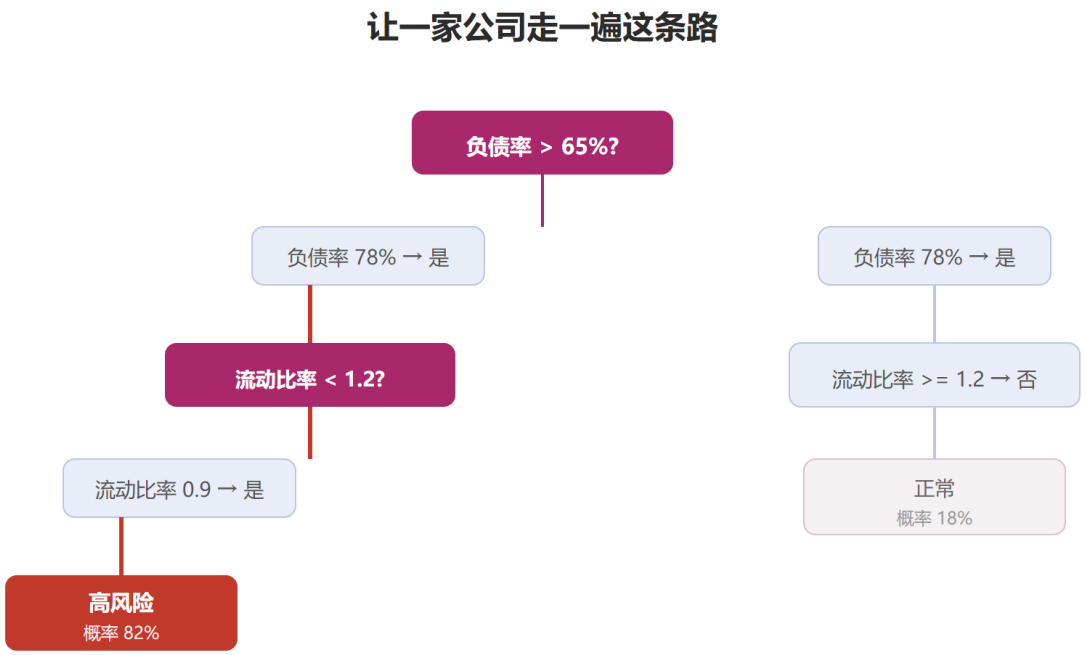
- **来源：台湾经济新报（UCI），先导公开课已用过**
- 规模：6,819 家公司 × 95 个财务比率
- 标签 Bankrupt?：1 = 破产（220 家，3.23%）
- 特征：95 个财务比率，建模前做特征选择

★ 把树画出来

破产预测：决策树（深度 3）—— 每一层都在问"负债率、偿债能力够不够"



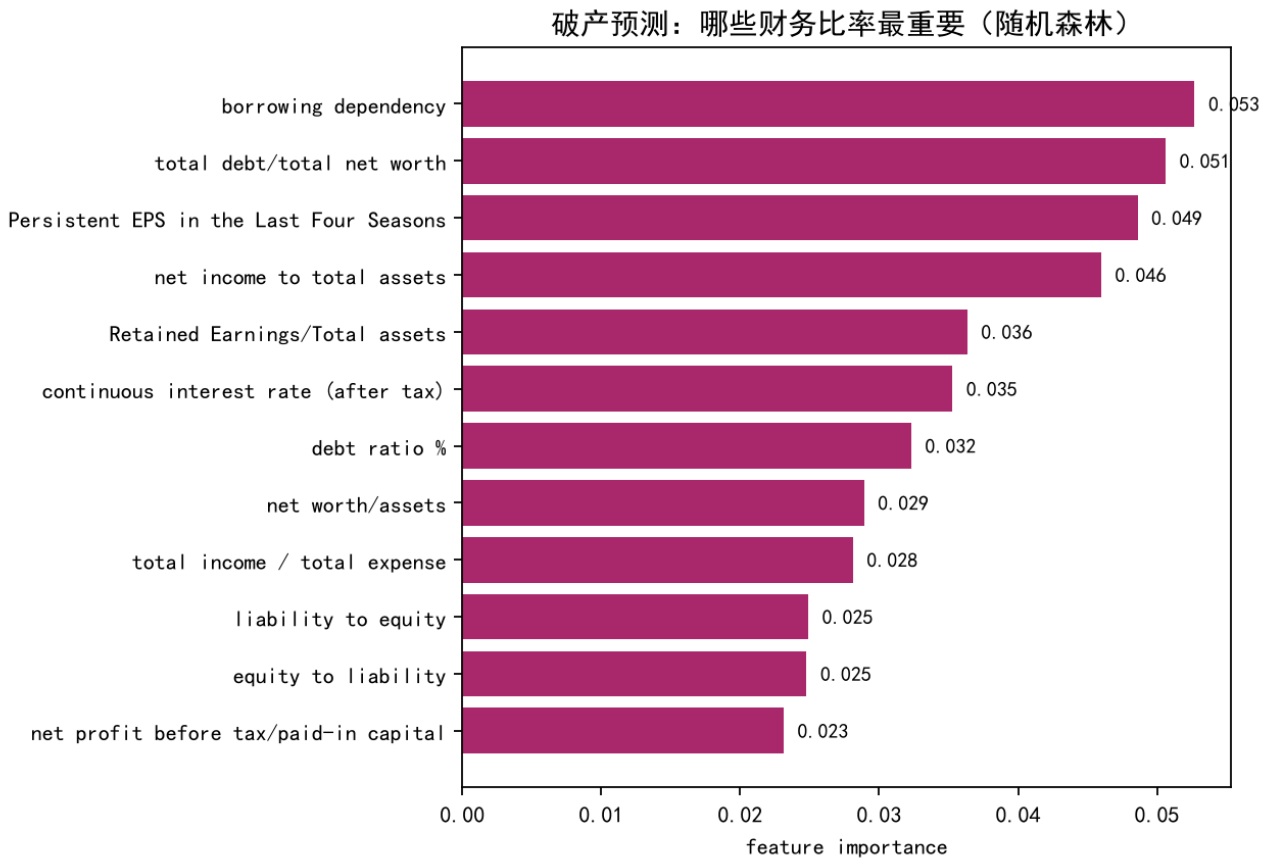
让一家公司走一遍这条路



这家公司被判高风险，是因为负债率 78% 且流动比率 0.9——能说出来

这就是可解释：不是黑箱给个分数，而是把判断依据一路指给你看

哪些变量最有用


破产预测：哪些财务比率最重要（随机森林）
borrowing dependency
total debt/total net worth
Persistent EPS in the Last Four Seasons
net income to total assets
Retained Earnings/Total assets
continuous interest rate (after tax)
debt ratio %
net worth/assets
total income / total expense
liability to equity
equity to liability
net profit before tax/paid-in capital
0.053
0.051
0.049
0.046
0.036
0.035
0.032
0.029
0.028
0.025
0.025
0.023
0.00
0.01
0.02
0.03
0.04
0.05
feature importance

单棵树 vs 森林：这笔交易值不值

P38 期望产出："模型比武表"（示意，数值待直播实跑填充）

模型	准确率	查准率	查全率	F1	AUC
逻辑回归	—	—	—	—	—
决策树	—	—	—	—	—
随机森林	—	—	—	—	—
梯度提升树	—	—	—	—	—
SVM (RBF)	—	—	—	—	—

统一评估协议：分层 5 折 CV • 类别权重 balanced • random_state=42 • 全程未碰测试集

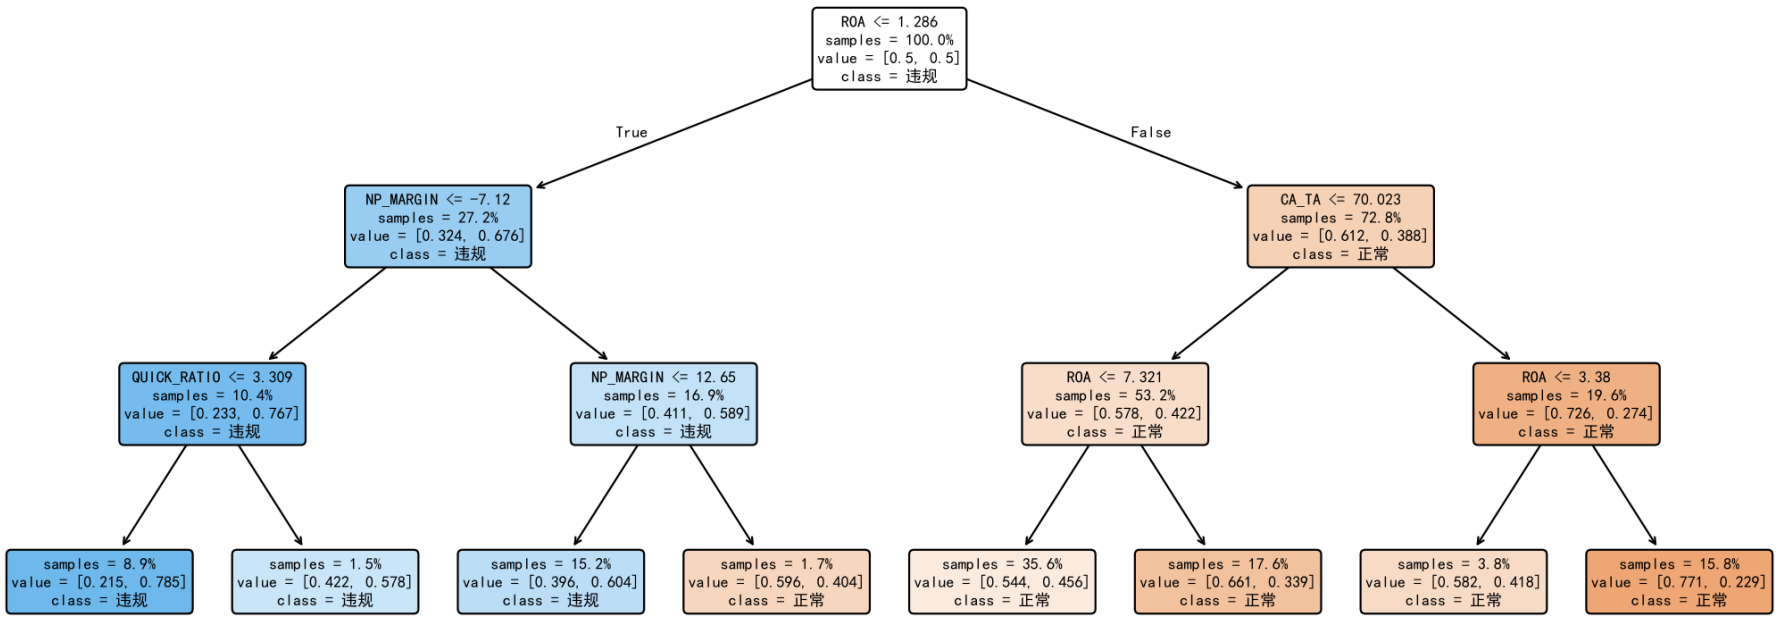
排序依据用 **F1**（不是准确率）——因为破产样本只占 3.23%

数据集二：财务舞弊

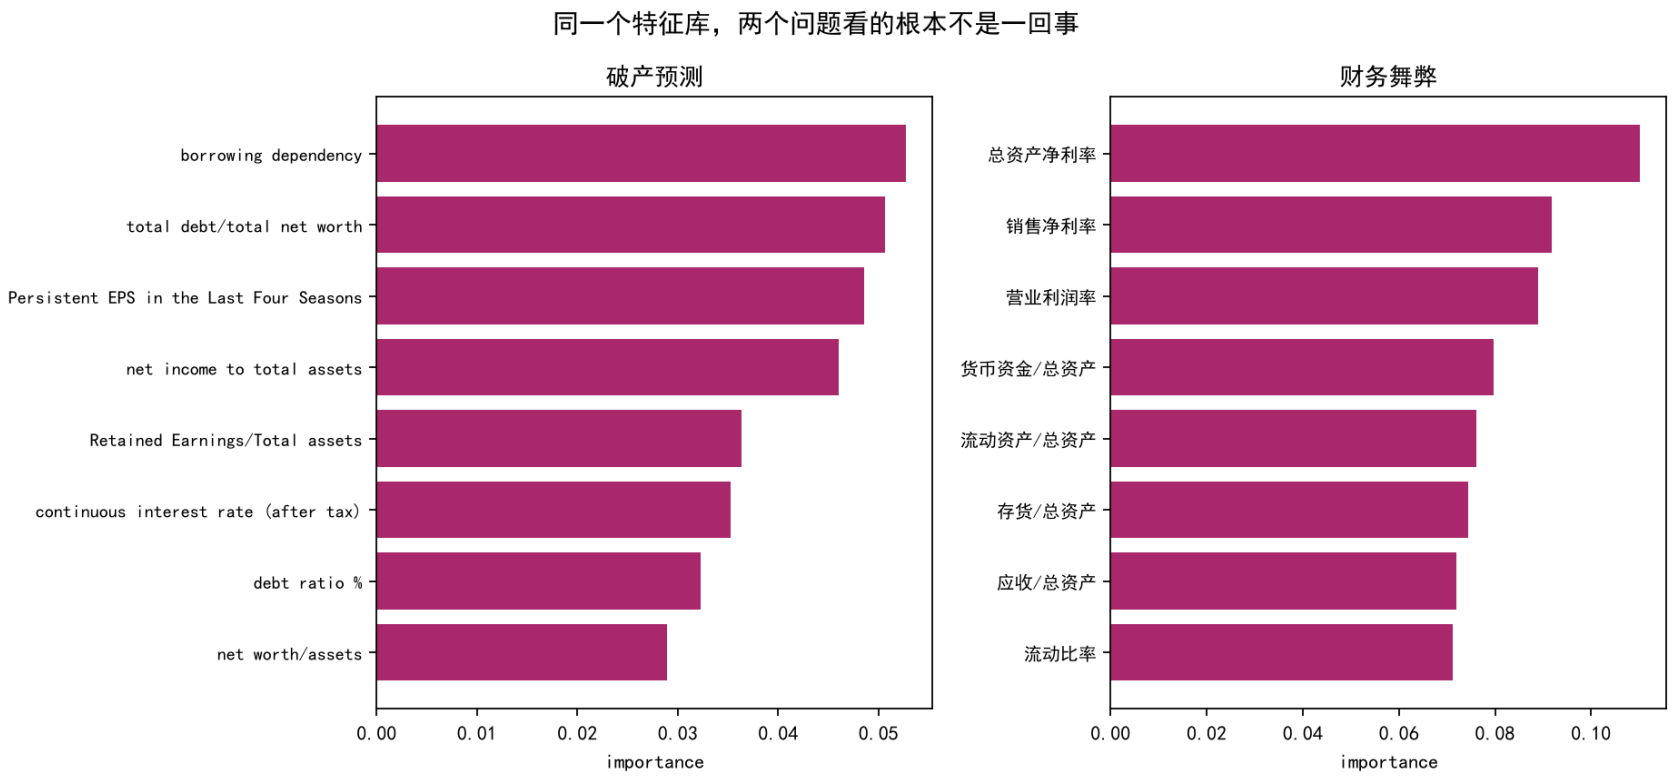
- fraud_panel_2014_2023.csv：34,654 个公司—年度观测 × 13 个财务比率
- 标签 VIOLATED：1 = 当年有违规处罚记录（2,547 家，7.35%）
- 来源：国泰安 CSMAR——违规表 + 利润表 + 资产负债表拼接
- 特征侧重：盈利能力（ROA / 净利率）与应收、存货、现金流质量
- 难点：造假会刻意模仿正常公司，信号比困境更隐蔽

同一套流程，再跑一遍

财务舞弊：决策树（深度 3）—— 先看盈利质量，再看应收与存货



★ 两个任务，看的根本不是一回事



树模型的边界：它能说什么、不能说什么

- **能说：这家公司因为哪些指标被判高风险**
- 不能说：把负债率降低就能避免困境
- 特征重要性 ≠ 因果效应——这是最容易讲错的一句话
- 结论：它给的是线索，不是处方

05

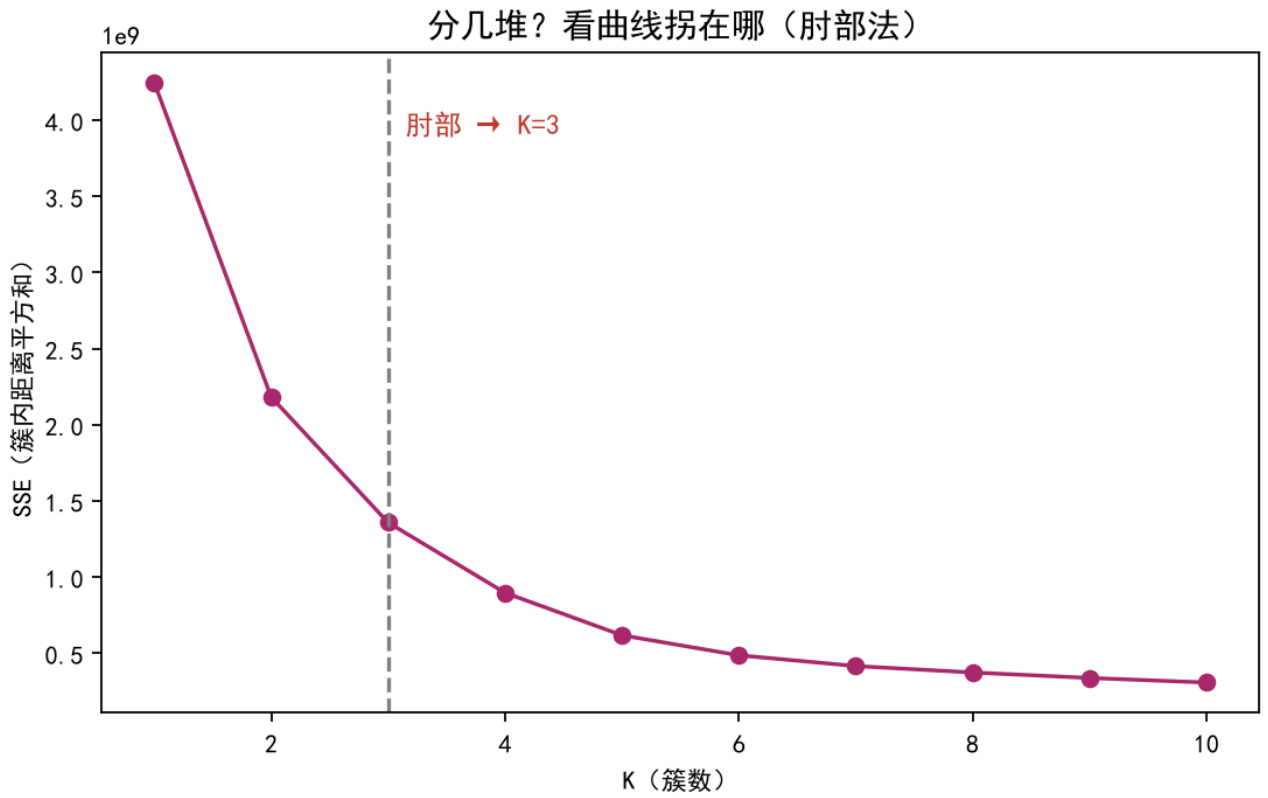
聚类

K-Means • 肘部法 • 簇画像

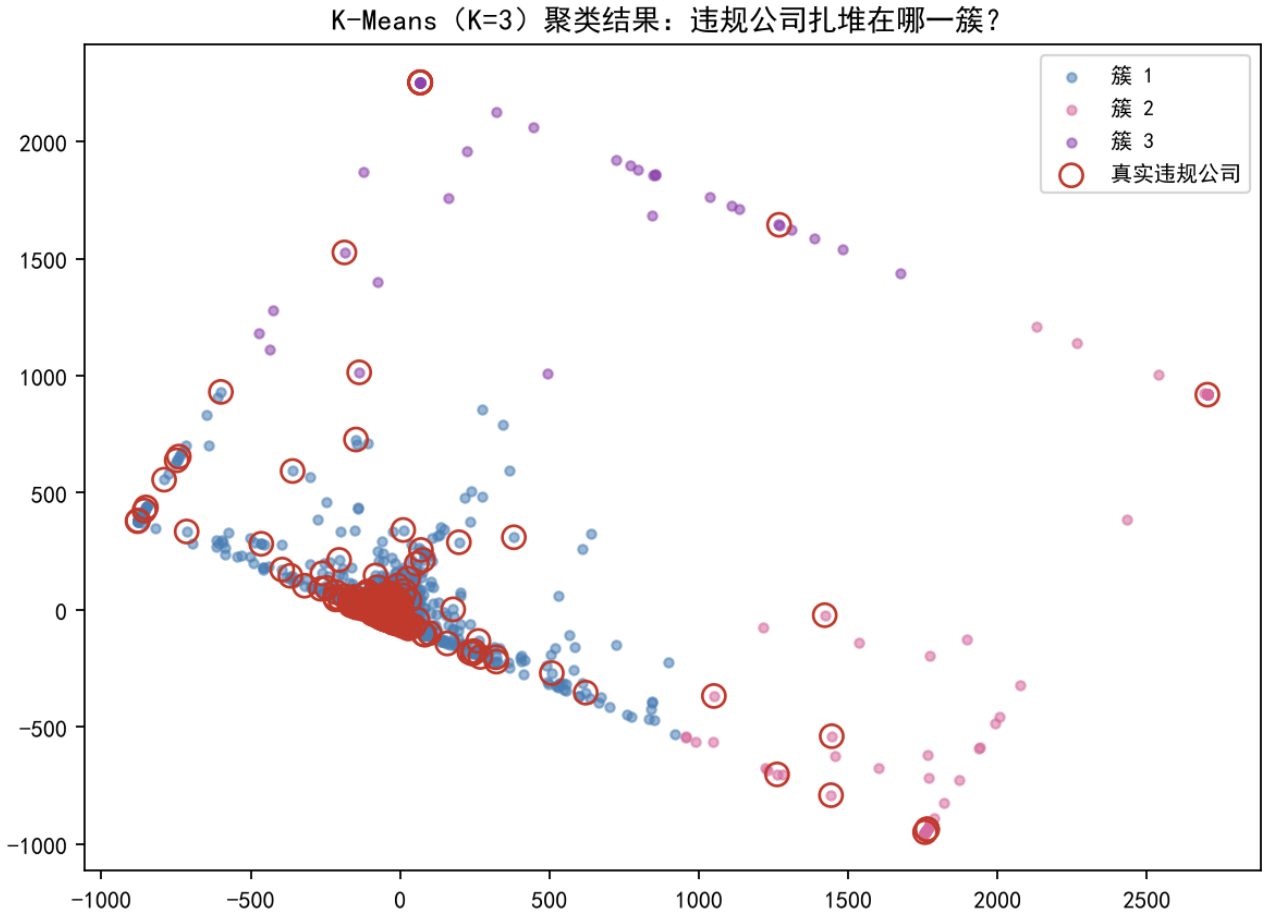
换个问法：不看标签会怎样

- **前面问的都是「它是不是高风险」，这是有监督的学习**
- 现在换个问法：这些公司自己会长成几堆？
- 聚类不预先知道答案，只看谁跟谁长得像
- 用途：客户分群、异常发现、做研究前的分组探索

K-Means：怎么分、分几堆



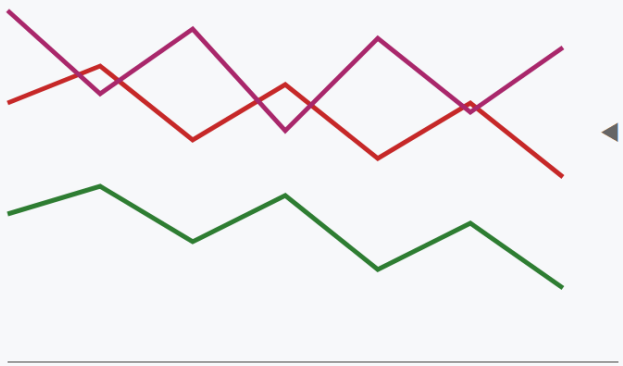
把聚类结果画出来


K-Means（K=3）聚类结果：违规公司扎堆在哪一簇？
簇 1
簇 2
簇 3
真实违规公司
2000
1500
1000
500
0
-500
-1000
-1000
-500
0
500
1000
1500
2000
2500

每一堆都是什么样的公司

聚类应用之二：把"涨跌同步"的股票聚到一起

原始输入：每天每只股票的涨跌



没有"板块"标签，只有每日涨跌记录

◀ 涨/跌　聚类

聚类结果：涨跌同步的股票成团



聚类后我们才"回过头"给它们起名字

用途：组合分散风险 · 发现"看起来无关其实同涨同跌"的隐性板块

06

小结与课后任务

两种视角

小结：树与簇给我们的两种视角

- **树回答：这家公司会不会出事，为什么**
- 簇回答：这些公司天然分成几类，每类长什么样
- 共同点：都能画出来给业务经理解释
- 明天：我们用同样「能解释」的思路，去读年报里的文字