LLM

HTML

LLM 判读 + 项目 HTML 交付

下午 • 让 LLM 读懂意思，把三天的成果做成一个能打开的链接

Day 3 下午 • 180 min • LLM 分析文本与图片 • 发布项目 HTML

深圳大学 • 经济学院

主讲：杨楷

kindyang.github.io

00

开场

下午两件事：LLM 判读 + 双页面项目

下午两件事

- **前半场：换个做法，不训练模型，直接让 LLM 去读**
- 后半场：大家一起完成一个双页面项目，推到 GitHub 上
- 页面一「重点关注公司」：舞弊模型打分 + 特征可视化
- 页面二「文本画像」：MD&A 词云 + 主题聚类 + 文化维度
- 今天的课结束时会有一个能打开的链接

01

LLM 判读

读懂意思，也要留证据

范式转变：不再数词了

两种范式

旧范式：数词

分词 | 计数 | 加权 | 向量 | 模型

特征由人定义
模型只做统计

对文本的理解停留在
「哪些词出现得多」

优点：快、便宜、可复现
弱点：读不出言外之意

范式转变

新范式：读懂意思

① 原文直接给 LLM

② 按提示词输出结构

③ 答案必须附带证据

特征由模型自己形成
优点：能理解语境与语气
弱点：贵、慢、会一本正经地错

不是谁取代谁，而是能说清证据的那个更可信

但有一条规矩不能破

- **LLM 用起来方便，不代表它可以不负责任**
- 每条结论必须能追回原文，不能有头无尾
- 上午说的那套证据留痕要求依然不变：它也要 inspection
- 找不到依据时，必须输出缺失

一条合格的抽取结果长什么样

一条合格的抽取结果

① 证据原文 (逐字引用，不得改写)	「持续加大研发投入，2024 年研发费用同比+23%」
② 位置	年报第 32 页 · MD&A 第 3 段
③ 抽取状态	未提及　是合法答案，不许让它猜
④ 模型版本	模型名 + 版本 + 调用日期
⑤ 提示词版本	prompt v1.2，2026-10-17

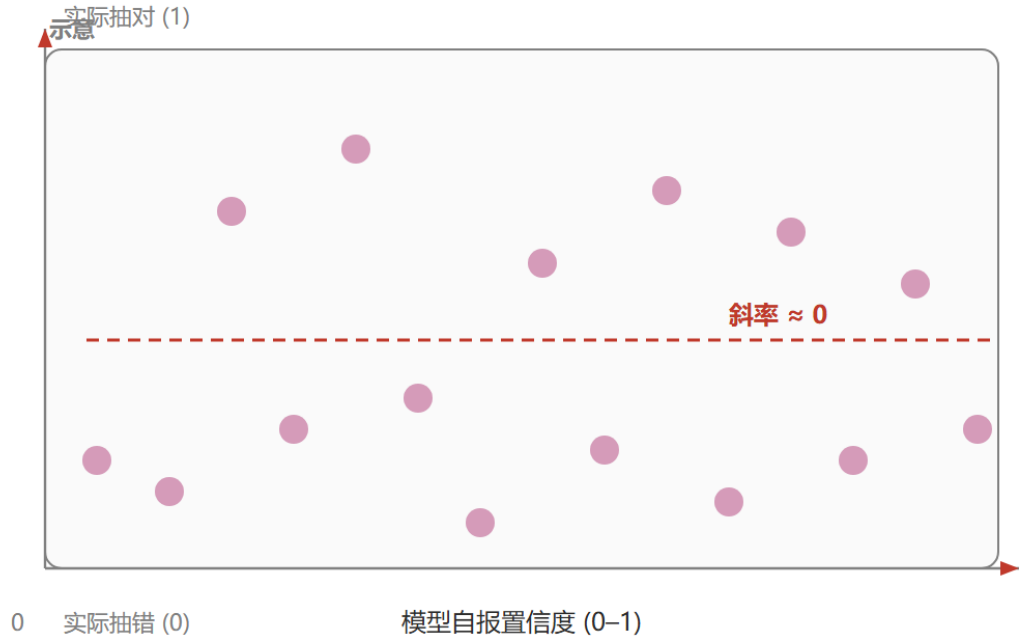
没有原文的
一律不算证据

「未提及」也是有价值
的结果，不是失败

缺任何一项，
这条记录不合格

为什么不用它自报的置信度

模型自报的置信度，能信吗?



自报 0.95 也可能错

自报 0.6 也可能对

可信度只能来自三样:

① 可核查的原文

② 多次抽取的一致性

③ 人工核验的通过率

提示词怎么构造

- **第一块：给它角色与任务边界**
- 第二块：给出维度定义与评分口径
- 第三块：硬性规定必须输出原句、页码、状态
- 第四块：明确说找不到就输出缺失，不许猜

演示：让 LLM 读一段年报

用 WorkBuddy 控制 ML 全流程：每一步都是"精准提示词 + 确认门"

1 业务理解
目标是什么?
漏报 vs 误报谁代价大?
成功标准先定好

2 数据理解
多少行/列？标签是什么?
缺失、异常、脏数据
"只出报告，不要建模"

3 数据准备
清洗规则逐条写明
缺失填充 · 标准化
"每步先说明再执行"

4 建模控制
指定算法与参数
划分方式 · 不均衡处理
"先别碰测试集"

5 评估解读
指定指标：F1/AUC
混淆矩阵必看
用业务语言解释

人在环中（Human-in-the-loop）：每步之间设"确认门"

提示词四要素：① 背景（数据与业务） ② 任务（做什么、不做什么） ③ 约束（方法/参数/指标） ④ 输出（形式与交付物）

关键技巧：分步执行、先报告后动手、限定指标、要求解释、可复核的中间产物

模糊提示词（AI 自由发挥，结果不可控）

"帮我预测哪些公司会财务舞弊"

→ 它可能随便选模型、不做清洗、报告一个 99% 准确率的假象

精准提示词（每一步都可控、可复核）

"FLAG 为标签；先出缺失率报告不要建模；类别权重 balanced；
分层 70/30 划分；报告召回率与 F1，不要只报准确率"

→ 过程透明，每步可纠正，结论可信

演示的结果要怎么验

- **第一步：拿模型返回的原句回年报里搜，看是不是真有这句话**
- 第二步：检查页码对不对
- 第三步：判断它的评分跟原句意思是否一致
- 三步都过了，这条才算通过

抽样核验怎么设计

抽样核验三件事

抽多少

成本—精度权衡：样本越多越准，但人工成本上升

推荐：10% 或最少 50 条（先小后大，不够再补）

怎么判

① 正确　② 错误　③ 无法判断

三分类，不要二分类——「无法判断」要单独统计

怎么记

编号	判定	备注

C012 正确 原句与年报一致

C013 无法判断 原文未提及该维度

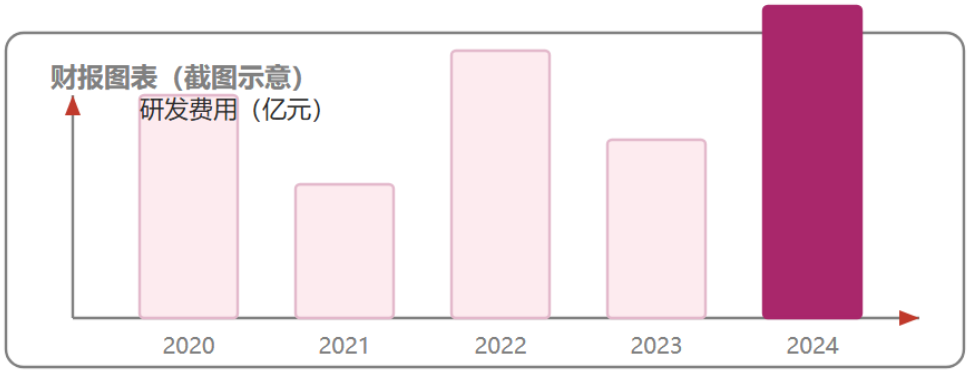
抽样的目的不是证明模型对，而是知道它错在哪、错多少

LLM 也能读图

- **财报里很多信息在图上：趋势图、结构图、扫描件**
- 多模态模型可以直接读图，不用先 OCR
- 好处：省掉 OCR 这个容易出错的中间环节
- 代价：贵，而且同样要把结果追回原图

演示：把一张图丢给它

把一张图直接丢给多模态模型



把图直接丢给它

模型输出的结构化结果（示意）

研发费用 2024 = 140 亿，为五年最高，同比 +75%

趋势判断：持续上升

单位：人民币亿元

证据：2024 年柱形，坐标轴图例，P1 图表标题

读图时必须问清三件事

① 单位与量级

② 坐标轴起止范围

③ 图上文字是否为原始标注

结论同样要指出：

图上哪一处支持了这个判断

适用边界：

清晰的矢量图很准；模糊的扫描件、手写体、密集小表格都不行

02

双页面项目制作

页面一：重点关注公司 • 页面二：MD&A 文本画像 • LDA 主题聚类

先看成品长什么样

- **一个 GitHub Pages 站点，两个页面**
- 页面一「重点关注公司」：舞弊模型打分 + 特征可视化
- 页面二「文本画像」：词云 + 主题聚类 + 文化维度
- 每一块都能点开看到证据出处

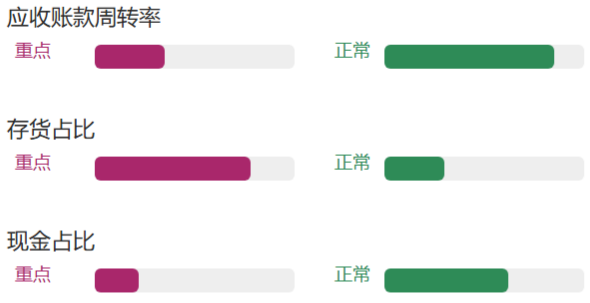
页面一整体样板

重点关注公司 · 基于舞弊模型打分（2026 最新年报）

① 重点关注公司

排名	公司	舞弊指数	风险等级	主要异常特征
1	平安银行	0.87	高	应收激增
2	ST 华业	0.82	高	存货异常
3	康得新	0.78	高	现金存疑
4	正常公司A	0.21	低	—

③ 特征可视化



红色为异常方向，绿色为健康方向

⑤ 数据来源与口径：历史舞弊公司训练模型 + 巨潮最新年报，证据见 CLAIM_EVIDENCE_MAP

双页面

页面一怎么算：舞弊模型打分

① 历史舞弊公司数据文件夹

公司 / 年份 / 是否舞弊

（Day2 下午训练过的数据）

② 训练舞弊模型 树

树模型 / 随机森林

（沿用 Day2 的模型与特征）

③ 最新年报打分 打分卡

每家公司一个舞弊指数 0–1

（带特征值，可追溯）

打分卡示例

平安银行：舞弊指数 0.87 ｜ 高风险 ｜ 应收激增 +46%、现金占比 -38%

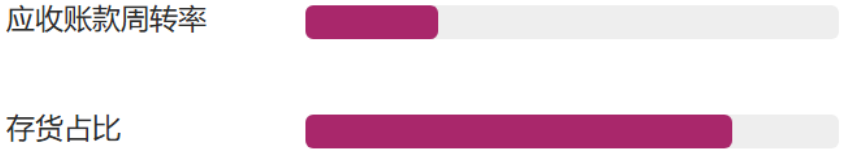
（每个分数都带特征值，不是孤立的数字）

重点不是模型多复杂，而是打分依据可追溯

双页面

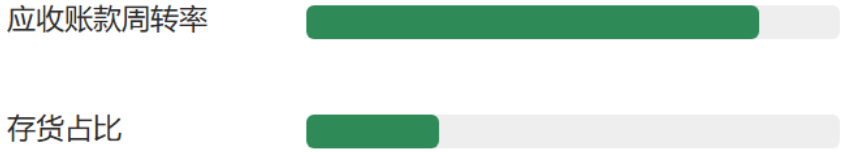
页面一怎么画：特征可视化

重点关注公司



应收低、存货高、现金薄、利润弱

正常公司



周转快、库存健康、现金充裕、盈利稳

特征可视化让「为什么是它」一眼可见

树模型说哪些特征重要（Day2），这里画出这些特征在重点公司长什么样

页面二整体样板

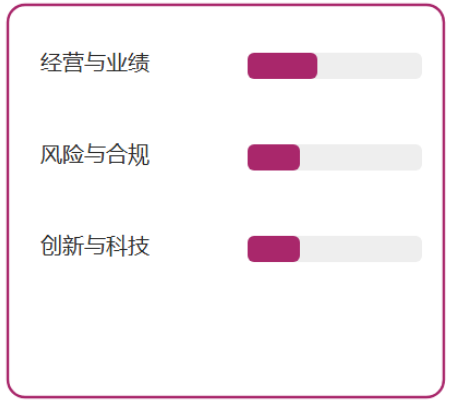
MD&A 文本画像 · 年报管理层讨论与分析

① MD&A 文本画像

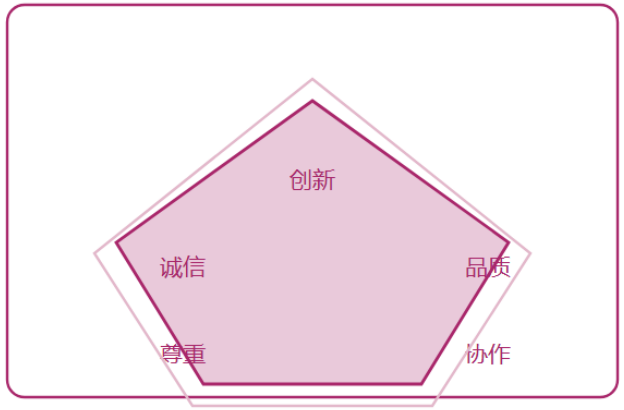
② 词云



③ 主题分布



④ 文化维度雷达



⑤ 口径说明：基于 MD&A 语料，与原论文电话会口径不可直接比较

页面二怎么画：词云

词云：年报在「说什么」



词频越高字越大

词云只讲「什么词出现多」，
不讲语义与情感

注意：

词云是探索工具，不是结论；
语义判断交给主题与文化维度

能快速看出这家公司年报在「说什么」

页面二怎么画：主题聚类

主题聚类：叙事往哪偏

公司A
年报 MD&A

公司B
年报 MD&A

公司C
年报 MD&A

LDA
主题模型

主题 1 · 经营与业绩
- 营收
- 利润
- 市场
- 客户

主题 2 · 风险与合规
- 风险
- 合规
- 内控
- 审计

主题 3 · 创新与科技
- 研发
- 创新
- 数字化
- 转型

每一家公司都落在主题分布上
可比谁的叙事更偏哪一面（主题名由人起，模型只给词）

LDA 实战①：输入 → 输出

LDA 主题聚类：输入 → 处理 → 输出

输入：MD&A 文本

公司A：经营情况讨论...

公司B：管理层分析...

公司C：报告期内业务...

.....（200 家公司）

处理：LDA

1 jieba 分词

2 去停用词

3 词频矩阵

4 主题模型 K=5

输出

① 每个主题 Top 10 词

② document–topic 分布（每家公司）

③ 主题名（人工标注）

要点：LDA 只输出词与概率，主题名由人看 top 词来标注

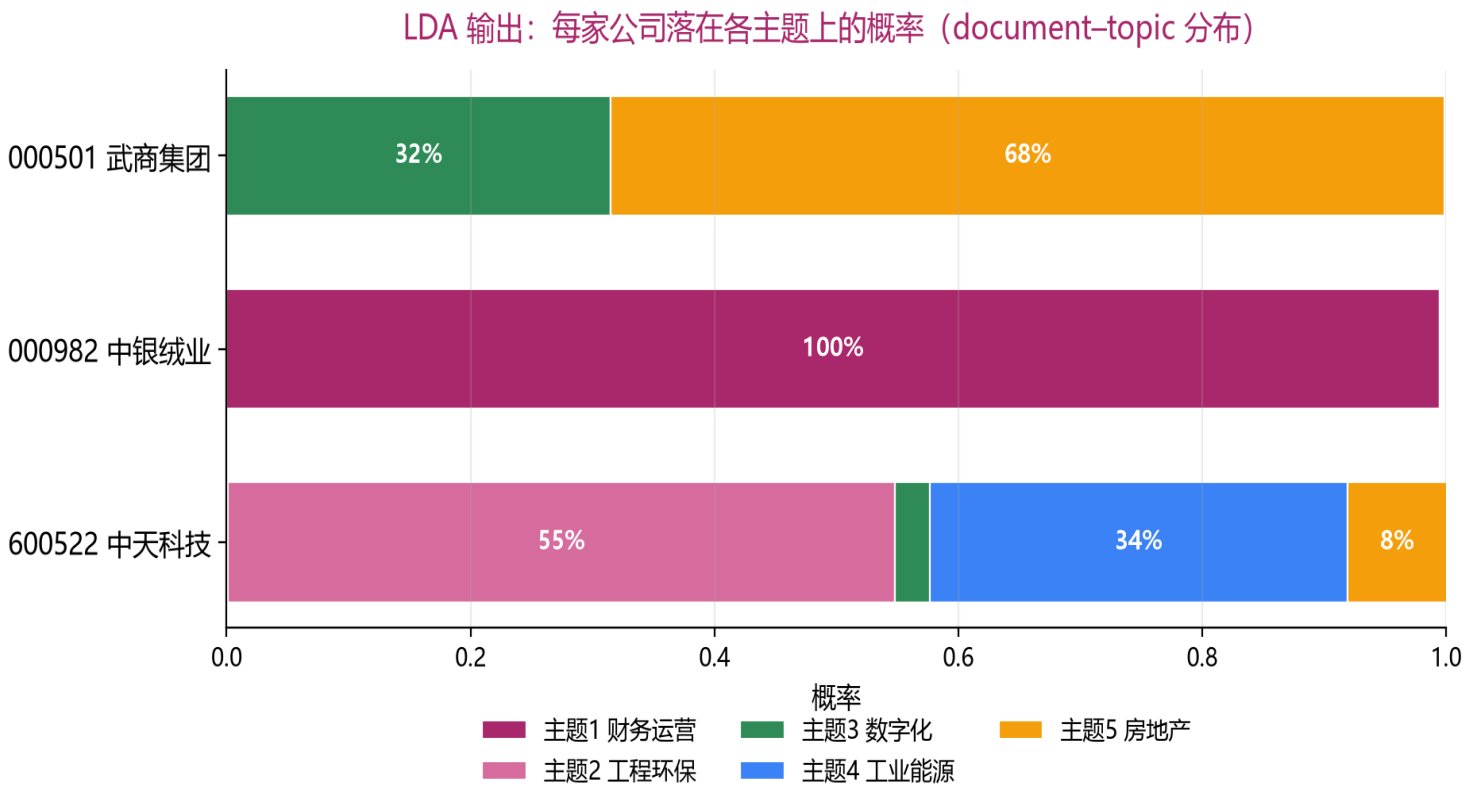
先出词 → 人标注主题 → 才算完成（又是「判断在人」）

K 的选择：先跑 3–5 个，看每个主题的 top 词是否可读

LDA 实战②：输出长什么样——Top 10 词

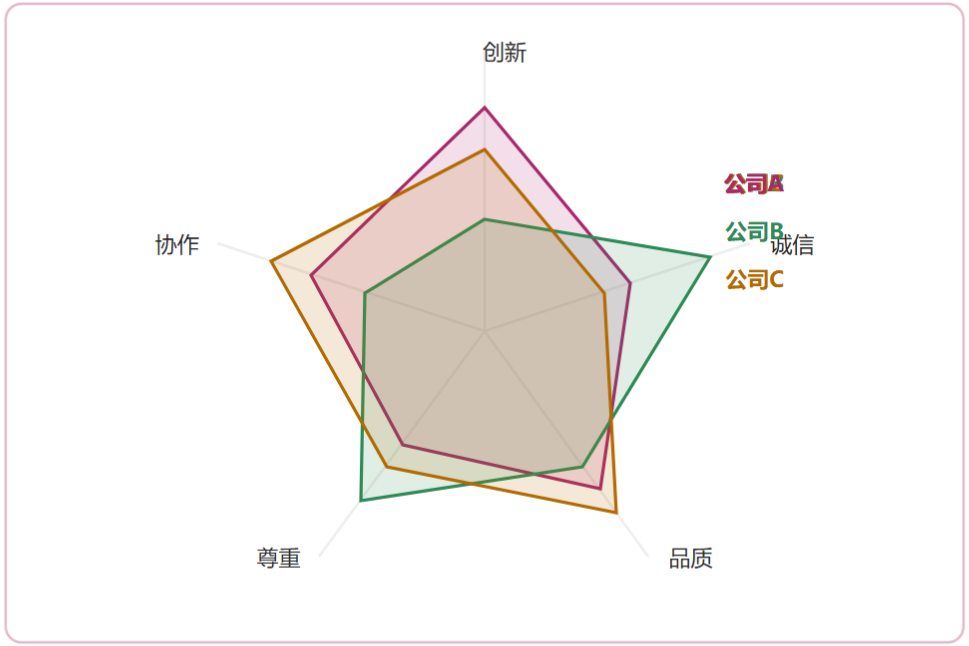
词位	主题1 财务运营	主题2 工程环保	主题3 数字化	主题4 工业能源	主题5 房地产
词1	子公司	设备	平台	制造	房地产
词2	调整	环保	品牌	工业	面积
词3	构成	工程	智能	医院	政策
词4	合计	科技	运营	能源	全国
词5	数据	系统	渠道	设备	开发
词6	处理	完善	系统	智能	商业
词7	期末	产业	应用	材料	住宅
词8	发生	体系	数据	医疗	区域
词9	销售量	中心	互联网	新能源	城市
词10	费用	优势	提供	天然气	增速

LDA 实战③：document－topic 分布



页面二怎么画：文化维度分布

文化维度分布：五维雷达对比



得分来自上午的五维文化词典

+ TF-IDF 加权计数

注意：

描述性证据，MD&A 是管理层自述，

不能直接做因果结论

对比才有意义：单看一家公司的绝对分数没有参照系

双页面

报告里必须有哪几块

一份报告必须有哪六块

① 问题

要回答的是什么

② 数据

从哪来、怎么抽的

③ 方法

用什么模型、什么参数

④ 结果

主要发现 + 图

⑤ 限制

哪些话不能说

没有第⑤条的报告，
答辩时一定会被追问

⑥ 附录

代码、日志、证据表

动态报告的好处

- 用 report.qmd 把数据、代码、图表串在一起
- 好处：数据一改，重新运行就全部更新
- 不必再手动改数字、重截图、重排版
- 这本身就是可复现研究的标准做法

03

可视化 Skill 工具箱

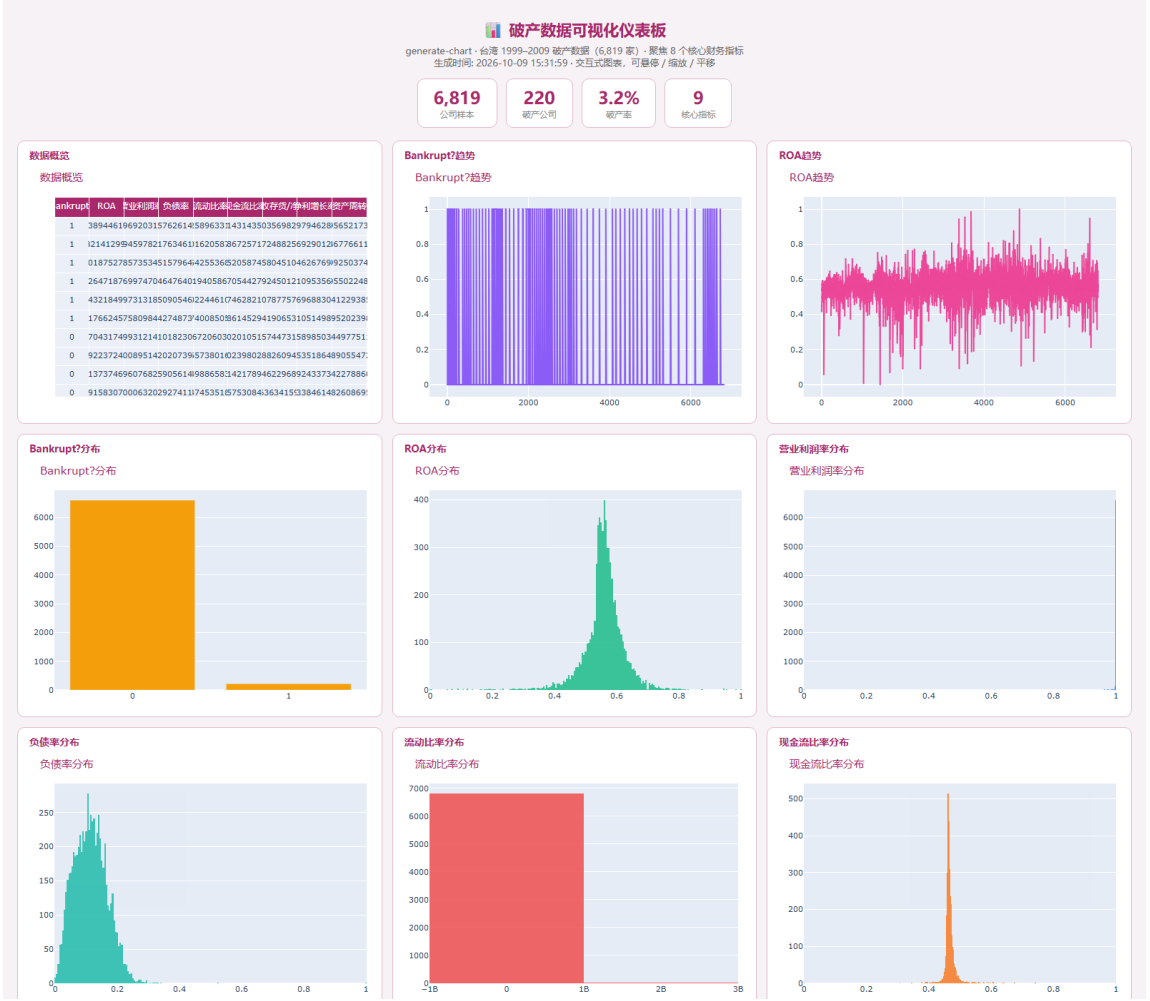
generate-chart • knowledge-graph-pro • 特征选择五图

让 Skill 帮你出图：两个可视化 Skill

- **表格数据 → generate-chart：一键生成交互式仪表板**
- 文本数据 → knowledge-graph-pro：一键生成业务关系图谱
- 都是 SkillHub 社区 Skill，装完即用，不写代码
- 演示完你就知道：今天项目的两张图也能这么做

Skill 出图

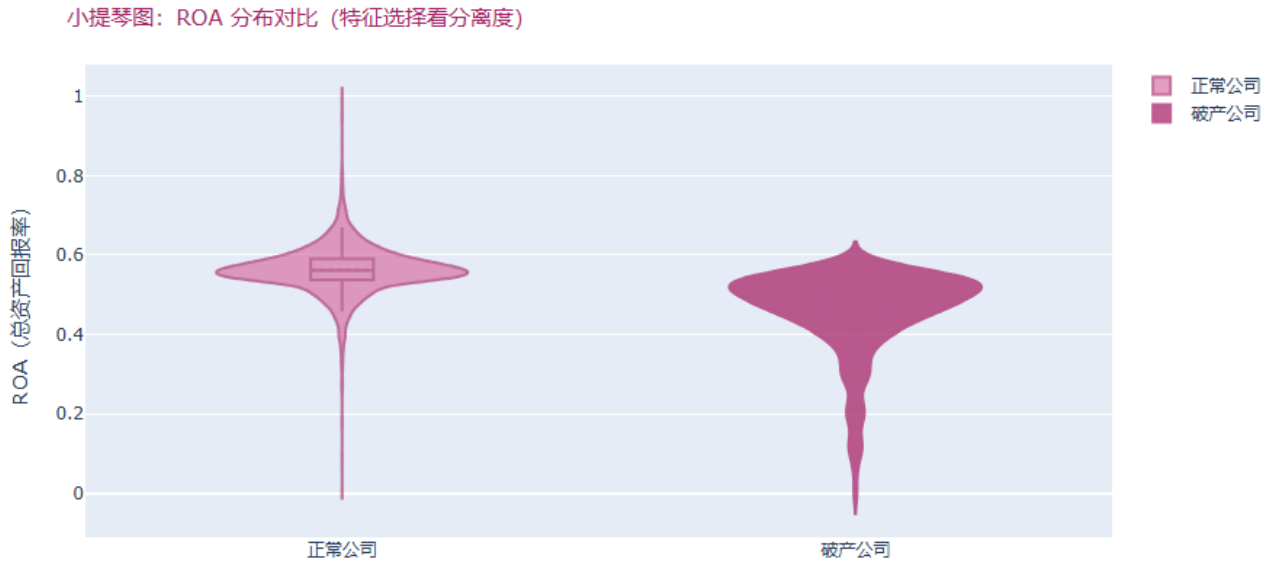
实战：破产数据 → 交互式仪表板



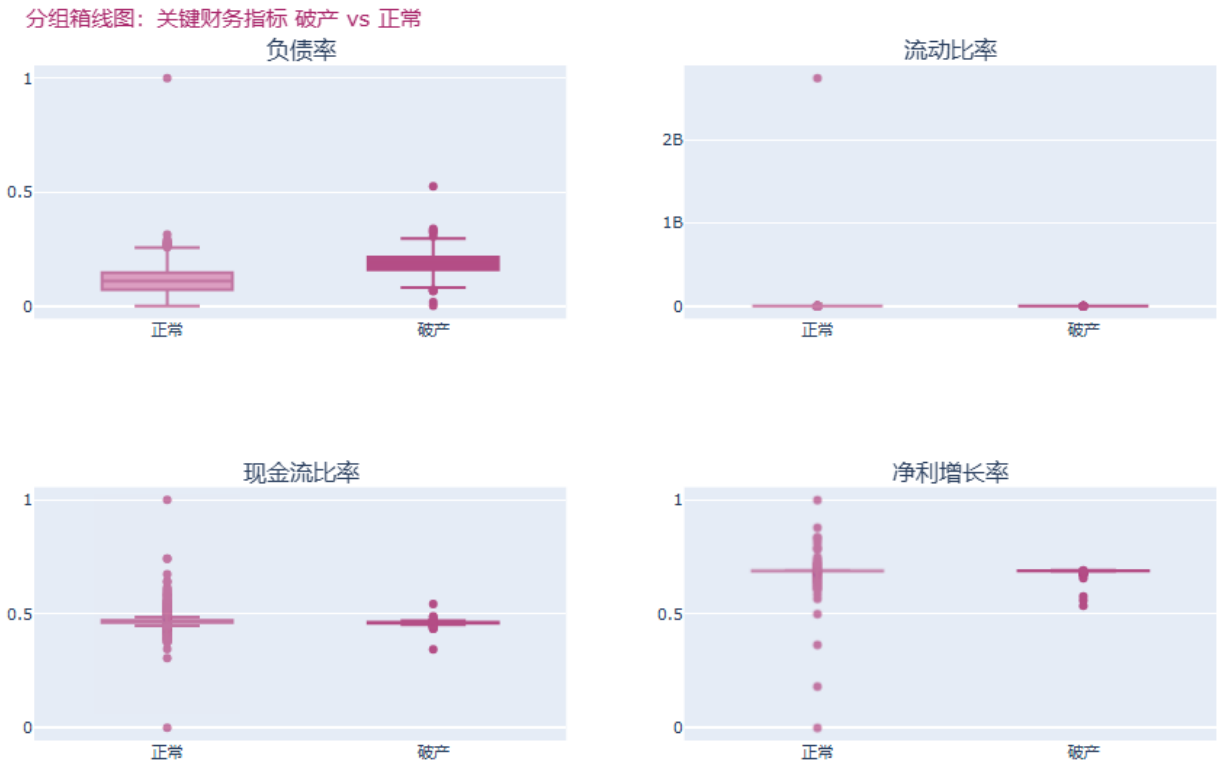
实战：MD&A → 业务相似图谱



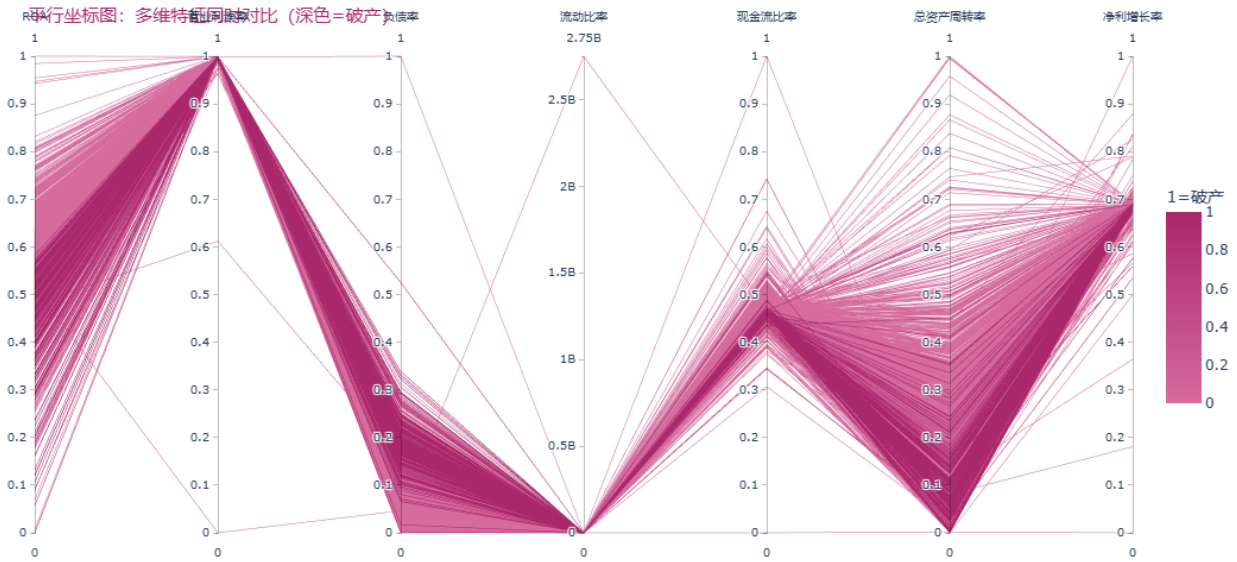
特征选择可视化①：小提琴图



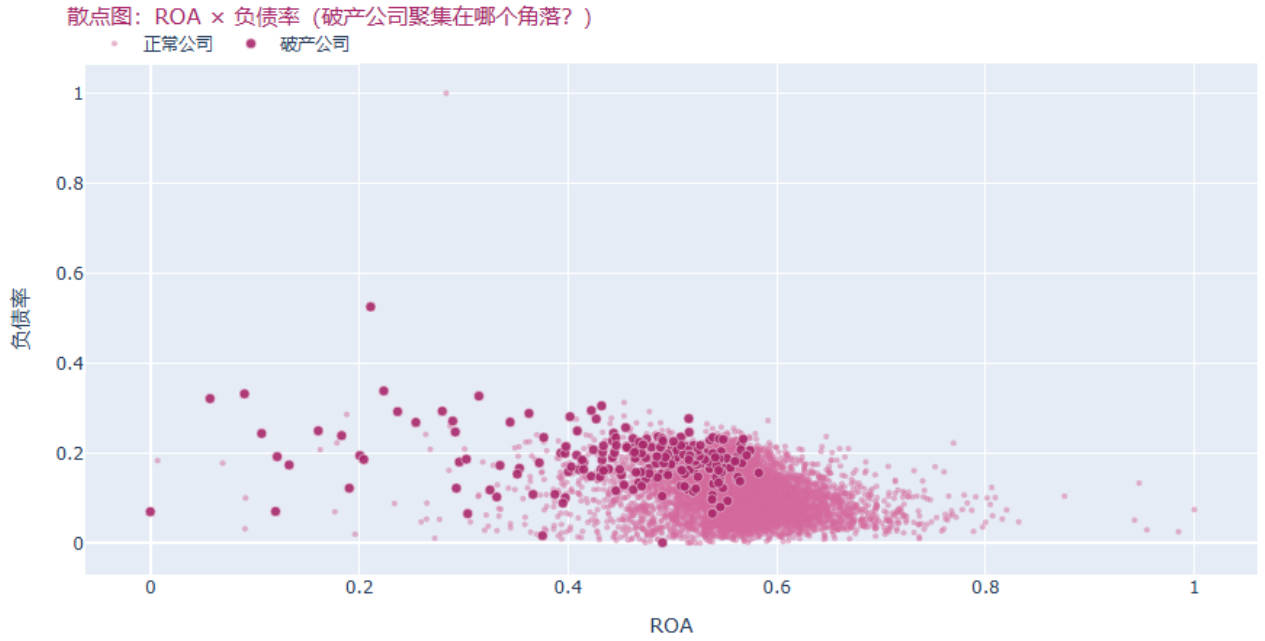
特征选择可视化②：分组箱线图



特征选择可视化③：平行坐标图

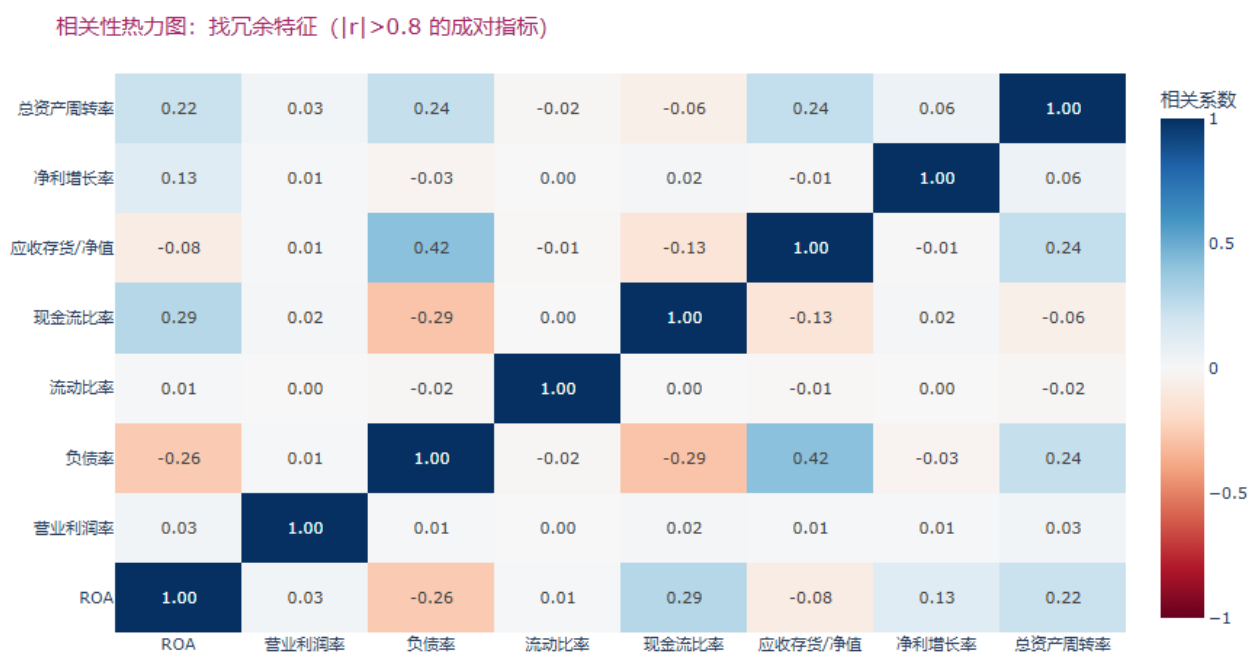


特征选择可视化④：散点图



Skill 出图

特征选择可视化⑤：相关性热力图



安装与使用：两行命令

- **安装 CLI（一次性）：curl -fsSL ...install.sh | bash**
- 安装 Skill: skillhub install generate-chart --namespace user_af28adda
- 安装 Skill: skillhub install knowledge-graph-pro --namespace user_52a81e7a
- 装完即可像刚才那样调用

04

报告与发布

追溯结论 • 发布上线 • 离线退路

★ 追溯结论：每一条都要能被核查

- **建立 CLAIM_EVIDENCE_MAP.csv**
- 挑出 5 到 10 条核心结论
- 每条映射到数据表、模型输出、图表或年报原文
- 这张表让报告里的每句话都能被逐条核查

这张表长什么样

结论—证据映射表 (CLAIM_EVIDENCE_MAP.csv)

结论编号	结论原文	证据类型	证据位置
C1	公司 2024 年偿债压力上升	模型输出	model/pred_2024.csv
C2	年报强调「科技创新」	文本抽取	年报 P32 第 3 段
C3	行业景气度处于下行区间	外部数据	data/macro_2024.csv
C4	舞弊风险集中在应收账款	模型输出	model/audit_2024.csv
C5	研发投入大幅增长	文本抽取	（空）

这一行不许留空

结论和证据一一对应，答辩时才能逐条追溯

发布之前：先过一遍红线

- **回到 Day1 下午讲的数据公开边界**
- 付费数据不能上传，含个人信息的数据不能上传
- 拿不准的一律只放获取脚本与字段说明
- 确认之后再动手发布

演示：发布到 GitHub Pages

发布到 GitHub Pages 四步

① 本地生成

quarto render

产出 report.html

≈2 min　　终端窗口

→

② 推送到 GitHub

git add / commit / push

到仓库 main 分支

≈1 min　　Git 图标

→

③ 开启 Pages

Settings → Pages

选分支与目录

≈3 min　　设置图标

→

④ 拿到链接

https://...github.io/report

地址栏 + 地球图标

即时　　链接图标

发布前检查一遍：

有没有把密钥、绝对路径、
个人信息推上去

扫码打开

(二维码占位)

链接会放进简历，也会被评委打开——它代表你的交付质量

README 里要写清六件事

项目骨架：开工前先让 AI 把"房子"盖好

推荐的项目目录结构

```
bankrupt_project/
    ├── data/  原始与处理后数据
    ├── src/  代码模块
    ├── models/  保存的模型
    ├── reports/  图表与分析报告
    └── docs/  项目文档与实验日志
```

关键文件：

docs/README.md —— 目标 · 目录职责 · 命名规范

docs/experiment_log.md —— 每次实验必记录

models/model_card.md —— 冠军模型的"身份证"

同时在 README 里定下的命名规范

· Python 模块：snake_case

例：data_prep.py、train.py

· 模型文件：模型名_日期.pkl

例：random_forest_20260914.pkl

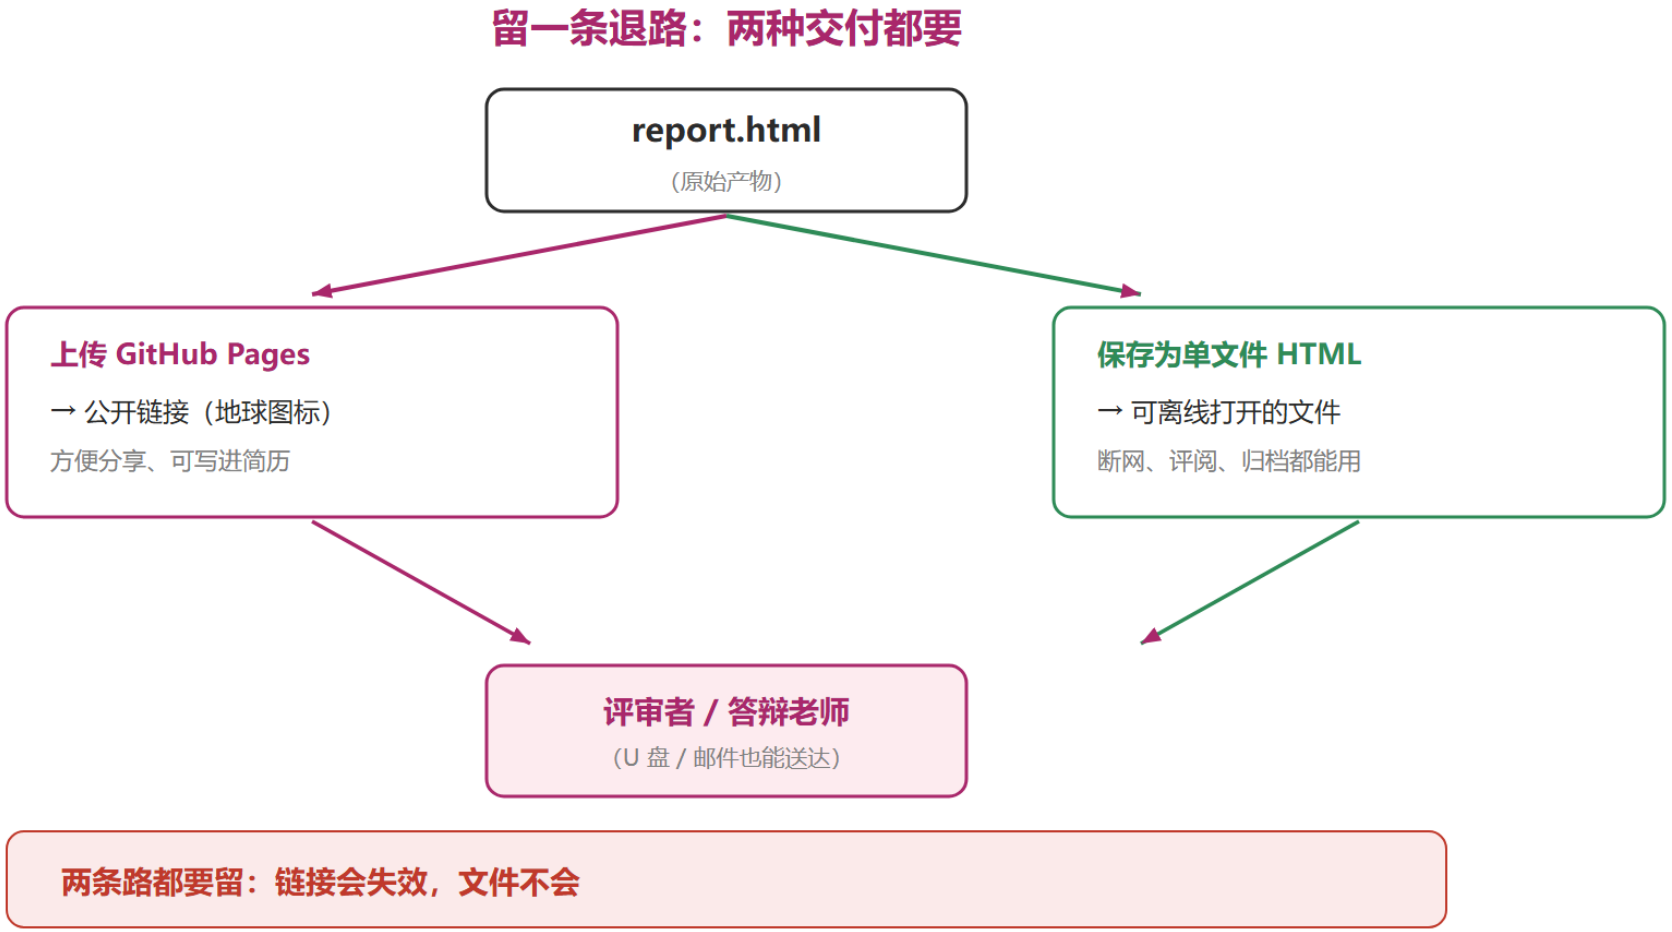
· 报告文件：日期_主题.md

例：2026-09-14_数据质量报告.md

为什么值得花这 3 分钟?

否则 AI 会把脚本、数据、图片随手散落，
项目不可复现、不可交接

留一条退路


留一条退路：两种交付都要
report.html
（原始产物）
上传 GitHub Pages
→ 公开链接（地球图标）
方便分享、可写进简历
保存为单文件 HTML
→ 可离线打开的文件
断网、评阅、归档都能用
评审者 / 答辩老师
（U 盘 / 邮件也能送达）
两条路都要留：链接会失效，文件不会

05

收尾

答辩四问 + 三天回顾

怎么把这个项目讲出来

- **做完不算完，还要能被人问住**
- 评委常问的四个问题，我们一个个过
- 每个问题示范怎么回答
- 课后大家写一份两分钟介绍稿

四个必答题

评委常问的四个问题

① 数据怎么来的？ 下载

· 来源、时间、获取方式

· 哪些能公开、哪些只留脚本

② 怎么防止数据泄漏？ 锁

· 划分时点（信息可得时间）

· 标准化只用训练集

③ 这个结果凭什么可信？ 曲线

· 交叉验证、测试集只用一次

· 类别不平衡处理

④ 这条结论的证据在哪？ 放大镜

· 结论编号 → 证据映射表

· 人做了哪些判断，不是「都是 AI 做的」

答得上来这四问，这份作业就站得住

两分钟介绍稿

- **四个必答点：问题是什么、数据从哪来、结果为什么可信、人做了什么**
- 写成稿子，课后录成视频即可
- 不用在直播里逐一展示，节省大家时间
- 这是给自己的项目留一份说明，也是求职时能用上的东西

三天回顾

连享会 · 2026 AI 数据分析实战专题（三天）

Day 1 · 数据采集

驱动 AI 从公开渠道
采集年报 / 公告 / 研报

练：数据获取与验收

Day 2 · 机器学习建模

构建财务困境预警模型
验证设计 · 评估指标 · 模型解释

今天这堂先导课 = Day 2 入门

Day 3 · 文本挖掘

从年报文本中抽取信号
可视化 + 报告交付

练：文本处理与表达

三天结束，你带走四项资产

一份分析报告
每个结论可追溯到出处

可复现 GitHub 仓库
别人能重跑你的结果

公开项目主页
可直接写进简历

一套可复用模板
换个数据照样跑